在高斯-马尔可夫假定下，OLS估计量方差与解释变量的关系是：**解释变量的变异程度越大，估计量方差越小；解释变量之间相关性越高，估计量方差越大。**

具体分两种情况看：

1. 一元回归

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

- 分母是解释变量的**总变异**（离差平方和）。
- 解释变量变异越大，分母越大，方差越小，估计越精确。
- 所以样本中x的取值范围越广、波动越大，估计越可靠。

2. 多元回归

$$Var(\hat{\beta}_j) = \frac{\sigma^2}{SST_j(1 - R_j^2)}$$

其中：

- $SST_j = \sum(x_{ij} - \bar{x}_j)^2$：第j个解释变量的总变异。
- R_j^2：把第j个解释变量对其余所有解释变量回归得到的R^2，衡量**多重共线性**程度。

关系可以概括为：

- **自身变异 SST_j 越大** → 方差越小。
- **与其他解释变量相关性越高（R_j^2 越接近1）** → 分母越小 → 方差越大，即多重共线性会放大方差。
- **扰动项方差 σ^2 越大** → 方差越大（这是你已知道的部分）。

一句话总结：估计量方差与解释变量的自身变异成反比，与解释变量之间的共线性程度成正比。

在矩阵形式下，OLS估计量为：

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

其方差-协方差矩阵为：

$$Var(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

理解的关键在于 $(\mathbf{X}'\mathbf{X})^{-1}$ 这个矩阵。

1. 把 $\mathbf{X}'\mathbf{X}$ 看成“信息矩阵”

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} n & \sum x_{i2} & \cdots & \sum x_{ik} \\ \sum x_{i2} & \sum x_{i2}^2 & \cdots & \sum x_{i2}x_{ik} \\ \vdots & \vdots & \ddots & \vdots \\ \sum x_{ik} & \sum x_{ik}x_{i2} & \cdots & \sum x_{ik}^2 \end{pmatrix}$$

它度量的是**解释变量所包含的信息量**：

- 对角线元素 $\sum x_{ij}^2$ 越大 → 第j个变量自身变异越大 → 信息越多。
- 非对角线元素 $\sum x_{ij}x_{il}$ 越大 → 两个变量越相关 → 信息重叠，独立信息反而少。

$\mathbf{X}'\mathbf{X}$ 越大（在矩阵正定意义下），其逆越小，方差越小。

2. 用特征值分解理解 $(\mathbf{X}'\mathbf{X})^{-1}$

设 $\mathbf{X}'\mathbf{X}$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_k > 0$，则 $(\mathbf{X}'\mathbf{X})^{-1}$ 的特征值为 $1/\lambda_1 \leq 1/\lambda_2 \leq \cdots \leq 1/\lambda_k$。

- **特征值越大** → 对应方向上解释变量变异越大 → 该方向估计方差越小。
- **特征值越小** → 对应方向上解释变量变异很小（近似共线）→ 该方向估计方差极大。

所以：

$$\text{最小特征值 } \lambda_{\min} \text{ 越小，最大方差越大}$$

这正是一元回归中分母 $\sum(x_i - \bar{x})^2$ 的推广。

3. 与多重共线性的联系

对于第j个系数：

$$Var(\hat{\beta}_j) = \sigma^2[(\mathbf{X}'\mathbf{X})^{-1}]_{jj}$$

可以证明：

$$[(\mathbf{X}'\mathbf{X})^{-1}]_{jj} = \frac{1}{SST_j(1 - R_j^2)}$$

这与前面标量形式完全一致。矩阵形式的优势在于：

- $(\mathbf{X}'\mathbf{X})^{-1}$ 的**对角元**给出各系数方差；
- **非对角元**给出系数之间的协方差；
- 当 $\mathbf{X}'\mathbf{X}$ 接近奇异（$\lambda_{\min} \approx 0$）时，逆矩阵元素爆炸，方差急剧增大。

4. 一句话总结

矩阵形式下，估计量方差为 $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$：

- $\mathbf{X}'\mathbf{X}$ 是解释变量的**信息矩阵**；
- 信息矩阵越大（变量变异大、共线性弱）→ 逆越小 → 方差越小；
- 信息矩阵越小（变异小、共线性强）→ 逆越大 → 方差越大；
- 特征值分解给出几何直观：方差在信息量小的方向上最大。

附录：第 3 点中关键等式的证明

1. 设定与记号

设回归模型有 k 个参数（含截距），解释变量矩阵为：

$$\mathbf{X} = (\mathbf{1}, \mathbf{x}_2, \ldots, \mathbf{x}_k)$$

把第 j 个解释变量记为 $\mathbf{x}_j$，其余解释变量组成的矩阵记为 $\mathbf{X}_{-j}$。

定义：

- $SST_j = \sum_{i=1}^{n}(x_{ij} - \bar{x}_j)^2$：第 j 个解释变量的总变异。
- R_j^2：把 $\mathbf{x}_j$ 对其余所有解释变量（含截距）回归得到的决定系数。

2. 用分块矩阵求逆

把 $\mathbf{X}'\mathbf{X}$ 按第 j 个变量分块：

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} \mathbf{A} & \mathbf{b} \\ \mathbf{b}' & c \end{pmatrix}$$

其中：

- $c = \mathbf{x}_j'\mathbf{x}_j = \sum_i x_{ij}^2$
- $\mathbf{b} = \mathbf{X}_{-j}'\mathbf{x}_j$
- $\mathbf{A} = \mathbf{X}_{-j}'\mathbf{X}_{-j}$

分块矩阵求逆公式给出右下角元素：

$$[(\mathbf{X}'\mathbf{X})^{-1}]_{jj} = \frac{1}{c - \mathbf{b}'\mathbf{A}^{-1}\mathbf{b}}$$

3. 识别 $c - \mathbf{b}'\mathbf{A}^{-1}\mathbf{b}$

$c - \mathbf{b}'\mathbf{A}^{-1}\mathbf{b}$ 正是把 $\mathbf{x}_j$ 对其余解释变量回归后的**残差平方和**。

理由：把 $\mathbf{x}_j$ 对 $\mathbf{X}_{-j}$ 回归，OLS 拟合值为：

$$\hat{\mathbf{x}}_j = \mathbf{X}_{-j}(\mathbf{X}_{-j}'\mathbf{X}_{-j})^{-1}\mathbf{X}_{-j}'\mathbf{x}_j = \mathbf{X}_{-j}\mathbf{A}^{-1}\mathbf{b}$$

残差平方和：

$$RSS_j = \|\mathbf{x}_j - \hat{\mathbf{x}}_j\|^2 = \mathbf{x}_j'\mathbf{x}_j - \mathbf{x}_j'\mathbf{X}_{-j}\mathbf{A}^{-1}\mathbf{X}_{-j}'\mathbf{x}_j = c - \mathbf{b}'\mathbf{A}^{-1}\mathbf{b}$$

所以：

$$[(\mathbf{X}'\mathbf{X})^{-1}]_{jj} = \frac{1}{RSS_j}$$

4. 把 RSS_j 与 SST_j、R_j^2 联系起来

注意：这个回归**含截距**，因此总变异可以分解：

$$SST_j = RSS_j + ESS_j$$

其中 ESS_j 是回归平方和。于是：

$$R_j^2 = \frac{ESS_j}{SST_j} = 1 - \frac{RSS_j}{SST_j}$$

因此：

$$RSS_j = SST_j(1 - R_j^2)$$

代入第3步结果：

$$[(\mathbf{X}'\mathbf{X})^{-1}]_{jj} = \frac{1}{RSS_j} = \frac{1}{SST_j(1 - R_j^2)}$$

5. 最终结论

$$Var(\hat{\beta}_j) = \sigma^2[(\mathbf{X}'\mathbf{X})^{-1}]_{jj} = \frac{\sigma^2}{SST_j(1 - R_j^2)}$$

证明完成。

6. 直观理解

- 分块求逆的右下角元素，本质是**剔除其他变量影响后**第 j 个变量的剩余变异。
- 这个剩余变异就是 $RSS_j = SST_j(1 - R_j^2)$。
- 剩余变异越小（自身变异小或共线性强），分母越小，方差越大。