



高级计量经济学

(2026/27学年度 秋季学期)

第二讲：高等数学基础知识回顾

本讲主要内容

概率与统计相关知识

- 随机变量与统计分布
- 参数估计
- 假设检验

线性代数相关知识

- 矩阵定义及运算
- 特征根及特征矩阵
- 矩阵求导

一、概率与统计相关知识

➤ 随机变量

- 如果一个随机变量只能取**特定的值**，则称为**离散变量**。比如抛100次硬币正面朝上的次数。
- 如果一个随机变量可以取某一实数区间中的**任意值**，则称为**连续变量**。例如某校冬季供暖每小时能源消耗量。
- 通常都用大写字母表示随机变量（如X或Y），用小写字母表示其具体结果（如x或y）。

➤ 概率分布函数与概率密度函数

- 概率分布函数：一般用 $F(x)$ 表示；
- 概率密度函数：一般用 $f(x)$ 表示；
- 分布函数、密度函数决定随机变量X在指定区间取值的概率。

➤ 一类经典的连续分布：正态分布


▪ 正态分布又名高斯分布，是具有两个参数 μ 和 σ^2 的连续型随机变量的分布，第一个参数 μ 是遵从正态分布的随机变量的均值，第二个参数 σ^2 是此随机变量的方差。因此，正态分布一般记作 $N(\mu, \sigma^2)$ ，其概率密度函数为：

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad -\infty < x < +\infty$$

➤ **标准正态分布：**均值 $\mu = 0$ ，方差 $\sigma^2 = 1$ 的正态分布称为标准正态分布，其概率密度函数为：

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right), \quad -\infty < x < +\infty$$

右图中 $P(a \leq X \leq b)$ 表示a和b之间的阴影部分，是指该分布的取值在a到b之间的概率。



➤ 随机变量的矩(moments)

- 从统计学角度来说，一个随机变量 X 的第 n 阶矩可以定义为：

$$\text{中心矩: } E[(X - \mu)^n] = \int_{-\infty}^{+\infty} (x - \mu)^n f(x) dx$$

$$\text{原点矩: } E[X^n] = \int_{-\infty}^{+\infty} x^n f(x) dx$$

其中, μ 表示 X 的均值, $E(\cdot)$ 代表期望。

- **常用 n 阶矩示例：**
 - 一阶原点矩被称为均值或者**期望**，经常使用 μ 来表示，它度量了随机分布的中央位置。
 - 二阶中心矩被称为**方差**，经常用 σ^2 来表示，它衡量了 X 的变化幅度。
 - 方差的平方根称为标准差，用 σ 表示。
 - 均值和方差被广泛地用来刻画各种随机分布（尤其是正态分布）的特性。

$$E[(X - \mu)^n] = \int_{-\infty}^{+\infty} (x - \mu)^n f(x) dx$$

- 三阶中心矩被称为**偏度**(skewness), 度量了随机变量分布的非对称程度。如果偏度统计量为正值, 说明 X 的分布具有右侧长尾特征, 而负的偏度表明左侧长尾特征。
- 四阶中心矩又称为**峰度**(kurtosis), 其衡量随机变量分布的尖峰程度或平坦程度。
- 为了保证偏度和峰度的计算在不同分布、不同样本之间具有可比性, 通常进行标准化处理, 即计算: $E \left[\frac{X - \mu}{\sigma} \right]^n$ 。
 - 正态分布的峰度为3, 据此可以定义超额峰度: $E \left[\frac{X - \mu}{\sigma} \right]^4 - 3$ 。
 - 如果随机变量 X 的峰度大于3 (比如 t 分布), 则其密度函数的两侧尾部更“厚”(fat tails)。
- 偏度和峰度统计量可以用来检验随机变量是否服从正态分布。

-
-
- 期望和方差在实践中运用最为广泛，二者具有下列性质：

假设 A 为常数， ε_t 和 u_t 为两个随机变量，则有：

- $E[A\varepsilon_t] = AE[\varepsilon_t]$
- $E[A + \varepsilon_t] = A + E[\varepsilon_t]$
- $E[u_t + \varepsilon_t] = E[u_t] + E[\varepsilon_t]$
- $Var[A\varepsilon_t] = A^2Var[\varepsilon_t]$
- $Var[A + \varepsilon_t] = Var[\varepsilon_t]$
- $Var[u_t + \varepsilon_t] = Var[u_t] + Var[\varepsilon_t] + 2Cov[u_t, \varepsilon_t]$

- 更多的时候，我们需要利用样本均值和方差估计随机变量的矩。

$$\hat{\mu} = \frac{1}{T} \sum_{t=1}^T x_t$$

$$\hat{\sigma}^2 = \frac{1}{T-1} \sum_{t=1}^T (x_t - \hat{\mu})^2$$

其中， T 表示随机变量的样本观察值个数。

➤ 联合概率

- 一对随机变量的概率函数称为联合概率分布。为简单起见，以离散随机变量为例讨论。设 X 或 Y 为离散随机变量，设 x 和 y 为其所取值。 $X = x$ 且 $Y = y$ 的概率就称为 X 和 Y 的联合概率函数，用 $f_{XY}(x, y)$ 表示，则 $f_{XY}(x, y) = P(X = x, Y = y)$ 。因为概率函数通常用 $f(\cdot)$ 表示，所以用下标 XY 来确认讨论中的随机变量为 X 和 Y 的联合。

- **统计独立性**

如果随机变量 X 和 Y 具有统计独立性，此时联合概率为单个概率的乘积。

对于连续随机变量： $f_{XY}(x, y) = f_X(x) \cdot f_Y(y)$

对于离散随机变量： $P(X = x, Y = y) = P(X = x)P(Y = y)$

➤ 随机变量无关的三个层次

- 对于连续型随机变量 X 与 Y ，如果其联合密度等于边缘密度的乘积，即 $f_{XY}(x, y) = f_X(x) \cdot f_Y(y)$ ，则称 X 与 Y 相互独立。
 - X 与 Y 相互独立，是随机变量“无关”的最强概念。
 - 线性不相关的概念更弱，仅要求 $Cov(X, Y) = 0$ 。
 - **“相互独立”意味着“线性不相关”，但反之不然。**
 - 二者之间还有一个中间层次的无关概念，即**“均值独立”**(mean-independence)。
 - **定义：**假设条件期望 $E(Y|X)$ 存在，如果 $E(Y|X)$ 不依赖于 X ，则称“ Y 均值独立于 X ” (Y is mean-independent of X)。
 - 均值独立不是对称的关系，“ Y 均值独立于 X ”并不意味着“ X 均值独立于 Y ”。

命题：“ Y 均值独立于 X ”当且仅当 $E(Y|x) = E(Y)$ [即条件期望等于无条件期望]。

证明：(1) 假设“ Y 均值独立于 X ”，则 $E(Y|x)$ 不依赖于 X ，故：

$$E_X[E(Y|x)] = E(Y|x)$$

▪ 根据迭代期望定律，可得：

$$E(Y) = E_X[E(Y|x)] = E(Y|x)$$

(2) 假设 $E(Y|x) = E(Y)$ ，则显然 $E(Y|x)$ 不依赖于 X 。

➤ 条件概率

- 给定某一随机变量X已发生的条件下另一特定随机变量Y发生的概率，称之为**条件概率**。
- 符号 “|” 代表给定。条件概率密度函数定义如下（同时适用于离散随机变量和连续随机变量）：

$$f_{Y|X}(x, y) = \frac{f_{XY}(x, y)}{f_X(x)} \quad f_X(x) > 0, \quad x \text{ 可取任何值}$$

其中， $f_{XY}(x, y)$ 为X和Y联合概率， $f_X(x)$ 为X的密度函数，通常称为X的边际密度。需要注意的是，条件概率依赖于x和y。当两个随机变量为独立统计时，条件概率分布变为相应的边际分布。

➤ 条件期望与条件方差

▪ 条件期望

给定 X 的情况下， Y 的期望值即为 Y 对 X 的条件期望值。以离散随机变量为例，条件期望可表示为： $E(Y|X = x) = \sum_{Y=y} y \cdot f_{Y|X}(x, y)$ ，即以条件密度 $f_{Y|X}(x, y)$ 作为权重的 Y 的期望。

▪ 条件方差

假设 $\mu^*(X)$ 为 Y 对 X 的条件期望，即 $E(Y|X)$ ，则 Y 对 X 的条件方差定义为 $Var(Y|X) = E_{Y|X}[(Y - \mu^*)^2|X]$ ，即在 X 值给定的前提下，求 Y 对 X 的条件期望以及条件密度 $f_{Y|X}(x, y)$ 为权重求该均值的方差。

- **条件期望与条件方差的性质:**

1) $E[\mu(X)|X] = \mu(X)$

2) $E([a(X) + b(X)Y]|X) = a(X) + b(X)E(Y|X)$

3) $E_{XY}(Y) = E_X[E_{Y|X}(Y|X)]$

4) $Var(Y) = E_X[Var(Y|X)] + Var_X[E(Y|X)]$

➤ 协方差和相关系数

- 函数 $g(X, Y) = (X - \mu_X)(Y - \mu_Y)$ 的期望值称为X和Y的**协方差**，用 σ_{XY} 或 $Cov(X, Y)$ 表示。

- 随机变量X和Y的协方差定义为：

$$\begin{aligned}\sigma_{XY} = Cov(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] = E[XY - X\mu_Y - Y\mu_X + \mu_X\mu_Y] \\ &= E(XY) - \mu_Y E(X) - \mu_X E(Y) + \mu_X\mu_Y = E(XY) - \mu_X\mu_Y\end{aligned}$$

- 对协方差进行“标准化”，即可得到X和Y之间的**相关系数**，用 ρ_{XY} 表示。X和Y之间的相关系数定义为：
$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \cdot \sigma_Y} = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}}。$$

- 独立的两个变量一定不相关，但不相关的两个变量不一定独立。

▪ 协方差与相关系数的性质

- 1) 如果 a 、 b 为常量, 则 $Var(aX + bY) = a^2Var(X) + b^2Var(Y) + 2abCov(X, Y)$ 。
- 2) 相关系数 ρ_{XY} 的取值介于-1到1之间。
- 3) 如果 X 和 Y 相互独立, 则 $\sigma_{XY} = Cov(X, Y) = 0 = \rho_{XY}$; 即 X 和 Y 不相关。结合上面的性质 1), 可以得出: 在这种情况下, $Var(X + Y) = Var(X) + Var(Y)$, 且 $Var(X - Y) = Var(X) + Var(Y)$ 。
- 4) 如果 $U = a_0 + a_1X$, $V = b_0 + b_1Y$, 且 $a_1b_1 > 0$, 则 $\rho_{UV} = \rho_{XY}$; 即在**单位比例改变**的情况下, 相关系数保持恒定。如果 $a_1b_1 < 0$, 则 $\rho_{UV} = -\rho_{XY}$ 。

但当 $U = a_0 + a_1X_1 + a_2X_2$, $V = b_0 + b_1Y_1 + b_2Y_2$ 时, $\rho_{UV} \neq \rho_{XY}$ 。这说明在**一般线性变换**的情况下, 相关系数为变量 (a_i 和 b_i 均不为零)。

➤多元分布

- 设 $x_1, x_2, x_3, \dots, x_n$ 为 n 个随机变量，其联合概率密度函数为 $f_X(x_1, x_2, x_3, \dots, x_n)$ 。

如果联合概率密度函数等于单个概率密度函数的乘积，则其相互独立：

$$f_X(x_1, x_2, \dots, x_n) = f_{X_1}(x_1)f_{X_2}(x_2) \dots f_{X_n}(x_n)$$

- 应用：极大似然估计（MLE）的推导

➤多元分布的性质

- 线性组合的期望为期望的线性组合。如果 $a_1, a_2, \dots, a_n$ 为常量, 设 $U \equiv \sum a_i x_i$, 则

$$EU \equiv E[a_1 x_1 + a_2 x_2 + \dots + a_n x_n] = a_1 E(x_1) + a_2 E(x_2) + \dots + a_n E(x_n)$$

- 若干**独立同分布** (i.i.d.) 随机变量均值的期望等于它们的共同期望。
- 线性组合的方差: $Var[\sum a_i x_i] = \sum_i a_i^2 Var(x_i) + \sum_{i \neq j} \sum a_i a_j Cov(x_i, x_j)$, 其中, a_i 为常量。
- 如果 $x_1, x_2, \dots, x_n$ 相互独立, 则在 $i \neq j$ 的情况下, $Cov(x_i, x_j) = 0 = \rho_{ij}$ 。
- **独立随机变量**的和的方差为所有方差的和。特别地, 当方差相同时, 对于每个 i , 都有 $Var(x_i) = \sigma^2$, 所以 $Var[\sum a_i x_i] = \sigma^2 \sum_i a_i^2$ 。
- 如果 $x_1, x_2, \dots, x_n$ 相互独立, 并且 $x_i \sim N(\mu, \sigma^2)$, 则有 $U \equiv \sum a_i x_i \sim N(\mu \cdot \sum_i a_i, \sigma^2 \cdot \sum_i a_i^2)$ 。
- 如果 $x_i \sim N(\mu, \sigma^2)$, 则它们的均值 $\bar{x} = \frac{1}{n} \sum x_i$ 服从正态分布, 均值为 μ , 方差为 σ^2/n 。

➤ 随机抽样

- 从总体中抽取一定数量的样本进行观察，并根据样本对总体的代表性及观察值来对总体进行推论的过程即为**抽样**。
- **简单随机抽样**可以使随机抽取的 n 个单位的任意组合具有均等的机会。随机变量 X 观察值的随机样本是独立同分布的随机变量 $x_1, x_2, \dots, x_n$ 的集合，其中的每个变量均具有和 X 相同的概率分布。
- 不含任何未知参数的随机变量观察值的函数称为样本统计量，最常用的包括样本均值（用 $\bar{x}$ 表示）和样本方差（用 s^2 表示）：

样本均值： $\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum x_i$

样本方差： $s^2 = \frac{1}{n-1} \underbrace{[(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2]}_{\text{离差平方和}} = \frac{1}{n-1} \sum (x_i - \bar{x})^2$

▪ **Q:** 为什么样本方差的公式里是离差平方和除以 $(n - 1)$ ，而不是 n ？

▪ **A:** 为了得到总体方差的无偏估计量。假设 $s^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ 是总体方差 σ^2 的无偏估计量，则样本方差 s^2 的期望可以表示为：

▪ $E(s^2) = E\left(\frac{1}{n} \sum (x_i - \bar{x})^2\right) = E\left[\frac{1}{n} \sum ((x_i - \mu) - (\bar{x} - \mu))^2\right]$ ，其中， μ 表示总体期望。进一步化简：

$$E\left(\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2\right) - E((\bar{X} - \mu)^2)$$

$$= \text{Var}(X) - \text{Var}(\bar{X})$$

$$= \sigma^2 - \frac{1}{n} \sigma^2$$

$$= \frac{n-1}{n} \sigma^2$$

$$E(S^2) = \frac{n-1}{n} \sigma^2$$

基于此，可证明：对未修正的样本方差乘以 $n/(n - 1)$ ，即修正为如前所述的表达式：

$$s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$$

即可得到总体方差 σ^2 的无偏估计量。

注：当样本量 n 很大时，是否修正影响不大。

➤ 正态总体抽样

- 设 X 为一个服从均值为 μ ，方差为 σ^2 的正态分布的随机变量。从总体中随机抽取 n 个样本，得到观察值 $x_1, x_2, \dots, x_n$ 。则：样本均值 $\bar{x} = \frac{1}{n} \sum x_i$ 服从正态分布，均值为 μ ，方差为 σ^2/n ，即： $\bar{x} \sim N(\mu, \sigma^2/n)$ 。
- 由此可以发现，样本均值在总体均值附近的分散较小，样本量越大，方差越小。
- 对于样本均值进行标准化，可得： $z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} = \sqrt{n} \frac{\bar{x} - \mu}{\sigma} \sim N(0,1)$ 。
- 更一般地，如果 $X \sim N(\mu, \sigma^2)$ ，则： $Z = \frac{X - \mu}{\sigma} \sim N(0,1)$ 。

➤ 大样本分布的两个性质

(1) 大数定律

- 概率论中讨论**随机变量序列**的算术平均值向随机变量各数学期望的算术平均值收敛的定律，根据收敛性的强弱不同，可分为**弱大数定律**和**强大数定律**。
- 设 $\bar{x}$ 为取自总体 X 的独立同分布的随机样本 $\{x_1, x_2, \dots, x_n\}$ 的样本均值，则 $\bar{x} = \frac{1}{n} \sum_i x_i$ 向总体期望 $\mu = E(X)$ 趋近。即：随着样本量 n 的增大，随机变量集合的样本均值就越接近其期望值。
- 由于 $E(\bar{x}) = \mu$ ，样本均值 $\bar{x}$ 趋向于 μ 。同样，随着 n 趋向于无穷大，样本方差 $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$ 趋向于总体方差 σ^2 。【依概率收敛】

(2) 中心极限定理

- 设 $\{x_1, x_2, \dots, x_n\}$ 为取自同一分布的观察值所组成的随机样本，均值为 μ ，方差为 σ^2 ，则随机变量 $Z_n = \sqrt{n} \frac{\bar{x} - \mu}{\sigma}$ 的抽样分布随着 n 趋向于无穷大而渐近服从标准正态分布 $N(0,1)$ ，又称“ $\sqrt{n}$ 收敛”。【依分布收敛】
- 应用：大样本OLS性质的推导

➤ 常用抽样分布

1) 卡方分布

- n 个独立标准正态随机变量平方和的分布称为卡方 χ^2 分布, 自由度为 n , 也写作 χ_n^2 。即 n 个独立同分布的随机变量 $Z_1, Z_2, \dots, Z_n$ 服从 $N(0,1)$ 分布。
- 定义一个新的随机变量 U , U 是 Z 的平方和, 即 $U = Z_1^2 + Z_2^2 + \dots + Z_n^2 = \sum Z_i^2$, 随机变量 U 的分布为 χ_n^2 。
- 卡方分布的期望值为其自由度 n 。
- 两个卡方分布之和仍为卡方分布, 自由度为两个卡方分布自由度之和。

2) t 分布 (学生分布)

- 设 $Z \sim N(0,1)$, $U \sim \chi_n^2$ 。 Z 和 U 相互独立, 则随机变量 $t = \frac{Z}{\sqrt{U/n}} = Z\sqrt{n}/\sqrt{U}$ 服从自由度为 n 的 t 分布。当 n 较大时, t 分布近似服从正态分布, 一般至少满足 $n \geq 30$ 。

3) F 分布

- 设 $U \sim \chi_m^2$, $V \sim \chi_n^2$ 相互独立, 则 $F = (U/m)/(V/n)$ 的分布称为 F 分布, 自由度为 m 和 n , 写作 $F \sim F_{m,n}$ 。

4) 样本统计量分布

- 从均值为 μ , 方差为 σ^2 的正态总体中抽取独立随机样本 $x_1, x_2, \dots, x_n$, 样本方差 $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$, 具有性质: $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$ 。
- $E(s^2) = \sigma^2$, 即样本方差 s^2 为总体方差 σ^2 的无偏估计量。
- $Z = \sqrt{n} \frac{\bar{x} - \mu}{\sigma} \sim N(0,1)$, 当以样本标准差 s 代替总体标准差 σ 时, 可得:

$$t = \sqrt{n} \frac{\bar{x} - \mu}{s} \sim t(n-1)$$

➤ 参数估计方法

矩估计法

- 设一个分布有 k 个未知参数，估计方法就是计算分布的前 k 个样本矩，再利用其作为对应总体矩的估计量。分布的总体均值也称作一阶原点矩，样本均值为总体均值的估计量；随机变量的方差也称为二阶中心矩，样本方差即分布总体方差的估计量。
- 示例：估计两个随机变量 X 和 Y 之间相关系数

$$s_{XY} = \widehat{Cov(X, Y)} = \frac{1}{n-1} \sum (x_i - \bar{x})(y_i - \bar{y})$$
$$r_{XY} = \frac{s_{XY}}{s_X s_Y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

最小二乘法——以均值为例（一元的简化情形）

- 由于 $E(x_i) = \mu$ ，每个观察值均可视为样本均值的估计量，该估计量的误差为 $e_i = x_i - \mu$ 。考虑能使误差平方和最小的估计量，即使得整个样本误差的平方和 $SSE(\mu) = \sum e_i^2 = \sum (x_i - \mu)^2$ 最小的估计量。

- 要找到使 SSE 最小的估计值 $\hat{\mu}$ ， $SSE(\hat{\mu})$ 可表示为

$$SSE(\hat{\mu}) = \sum (x_i - \hat{\mu})^2 = \sum (x_i - \bar{x})^2 + \sum (\bar{x} - \hat{\mu})^2 + 2 \sum (x_i - \bar{x})(\bar{x} - \hat{\mu})$$

- 对于上式，当且仅当 $\hat{\mu} = \bar{x}$ 时， SSE 最小，所以 μ 的最小二乘法估计量为样本均值 $\bar{x}$ 。

➤ 估计量性质——针对小样本

无偏性

- 如果 $E(\hat{\theta}) = \theta$ ，则估计量 $\hat{\theta}$ 为 θ 的无偏估计量。否则该估计量有偏，偏差为 $E(\hat{\theta}) - \theta$ 。

有效性

- 设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 为参数 θ 的两个无偏估计量,如果 $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$ ，则 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效。

不同估计量的比较：均方误差 (MSE)

- 估计量 $\hat{\theta}$ 的均方误差定义为 $MSE(\theta) = E[(\hat{\theta} - \theta)^2]$ ，即为从 $\hat{\theta}$ 到 θ 偏差平方的期望值。
- 如果 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 为的两个可选估计量，且 $MSE(\hat{\theta}_1) < MSE(\hat{\theta}_2)$ ，则 $\hat{\theta}_1$ 为均方有效系数。如果两个估计量都具有无偏性，则 $\hat{\theta}_1$ 更有效。
- 均方误差最小化，可视为在 “估计量方差” (variance) 与 “偏差” (bias) 之间进行权衡。

➤ 估计量性质——针对大样本

一致性

- 随着样本容量 n 增大，估计量接近 θ 的真实值。严格的定义为：对于所有 $\varepsilon > 0$ ，如果 $\lim_{n \rightarrow \infty} P(\theta - \varepsilon \leq \hat{\theta}_n \leq \theta + \varepsilon) = 1$ 成立，则估计量 $\hat{\theta}_n$ 为 θ 的**一致估计量**。

渐近无偏性

- 如果偏差随着 n 趋向于无穷大而趋近于零，则称估计量 $\hat{\theta}_n$ 是渐近无偏的。即：以 $b_n(\theta) = E(\hat{\theta}_n) - \theta$ 表示偏差，如果 $\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$ 或 $\lim_{n \rightarrow \infty} b_n(\theta) = 0$ ，则该估计量是**渐近无偏估计量**。

渐近有效性

- 如果对于所有的其他估计（以 $\hat{\theta}_2$ 表示），一致估计量 $\hat{\theta}_1$ 满足： $\lim_{n \rightarrow \infty} \left[\frac{Var(\hat{\theta}_1)}{Var(\hat{\theta}_2)} \right] < 1$ ，则称一致估计量 $\hat{\theta}_1$ 为**渐近有效估计**。

➤ 假设检验



原假设与备择假设：

- 原假设(用 H_0 表示)与备择假设(用 H_1 表示)是两个相反的假设。

统计检验：

- 对实验结果选择“拒绝原假设”或“不拒绝原假设”的判定准则称为统计检验。
- 该过程通常包括：先计算样本统计量 $T(x_1, x_2, \dots, x_n)$ ；接着推导零假设条件下 T 的抽样分布；最后，根据 T 的观察值推导出一个判定准则。建议拒绝零假设的 T 值的范围称为拒绝域，建议不拒绝零假设的范围称为接受域，或者不拒绝区域。

第一类错误与第二类错误

- 拒绝真假假设 H_0 所犯的误差称为**第一类错误**，又称**弃真错误**或 α 错误；不拒绝伪假设所犯的误差称为**第二类错误**，又称**存伪错误**或 β 错误。与这些误差相关联的是概率，称为第一类错误概率和第二类错误概率，用 $P(I)$ 和 $P(II)$ 表示。

显著水平和检验功效

- 在 H_0 为真的情况下，犯第一类错误的最大概率称为**显著水平**（或检验大小），最常见的显著水平0.01、0.05、0.10。当 H_0 为伪时，拒绝原假设的概率称为**检验功效**。
- 标准检验方法是找到 $P(II)$ 最小（或检验功效最大）的判定准则，约束条件为 $P(I) < \alpha$ ，其中 α 为给定的常量($0 < \alpha < 1$)。该检验方法称为最大功效检验。

➤ 正态分布均值检验

单侧检验

- 第1步：设定原假设 $H_0: \mu = \mu_0$ ，以及备择假设 $H_1: \mu > \mu_0$ ；
- 第2步：检验统计量为 $t_c = \sqrt{n}(\bar{x} - \mu_0)/s$ ，在原假设条件下，服从 $t(n-1)$ 分布。
- 第3步：在 t 值表中，查找对应自由度 $(n-1)$ 和给定显著水平 α 下 $t_{n-1}^*(\alpha)$ 时的对应值，所以 $P(t > t^*) = \alpha$ ，其中 α 为所选显著水平， t^* 为临界值。
- 第4步：如果统计量 $t_c > t^*$ ，则拒绝 H_0 。

如果备择假设为 $H_1: \mu < \mu_0$ ，则当 $t_c < -t^*$ 时拒绝原假设。

双侧检验

- 第1步：设定原假设 $H_0: \mu = \mu_0$ ，以及备择假设 $H_1: \mu \neq \mu_0$ ；
- 第2步：检验统计量为 $t_c = \sqrt{n}(\bar{x} - \mu_0)/s$ ，在原假设下服从 $t(n-1)$ 分布。
- 第3步：在 t 值表中，查自由度为 $(n-1)$ 、显著水平为 $\alpha/2$ 下 $t_{n-1}^*(\alpha/2)$ 的对应值，这里 α 为给定显著水平， t^* 为临界值。
- 第4步：如果 $t_c > t^*$ 或 $t_c < -t^*$ ，即如果 $|t_c| > t^*$ ，则拒绝原假设 H_0 。

两个变量间相关系数的检验

- 原假设 $H_0: \rho_{XY} = 0$ ；备择假设 $H_1: \rho_{XY} \neq 0$ 。如果拒绝原假设，则可以认为X和Y相关。
- 检验统计量为 $F_c = [(n-2)r^2]/(1-r^2)$ ，其中， r^2 为样本相关系数的平方。在原假设下该统计量服从 $F(1, (n-2))$ 。从 F 值表中找到 $F_{1,n-2}^*(\alpha)$ ，如果 $F_c > F^*$ ，则拒绝原假设 H_0 。

➤ 区间估计

- 以正态分布的均值为例，若随机变量 $X \sim N(\mu, \sigma^2)$ ，则样本均值 $\bar{x} \sim N(\mu, \sigma^2/n)$ 。由于 $t = \frac{\sqrt{n}(\bar{x} - \mu)}{s} \sim t(n-1)$ ，且 t 分布关于原点对称，因此可以得到 μ 的区间估计。以 $\alpha = 0.05$ 为例，可以得知 $P(-t^* \leq t \leq t^*) = 0.95$ 。把样本均值和标准偏差中的 t 代入，可得：


$$P\left(-t^* \leq \frac{\sqrt{n}(\bar{x} - \mu)}{s} \leq t^*\right) = 0.95$$

- 整理可得： $P\left(\bar{x} - \left(\frac{s}{\sqrt{n}}\right)t^* \leq \mu \leq \bar{x} + \left(\frac{s}{\sqrt{n}}\right)t^*\right) = 0.95$
- 这意味着参数真值 μ 位于 $\left(\bar{x} - \left(\frac{s}{\sqrt{n}}\right)t^*, \bar{x} + \left(\frac{s}{\sqrt{n}}\right)t^*\right)$ 区域中的可能性为95%，该区间为 μ 的95%置信区间。当显著性水平 α 越低时，置信水平 $(1 - \alpha)$ 越高， t^* 值越大，置信区间越宽。
- **置信区间** (confidence interval)的含义为：如果**大量重复**该实验，抽取样本并计算置信区间，则在估计出的置信区间中有95%将包括期望 μ 的真实值。

统计推断的基本思想

- 计量经济学的主要方法是数理统计的“统计推断” (statistical inference)。
- 称我们感兴趣的研究对象全体为“总体” (population), 其中的每个研究对象称为“个体” (individual)。
- 由于总体包含的个体可能很多, 普查成本较高, 故常从总体抽取部分个体, 称为“样本” (sample)。样本中包含个体的数目称为“样本容量” (sample size)。
- 通常希望样本为“随机样本” (random sample), 即总体中的每个个体都有相同的概率被抽中, 且被抽中的概率相互独立, 称为“独立同分布” (independently identically distributed, 简记i.i.d.)。

-
- 由于样本来自总体，必然带有总体的信息。而统计推断就是根据样本数据对总体性质进行推断的科学。
 - 统计推断的主要形式有参数估计(点估计、区间估计)、假设检验及预测等。



二、线性代数相关知识

➤ 矩阵基本定义

- 矩阵就是由 m 行 n 列实数组成的矩形数组。由 m 行与 n 列组成的矩阵称为 $m \times n$ 维矩阵。一个 $m \times n$ 矩阵可以写成如下形式：

$$A_{m \times n} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

其中, $a_{11}, a_{12}, \dots, a_{mn}$ 都称为矩阵 A 的元素, 位于第 i 行第 j 列的元素记为 a_{ij} , 也可以写成 A_{ij} (但后者较少使用, 因为可能与行列式混淆)。

- 所有元素都为0的矩阵称为零矩阵; **行数和列数相等的矩阵称为方阵。**
- 秩**是指矩阵中线性无关的行或者线性无关的列的数量, 对于矩阵 A , 一般记作 $\text{rank}(A)$ 。秩与其维度相等的矩阵称为**满秩矩阵**。
一个非零**方阵**, 其秩小于矩阵维度 (不满秩) 时, 称为**奇异矩阵**。

➤ 矩阵运算

- 参与运算的矩阵彼此之间具有运算一致性——即它们的维度必须能够允许这些矩阵之间进行运算。

矩阵相加

- 设A和B都是相同维度的矩阵，则 $A + B$ 就是将它们对应位置的元素相加即可。例如：

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad B = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$$

$$\text{则有: } A + B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} + \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} = \begin{bmatrix} 1+5 & 2+6 \\ 3+7 & 4+8 \end{bmatrix} = \begin{bmatrix} 6 & 8 \\ 10 & 12 \end{bmatrix}$$

矩阵相减

- 矩阵减法是加法的反向运算，如： $A - B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} - \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} = \begin{bmatrix} 1-5 & 2-6 \\ 3-7 & 4-8 \end{bmatrix} = \begin{bmatrix} -4 & -4 \\ -4 & -4 \end{bmatrix}$

矩阵相乘

- 两个矩阵要相乘，必须满足前一个矩阵的列数等于后一个矩阵的行数。即 $m \times n$ 维的矩阵A必须与 $n \times p$ 维的矩阵B才能相乘。两个矩阵相乘的基本运算规则是：前一个矩阵的第 i 行各个元素，乘以后一个矩阵的第 j 列对应元素后相加，其结果作为结果矩阵的第 i 行 j 列的元素。例如：

$$A_{3 \times 2} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix}, B_{2 \times 4} = \begin{bmatrix} b_{11} & b_{12} & b_{13} & b_{14} \\ b_{21} & b_{22} & b_{23} & b_{24} \end{bmatrix}$$

- 则有：

$$\begin{aligned} A_{3 \times 2} \times B_{2 \times 4} &= \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix} \times \begin{bmatrix} b_{11} & b_{12} & b_{13} & b_{14} \\ b_{21} & b_{22} & b_{23} & b_{24} \end{bmatrix} \\ &= \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} & a_{11}b_{13} + a_{12}b_{23} & a_{11}b_{14} + a_{12}b_{24} \\ a_{21}b_{11} + a_{22}b_{21} & a_{21}b_{12} + a_{22}b_{22} & a_{21}b_{13} + a_{22}b_{23} & a_{21}b_{14} + a_{22}b_{24} \\ a_{31}b_{11} + a_{32}b_{21} & a_{31}b_{12} + a_{32}b_{22} & a_{31}b_{13} + a_{32}b_{23} & a_{31}b_{14} + a_{32}b_{24} \end{bmatrix} \end{aligned}$$

-
-
- 注意，当一个实数乘以一个矩阵时，等于将原始矩阵的所有元素都乘以这个实数。例如：

$$5 \times A_{3 \times 2} = 5 \times \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix} = \begin{bmatrix} 5a_{11} & 5a_{12} \\ 5a_{21} & 5a_{22} \\ 5a_{31} & 5a_{32} \end{bmatrix}$$

- 因此，当某个矩阵各元素有公因子时，是可以提出到行列式之外的，比如：

$$N_{3 \times 2} = \begin{bmatrix} 5 & 10 \\ 5 & 15 \\ 5 & 25 \end{bmatrix} = 5 \times \begin{bmatrix} 1 & 2 \\ 1 & 3 \\ 1 & 5 \end{bmatrix}$$

矩阵“相除”

- 所谓两个矩阵“相除”，实质上是前一个矩阵乘以后一个矩阵的逆矩阵。

矩阵的克罗内克乘积

- 假定有 $m \times n$ 矩阵A和 $p \times q$ 矩阵B, A与B的克罗内克乘积为 $mp \times nq$ 矩阵, 即:

$$A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \cdots & a_{1n}B \\ a_{21}B & a_{22}B & \cdots & a_{2n}B \\ \vdots & \vdots & \vdots & \vdots \\ a_{m1}B & a_{m2}B & \cdots & a_{mn}B \end{bmatrix}$$

- 其中, a_{ij} 表示矩阵A中第*i*行第*j*列的元素。

矩阵的转置

- 矩阵的转置，即将原矩阵的行列互换。矩阵A的转置一般可以表示成 A' 或者 A^T 。例如：

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix}$$

- 则：

$$A' = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{12} & a_{22} & a_{32} \end{bmatrix}$$

- 因此，一个 $m \times n$ 维的矩阵，其转置矩阵则为 $n \times m$ 维矩阵。
- 对于矩阵A和B，有下列转置矩阵运算定律： $(AB)' = B'A'$ 。

矩阵求逆

- 记矩阵A的逆阵为 A^{-1} ，则 $A^{-1}A = I$ 。其中， I 表示单位矩阵。

- **只有非奇异方阵，即满秩方阵，才存在逆矩阵。**

- 以 2×2 维的矩阵求逆为例，如果： $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$ ，

- 则其逆矩阵为：
$$A^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix}$$

- 可以利用现代计量软件和数学计算工具计算出一个方阵的逆矩阵。

- 另外，如果矩阵A和B均可逆，则有如下性质：
$$\begin{cases} (AB)^{-1} = B^{-1}A^{-1} \\ (A')^{-1} = (A^{-1})' \\ [(AB)']^{-1} = [B'A']^{-1} = (A')^{-1}(B')^{-1} \end{cases}$$

➤ 特殊矩阵及性质

单位矩阵

- 主对角线所有元素都为1，而非主对角线上的元素都为0的矩阵，称为单位矩阵。例如， $I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 是一个 2×2 的单位矩阵。
- 任何矩阵乘以与其维度一致的单位矩阵，仍然是这个矩阵本身，例如：

$$B \times I = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = B$$

- 单位矩阵的逆阵和转置等于原单位矩阵，即 $I^{-1} = I' = I$ 。
- 特别地，形如 αI 的矩阵称为标量矩阵，其中 α 是标量。

对称矩阵

- 矩阵的转置仍然是其本身的矩阵，称为对称矩阵，即如果 $A' = A$ ，那么 A 称为对称矩阵。
- 显然，单位矩阵就是一个典型的对称矩阵。

三角矩阵

- 主对角线以下所有元素均为0，则该矩阵称为上三角矩阵；反之，主对角线以上所有元素均为0的矩阵称为下三角矩阵。
- 例如，下面的矩阵A为下三角矩阵，而B则为上三角矩阵。

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 5 & 0 \\ 4 & 7 & 3 \end{bmatrix} \quad B = \begin{bmatrix} 1 & 1 & 7 \\ 0 & 5 & 9 \\ 0 & 0 & 3 \end{bmatrix}$$

对角矩阵

- 除主对角线之外的所有元素均为0的矩阵称为对角矩阵。如： $A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 3 \end{bmatrix}$

幂等矩阵

- 如果矩阵A满足 $AA = A$ ，则该矩阵称为幂等矩阵。
- 单位矩阵就是一个幂等矩阵。
- 幂等矩阵的**特征根**只可能为0或1。【特征根和特征向量的定义见下页】

➤ 矩阵的特征根

- 设 A 是一个 $n \times n$ 的方阵，假定存在一个 $n \times 1$ 的非零向量 C 和实数 λ ，使得 $AC = \lambda C$ 成立，则向量 C 称为矩阵 A 的特征向量， λ 称为矩阵 A 的特征根。
- 此时矩阵 $A - \lambda I$ 应该为奇异矩阵，该矩阵的行列式应该为0，即 $|A - \lambda I| = 0$ 。
- 一个矩阵主对角线上元素的代数和，称为**矩阵的迹 (trace)**，它等于该矩阵特征根的算术和。

➤ 正定矩阵

- 根据矩阵的特征根，可以判断该矩阵是否为**正定矩阵**。

对于所有非零向量 X ，如果对称矩阵 A 满足 $X'AX$ 都为正数，则矩阵 A 称为**正定矩阵**。如果一个对称矩阵的所有特征根均为正数，则该矩阵为正定矩阵。如果一个对称矩阵的所有特征根均为负数，则称该矩阵为**负定矩阵**。

- 单位矩阵是正定的。
- 如果 A 是正定的，则 A^{-1} 也是正定的。
- 如果 A 是正定的， B 是可逆矩阵，则 $B'AB$ 也是正定的。

➤矩阵求导

- 矩阵求导的方法是以矩阵形式表达最小二乘法（OLS）估计过程的基础。
- 基本法则（推荐阅读1：[基础篇](#)；推荐阅读2：[进阶篇](#)）

(1) 常数矩阵的矩阵微分： $d\mathbf{A}_{m \times n} = \mathbf{0}_{m \times n}$

(2) 线性法则： $d(c_1\mathbf{F}(\mathbf{X}) + c_2\mathbf{G}(\mathbf{X})) = c_1d\mathbf{F}(\mathbf{X}) + c_2d\mathbf{G}(\mathbf{X})$

其中， c_1, c_2 为常数——口诀：“相加再微分等于微分再相加，常数提外面。”

(3) 乘积法则： $d(\mathbf{F}(\mathbf{X})\mathbf{G}(\mathbf{X})) = d(\mathbf{F}(\mathbf{X}))\mathbf{G}(\mathbf{X}) + \mathbf{F}(\mathbf{X})d\mathbf{G}(\mathbf{X})$

其中， $\mathbf{F}_{p \times q}(\mathbf{X}), \mathbf{G}_{q \times s}(\mathbf{X})$ ——注意：这里的微分是矩阵运算，不能交换乘积的左右顺序。

(4) 转置法则： $d\mathbf{F}_{p \times q}^T(\mathbf{X}) = (d\mathbf{F}_{p \times q}(\mathbf{X}))^T$

转置的矩阵微分等于矩阵微分的转置。

此外， $\frac{d\mathbf{X}'}{d\mathbf{X}} = \frac{d\mathbf{X}}{d\mathbf{X}'} = \mathbf{I}$ ，其中 $\mathbf{I}$ 为单位矩阵。但要注意： $\frac{d\mathbf{a}^T(\mathbf{X})}{d\mathbf{X}} \neq \frac{d\mathbf{a}(\mathbf{X})}{d\mathbf{X}^T}$ $\frac{d\mathbf{a}^T(\mathbf{X})}{d\mathbf{X}} = \left[\frac{d\mathbf{a}(\mathbf{X})}{d\mathbf{X}^T} \right]^T$

-
- 假设 X 和 C 均为 $n \times 1$ 的矩阵,
定义一个函数: $f = C'X$, 其中:
$$X = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad C = \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix}$$
 - 则: $f = C'X = \begin{pmatrix} c_1 & c_2 & \cdots & c_n \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \sum_{i=1}^n c_i x_i$
 - 如果将 f 对 X 中的每一元素进行求导, 可得:
$$\frac{\partial f}{\partial X} = \frac{\partial C'X}{\partial X} = C$$
 - 类似地, 如果 $A = C'$, 对于 $g = AX$, 推导可得:
$$\frac{\partial g}{\partial X} = \frac{\partial AX}{\partial X} = A'$$
 - 更一般地, 矩阵 C' 可以替换成 $A_{m \times n}$ 。具体计算过程, 可以参考[这里](#)。

- 可以证明：
$$\frac{d[\mathbf{a}^T(\mathbf{X}) \cdot \mathbf{b}(\mathbf{X})]}{d\mathbf{X}} = \frac{d\mathbf{a}^T(\mathbf{X})}{d\mathbf{X}} \cdot \mathbf{b}(\mathbf{X}) + \frac{d\mathbf{b}^T(\mathbf{X})}{d\mathbf{X}} \cdot \mathbf{a}(\mathbf{X})$$

- 其中， $\mathbf{X}$ 为 $n \times 1$ 矩阵（列向量）， $\mathbf{a}(\cdot)$ 和 $\mathbf{b}(\cdot)$ 均为列向量函数。

【注：证明过程不作要求，需要用到 $\mathbf{a}^T \mathbf{y} = \mathbf{y}^T \mathbf{a}$ 这一矩阵乘积的性质。】

- 对于任意实数方阵 A ，求二次型 $f = \mathbf{X}' A \mathbf{X}$ 对 $\mathbf{X}$ 的导数，可得：

$$\frac{df}{d\mathbf{X}} = \frac{d\mathbf{X}' A \mathbf{X}}{d\mathbf{X}} = \frac{d\mathbf{X}'}{d\mathbf{X}} (A \mathbf{X}) + \frac{d(A \mathbf{X})'}{d\mathbf{X}} \mathbf{X} = A \mathbf{X} + \frac{d\mathbf{X}' A'}{d\mathbf{X}} \mathbf{X} = (A + A') \mathbf{X}$$

- 如果 A 是一个对称方阵，则上式可以写成：

$$\frac{df}{d\mathbf{X}} = \frac{d\mathbf{X}' A \mathbf{X}}{d\mathbf{X}} = (A + A') \mathbf{X} = 2A \mathbf{X}$$

- 矩阵求导的其他相关资料，可以参考[这里](#)。



经济与工商管理学院
BNU Business School



问题与讨论

电子邮箱: licheng.xu@bnu.edu.cn

办公室: 后主楼1730A