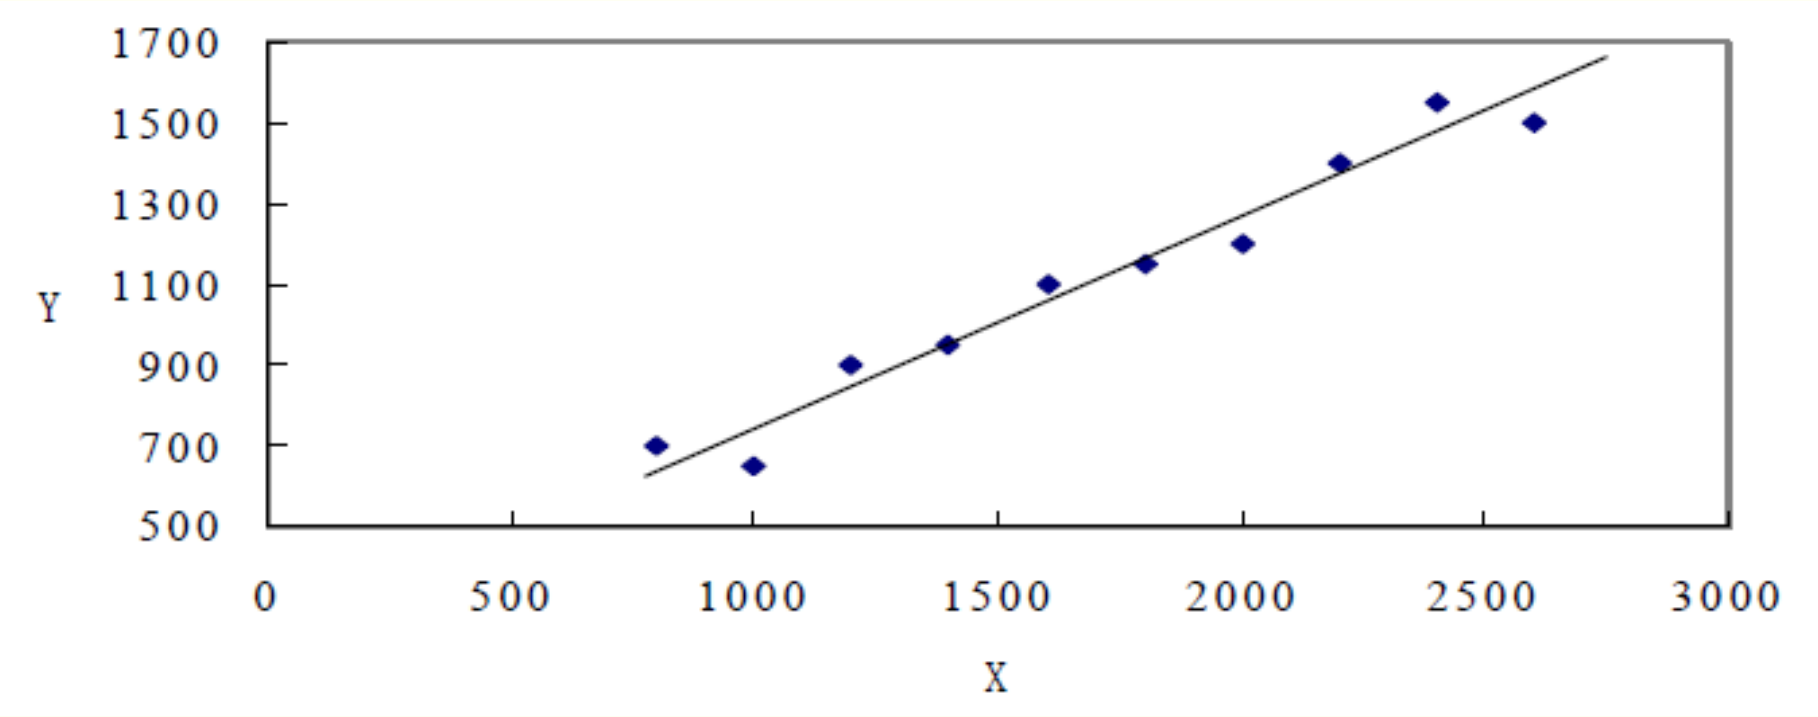
高级计量经济学

(2026/27学年度 秋季学期)

第三讲：小样本OLS

引言（1）：什么时候使用线性回归模型？



- 例如：X=收入，Y=消费。样本观测值：*N*=10。

引言（2）：最小一乘 vs. 最小二乘 vs. 最小多乘

- 在进行线性回归时，有一个自然的想法：**为什么不使用这样的直线，使得每个点到直线的距离之和最小？**
- 这个距离（点与直线的垂直距离）叫做**最小绝对离差**（least absolute deviation），也有人称之为“最小一乘法”：

$$S = \sum_{i=1}^{n} |y_i - f(x_i)|.$$

- 此外，既然有最小二乘法（离差的指数为2），**为什么不能使用最小多乘法（离差的指数为更大的偶数，例如：4、6、8，…）？**
- 和最小绝对离差（“最小一乘法”）相比，我们更偏好使用最小二乘法，一来是计算更加便利（不用讨论取值去掉绝对值），二来则是能保证求到的解具有唯一性。
- 和最小多乘法相比，我们同样更偏好使用最小二乘法，因为可以避免对偏差过大的观测值赋过高权重，影响估计结果。

本讲主要内容

- 古典线性回归模型的假定
- **OLS** 的代数推导
- **OLS** 的几何解释
- 拟合优度
- **OLS** 的小样本性质
- 对单个系数的t 检验
- 对线性假设的F 检验
- F 统计量的似然比原理表达式
- 利用计量模型进行预测

3.1 古典线性回归模型的假定

- “最小二乘法”(Ordinary Least Square，OLS)是单一方程线性回归模型的基本估计方法。
- “古典线性回归模型”(Classical Linear Regression Model)包含如下四个基本假定：

1. **线性假定** (linearity)
2. **严格外生性** (strict exogeneity)
3. **不存在“严格多重共线性”** (strict multicolinearity)
4. **球型扰动项 (spherical disturbance)**，即扰动项满足“同方差”、“无自相关”的性质

假定3.1：线性假定 (linearity)

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_K x_{iK} + \varepsilon_i \quad (i = 1, \cdots, n)$$

- 其中，n为样本容量，解释变量x_{ik}的第一个下标表示第i个观测值，第二个下标则表示第k个解释变量 $(k = 1,2, \ldots, K)$。
- 如有常数项，令第一个解释变量为单位向量，即$x_{i1} = 1, \forall i$。
- $\beta_1, \beta_2, \ldots \beta_K$为待估参数，称为“回归系数” (regression coefficients)。
- 线性假设的含义是x_{ik}对y_i的边际效应为常数，比如$\frac{\partial E(y)}{\partial x_{i1}} = \beta_1$。
- 如果边际效应可变，可加入平方项(x_{ik}^2)或交互项$(x_{ik} \cdot x_{im})$。比如，教育投资回报可能会随着受教育程度提高而递减。
- 加入交互项$(x_{ik} \cdot x_{im})$后，边际效应$\frac{\partial E(y)}{\partial x_{ik}}$会如何变化？
- 只要把高次项也作为解释变量来看待，则依然满足线性假定。

- 总体模型也称“数据生成过程”(Data Generating Process，DGP)。
- 为了更简洁地表达，以下引入矩阵符号。记第i个观测数据为$\boldsymbol{x}_i \equiv (x_{i1}\ x_{i2}\ \dots\ x_{iK})'$，待估参数$\boldsymbol{\beta} \equiv (\beta_1, \beta_2, \dots \beta_K)'$，则原模型可改写为：

$$y_i = \boldsymbol{x}_i' \boldsymbol{\beta} + \varepsilon_i \quad (i = 1, \cdots, n)$$

- 把所有个体方程叠放，可得：

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1' \\ \boldsymbol{x}_2' \\ \vdots \\ \boldsymbol{x}_n' \end{pmatrix} \boldsymbol{\beta} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

- 定义$\boldsymbol{y} \equiv (y_1\ y_2\ \dots y_n)'$，数据矩阵$\boldsymbol{X} \equiv (\boldsymbol{x_1}\ \boldsymbol{x_2}\ \dots \boldsymbol{x_n})'$，$\boldsymbol{\epsilon} \equiv (\epsilon_1\ \epsilon_2\ \dots \epsilon_n)'$，则：

$$\boldsymbol{y} = \boldsymbol{X\beta} + \boldsymbol{\epsilon}$$

假定3.2：严格外生性 (strict exogeneity)

$$\mathrm{E}(\varepsilon_i \mid \boldsymbol{X}) = \mathrm{E}(\varepsilon_i \mid \boldsymbol{x}_1, \cdots, \boldsymbol{x}_n) = 0 \quad (i = 1, \cdots, n)$$

- ϵ_i均值独立于**所有解释变量**的观测数据，而不仅仅是同一解释变量$\boldsymbol{x_i}$中的观测数据。
- ϵ_i与所有解释变量均不相关，即$Cov(\epsilon_i, x_{jk}) = 0, \forall j, k$。此假定很强，会在后续关于大样本OLS的讨论时放松。
- 均值独立仅要求$E(\epsilon_i \mid X) = c$，c为某常数，不一定为0。
- 当回归方程有常数项时，如果$E(\epsilon_i \mid X) = c \neq 0$，总可以把$c$归入常数项以满足$E(\epsilon_i \mid X) = 0$的要求，此时新的扰动项可视为$\epsilon_i - c$ 。

- **命题：** $E(\epsilon) = 0$，即扰动项的无条件期望为0。
- **证明：** 根据迭代期望定律，$$\mathrm{E}(\varepsilon_i) = \mathrm{E}_{\boldsymbol{X}} \underbrace{\mathrm{E}(\varepsilon_i \mid \boldsymbol{X})}_{=0} = \mathrm{E}_{\boldsymbol{X}}(0) = 0$$。

- **定义：** 如果随机变量 X, Y 满足$E(XY) = 0$，则称 X, Y 正交(orthogonal)。
- **命题：** 解释变量与扰动项正交。
- **证明：** $$0 = \mathrm{Cov}(x_{jk}, \varepsilon_i) = \mathrm{E}(x_{jk}\varepsilon_i) - \mathrm{E}(x_{jk}) \underbrace{\mathrm{E}(\varepsilon_i)}_{=0} = \mathrm{E}(x_{jk}\varepsilon_i)$$。

假定3.3：不存在“严格多重共线性” (strict multicolinearity)，即数据矩阵$\boldsymbol{X}$满列秩，或$rank(\boldsymbol{X}) = K$，其中“$rank$”表示矩阵的秩。

- 如果不满足此条件，则β“不可识别”(unidentified)，因为$\boldsymbol{X}$中的某个或多个变量为多余。
- 根据OLS估计，可得：$\boldsymbol{b} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}$。（推导过程见3.2小节，p.12）
- 如$\boldsymbol{X}$满列秩，$\boldsymbol{X}'\boldsymbol{X}$正定，故$(\boldsymbol{X}'\boldsymbol{X})^{-1}$存在；反之，$(\boldsymbol{X}'\boldsymbol{X})^{-1}$不存在。
- 实际数据不易出现严格多重共线性。
- 如果出现，在应用计量的实际操作中，Stata 也会自动识别。

假定3.4：球型扰动项 (spherical disturbance)，即扰动项满足“同方差”、“无自相关”的性质，数学表达为：

$$\mathrm{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) = \mathrm{E}(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}' \mid \boldsymbol{X}) = \sigma^2 \boldsymbol{I}_n = \begin{pmatrix} \sigma^2 & & 0 \\ & \ddots & \\ 0 & & \sigma^2 \end{pmatrix}$$

- 其中，$\boldsymbol{I_n}$为n阶单位矩阵。
- 协方差矩阵$Var(\epsilon|\,\boldsymbol{X})$的主对角线元素都等于$\sigma^2$，即满足“条件同方差”(conditional homoskedasticity)；反之，则存在“条件异方差”(conditional heteroskedasticity)。
- 协方差矩阵$Var(\epsilon|\,\boldsymbol{X})$的非主对角线元素都为0，不同个体的扰动项之间无“自相关”(autocorrelation)；反之，则存在自相关。

3.2 OLS 的代数推导

- 对于$\boldsymbol{\beta}$的任意假想值$\widetilde{\boldsymbol{\beta}}$，记个体$i$的拟合误差(即残差，residual)为$e_i = y_i - \boldsymbol{x_i}'\widetilde{\boldsymbol{\beta}}$。
- 将所有个体的残差叠放，可得残差向量$\boldsymbol{e} \equiv (e_1\ e_2\ \ldots e_n)' = \boldsymbol{y} - \boldsymbol{X}\widetilde{\boldsymbol{\beta}}$。
- **最小二乘法**寻找能使残差平方和(Sum of Squared Residuals，$SSR = \sum_{i=1}^{n} e_i^2$)最小的$\widetilde{\boldsymbol{\beta}}$。
- 几何上，一元回归就是寻找最佳拟合的回归直线；
- 二元回归就是寻找最佳拟合的回归平面；
- 多元回归，则寻找最佳拟合的回归超平面 (hyperplane)。

向量微分的规则：

记$\boldsymbol{a}=(a_1\ a_2\ \cdots\ a_K)'$，则$\boldsymbol{a}'\tilde{\boldsymbol{\beta}}=\sum_{i=1}^{K}a_i\tilde{\beta}_i$。

$$\frac{\partial(\boldsymbol{a}'\tilde{\boldsymbol{\beta}})}{\partial\tilde{\boldsymbol{\beta}}}\equiv\left(\frac{\partial(\boldsymbol{a}'\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_1}\ \frac{\partial(\boldsymbol{a}'\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_2}\ \cdots\ \frac{\partial(\boldsymbol{a}'\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_K}\right)'=(a_1\ a_2\ \cdots\ a_K)'=\boldsymbol{a}$$

类似于对一次函数求导。假设$\boldsymbol{A}$为K阶对称矩阵，可证：

$$\frac{\partial(\tilde{\boldsymbol{\beta}}'\boldsymbol{A}\tilde{\boldsymbol{\beta}})}{\partial\tilde{\boldsymbol{\beta}}}\equiv\left(\frac{\partial(\tilde{\boldsymbol{\beta}}'\boldsymbol{A}\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_1}\ \frac{\partial(\tilde{\boldsymbol{\beta}}'\boldsymbol{A}\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_2}\ \cdots\ \frac{\partial(\tilde{\boldsymbol{\beta}}'\boldsymbol{A}\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_K}\right)'=2\boldsymbol{A}\tilde{\boldsymbol{\beta}}$$

类似于对二次函数求导。

- 最小化问题：

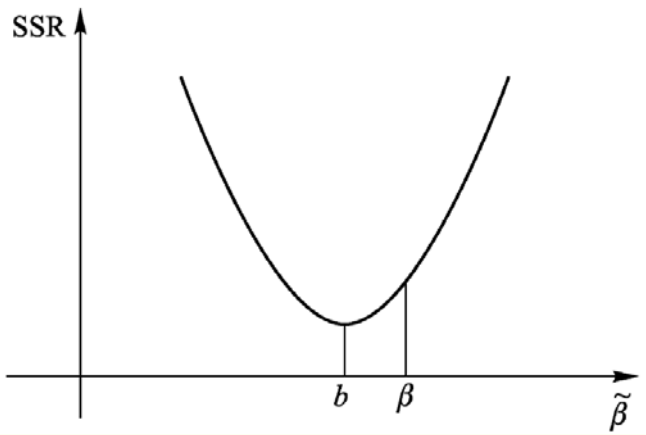
$$\min_{\tilde{\beta}} \ \mathrm{SSR}(\tilde{\beta}) = \sum_{i=1}^{n} e_i^2 = e'e \qquad \text{(平方和写成向量内积)}$$

$$= (y - X\tilde{\beta})'(y - X\tilde{\beta}) \qquad \text{(残差向量的表达式)}$$

$$= (y' - \tilde{\beta}'X')(y - X\tilde{\beta}) \qquad \text{(矩阵转置性质)}$$

$$= y'y - y'X\tilde{\beta} - \tilde{\beta}'X'y + \tilde{\beta}'X'X\tilde{\beta} \qquad \text{(乘积展开)}$$

$$= y'y - 2y'X\tilde{\beta} + \tilde{\beta}'X'X\tilde{\beta} \qquad \text{(合并同类项)}$$



- 思考：最后一步，$y'X\tilde{\beta}$和$\tilde{\beta}'X'y$为何能合并？
- 目标函数$SSR(\tilde{\beta})$是$\tilde{\beta}$的二次函数(二次型)，存在最小值，与之相对应的估计量记为b。

- 使用向量微分规则，可得最小化的一阶条件：

$$\frac{\partial(\mathrm{SSR})}{\partial\tilde{\boldsymbol{\beta}}} = -2\boldsymbol{X}'\boldsymbol{y} + 2\boldsymbol{X}'\boldsymbol{X}\tilde{\boldsymbol{\beta}} = 0$$

- 最小二乘估计量$\boldsymbol{b}$满足：

$$(\boldsymbol{X}'\boldsymbol{X})_{K\times K}\boldsymbol{b}_{K\times 1} = \boldsymbol{X}'_{K\times n}\boldsymbol{y}_{n\times 1} \quad \text{(正规方程组，}K\text{ 个方程，}K\text{ 个未知数)}$$

$$\boldsymbol{X}'\boldsymbol{y} - (\boldsymbol{X}'\boldsymbol{X})\boldsymbol{b} = \boldsymbol{0} \quad \text{(移项)}$$

$$\boldsymbol{X}'\underbrace{(\boldsymbol{y} - \boldsymbol{X}\boldsymbol{b})}_{=\boldsymbol{e}} = \boldsymbol{0} \quad \text{(向左提取共同的矩阵因子}\boldsymbol{X}'\text{)}$$

- 因此，$\boldsymbol{X}'\boldsymbol{e} = \boldsymbol{0}$，其中残差向量$\boldsymbol{e} \equiv \boldsymbol{y} - \boldsymbol{X}\boldsymbol{b}$。

- 残差向量$\boldsymbol{e}$与解释变量$\boldsymbol{X}$正交，是OLS的一大特征。
- 求解可得 OLS 估计量： $\boldsymbol{b}=(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}$。
- 二阶条件要求黑赛矩阵(Hessian)为正定矩阵。黑赛矩阵的表达式：

$$\frac{\partial^2(\mathrm{SSR})}{\partial\tilde{\boldsymbol{\beta}}\partial\tilde{\boldsymbol{\beta}}'}\equiv\frac{\partial\left(\frac{\partial\mathrm{SSR}}{\partial\tilde{\boldsymbol{\beta}}}\right)}{\partial\tilde{\boldsymbol{\beta}}'}\equiv\begin{pmatrix}\frac{\partial^2\mathrm{SSR}}{\partial^2\tilde{\beta}_1} & \cdots & \frac{\partial^2\mathrm{SSR}}{\partial\tilde{\beta}_1\partial\tilde{\beta}_K}\\ \cdots & \cdots & \cdots\\ \frac{\partial^2\mathrm{SSR}}{\partial\tilde{\beta}_K\partial\tilde{\beta}_1} & \cdots & \frac{\partial^2\mathrm{SSR}}{\partial^2\tilde{\beta}_K}\end{pmatrix}=2\boldsymbol{X}'\boldsymbol{X}$$

- 因为$\boldsymbol{X}$满列秩，故$\boldsymbol{X}'\boldsymbol{X}$正定。

- 被解释变量的“拟合值”(fitted values)或“预测值”(predicted values)：

$$\hat{\boldsymbol{y}} \equiv (\hat{y}_1\ \hat{y}_2\ \ldots \hat{y}_n)' \equiv \boldsymbol{Xb}$$

- 可把被解释变量$\boldsymbol{y}$分解为两个正交的部分，即$\boldsymbol{y} = \hat{\boldsymbol{y}} + \boldsymbol{e}$，而$\hat{\boldsymbol{y}}$与$\boldsymbol{e}$正交，因为

$$\hat{\boldsymbol{y}}'\boldsymbol{e} = (\boldsymbol{Xb})'\boldsymbol{e} = \boldsymbol{b}'\boldsymbol{X}'\boldsymbol{e} = \boldsymbol{b}' \cdot \boldsymbol{0} = \boldsymbol{0}$$

- 对于扰动项方差$\sigma^2 = Var(\epsilon_i)$的估计：

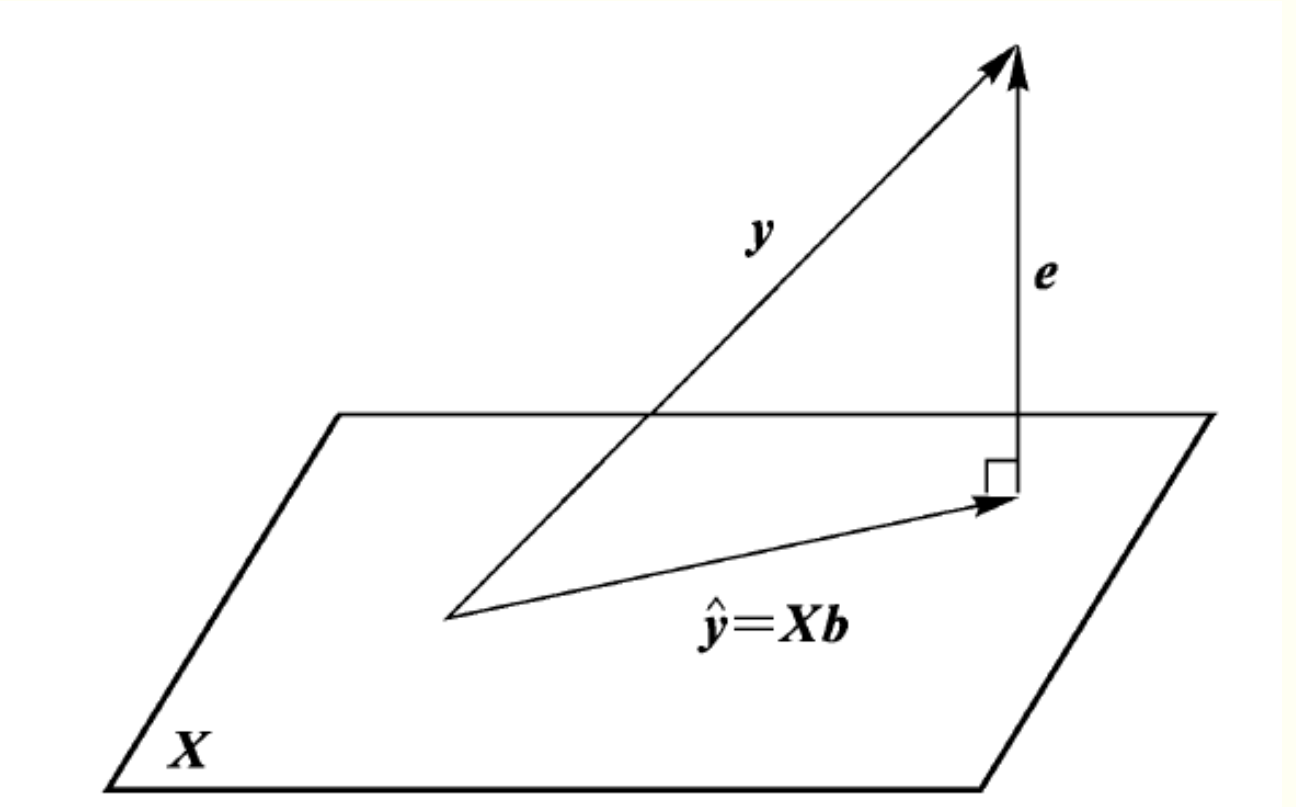
$$s^2 \equiv \frac{1}{n-K}\sum_{i=1}^{n} e_i^2$$

- 其中，$(n-K)$为自由度。为什么除以$(n-K)$而不除以n？

- 随机变量$\{e_1\ e_2\ ,\ldots,e_n\}$必须满足$K$个正规方程$\boldsymbol{X'e}\ =\mathbf{0}$，因此只有其中$(n-K)$个$e_i$是相互独立（自由）的。
- 经过校正后，才是无偏估计，$E(s^2)\ =\sigma^2$。
- 如果样本容量n很大$(n\to\infty)$，则$(n-K)/n\to 1$，是否进行“小样本校正”并没有多少差别。
- 称$s=\sqrt{s^2}$为“回归方程的标准误差” (standard error of the regression)，简称“回归方程的标准误”。
- 更一般地，称某统计量的标准差为该统计量的“标准误”(standard error)。

3.3 OLS 的几何解释

- $\hat{\boldsymbol{y}}$是$\boldsymbol{y}$向超平面$\boldsymbol{X}$的投影(projection)，因为$\boldsymbol{e}$与$\boldsymbol{X}$正交。



由于 $\hat{\boldsymbol{y}} \equiv \boldsymbol{X}\boldsymbol{b} = \boldsymbol{X}\underbrace{(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}}_{=\boldsymbol{b}} \equiv \boldsymbol{P}\boldsymbol{y}$，故 $\boldsymbol{P} \equiv \boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'$ 称为“投影矩阵”(projection matrix)。

用 $\boldsymbol{P}$ 左乘任何向量，就得到该向量在超平面 $\boldsymbol{X}$ 上的投影。

由于 $\boldsymbol{e} = \boldsymbol{y} - \hat{\boldsymbol{y}} = \boldsymbol{y} - \boldsymbol{P}\boldsymbol{y} = (\boldsymbol{I}_n - \boldsymbol{P})\boldsymbol{y} \equiv \boldsymbol{M}\boldsymbol{y}$，故 $\boldsymbol{M} \equiv \boldsymbol{I}_n - \boldsymbol{P}$ 称为“消灭矩阵”(annihilator matrix)。

用消灭矩阵 $\boldsymbol{M}$ 左乘任何向量，就得到该向量对超平面 $\boldsymbol{X}$ 投影后的残差向量。

矩阵 $\boldsymbol{P}$ 与 $\boldsymbol{M}$ 的性质(参见习题)：

(i) $\boldsymbol{PX} = \boldsymbol{X}$；　　(自己的投影还是自己)

(ii) $\boldsymbol{Pe} = \boldsymbol{0}$；　　(垂直于 $\boldsymbol{X}$ 的向量 $\boldsymbol{e}$ 投影于 $\boldsymbol{X}$ 则退化为一个点)

(iii) $\boldsymbol{MX} = \boldsymbol{0}$；　　(自己对自己投影，其残差为 $\boldsymbol{0}$)

(iv) $\boldsymbol{P}$ 与 $\boldsymbol{M}$ 都是对称阵；

(v) $\boldsymbol{P}^2 = \boldsymbol{P}$；　　(再次投影的效果等于一次投影)

(vi) $\boldsymbol{M}^2 = \boldsymbol{M}$。　　(再次消灭的效果等于一次消灭)

- 残差、残差平方和与扰动项的关系

把残差写成ε的函数：

$$e = My = M(X\beta + \varepsilon) = \underbrace{MX}_{=0}\beta + M\varepsilon = M\varepsilon$$

把残差平方和写为ε的函数：

$$\mathrm{SSR} = e'e = (M\varepsilon)'M\varepsilon = \varepsilon'M'M\varepsilon = \varepsilon'M^2\varepsilon = \varepsilon'M\varepsilon$$

3.4 拟合优度

- 如果回归方程有常数项，则$\sum_{i=1}^{n}(y_i-\bar{y})^2$可分解为：

$$\sum_{i=1}^{n}(y_i-\bar{y})^2=\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2+\sum_{i=1}^{n}e_i^2$$

- 其中，$\bar{y}\equiv\frac{1}{n}\sum_{i=1}^{n}y_i$表示样本均值，$e_i\equiv\hat{y}_i-y_i$为残差。
- 被解释变量y_i的离差平方和可分为两部分，即可由模型解释的部分$\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2$，以及模型无法解释的残差部分$\sum_{i=1}^{n}e_i^2$。
- 平方和分解公式能成立正是由于OLS的正交性。

定义 拟合优度(goodness of fit) R^2的表达式：

$$0\le R^2\equiv\frac{\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2}{\sum_{i=1}^{n}(y_i-\bar{y})^2}=1-\frac{\sum_{i=1}^{n}e_i^2}{\sum_{i=1}^{n}(y_i-\bar{y})^2}\le 1$$

- 拟合优度R^2也称“**可决系数**”(coefficient of determination)。
- 可以证明(参见习题)，在有常数项的情况下，拟合优度等于被解释变量y_i与拟合值$\hat{y}_i$之间相关系数的平方，即$R^2 = [Corr(y_i, \hat{y}_i)]^2$。
- R^2越高，拟合程度越好。
- 当然，实证研究中，也不宜过度追求更高的R^2。
- 拟合优度这一测度的缺点：如果增加解释变量，R^2只增不减，因为至少可让新增解释变量的系数为0而保持R^2不变。
- 通过调整自由度，对解释变量过多(模型不够简洁)进行惩罚。由此我们可以定义**校正拟合优度**，也称为“调整R^2”。

定义　校正拟合优度（adjusted R^2）$\overline{R}^2$ 为

$$\overline{R}^2 = 1 - \frac{\sum_{i=1}^{n} e_i^2 \Big/ (n-K)}{\sum_{i=1}^{n} (y_i - \bar{y})^2 \Big/ (n-1)}$$

缺点：$\overline{R}^2$ 可能为负。

无论 R^2 还是 $\overline{R}^2$，只反映拟合程度好坏，除此无太多意义。

评估回归方程是否显著，应使用 F 检验（R^2 与 F 统计量有联系）。

如果回归模型无常数项，则平方和分解公式不成立。仍可将 $\sum_{i=1}^{n} y_i^2$ 分解为：

$$\sum_{i=1}^{n} y_i^2 = \boldsymbol{y}'\boldsymbol{y} = (\hat{\boldsymbol{y}} + \boldsymbol{e})'(\hat{\boldsymbol{y}} + \boldsymbol{e}) = \hat{\boldsymbol{y}}'\hat{\boldsymbol{y}} + 2\underbrace{\hat{\boldsymbol{y}}'\boldsymbol{e}}_{=0} + \boldsymbol{e}'\boldsymbol{e} = \sum_{i=1}^{n} \hat{y}_i^2 + \sum_{i=1}^{n} e_i^2$$

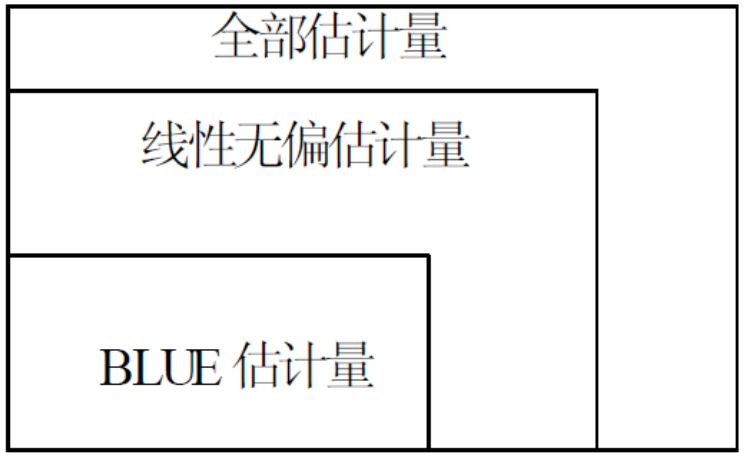
定义“非中心 R^2”（Uncentered R^2）：

$$R_{uc}^2 \equiv \frac{\hat{\boldsymbol{y}}'\hat{\boldsymbol{y}}}{\boldsymbol{y}'\boldsymbol{y}} = 1 - \frac{\boldsymbol{e}'\boldsymbol{e}}{\boldsymbol{y}'\boldsymbol{y}}$$

如果无常数项，则 Stata 汇报 R_{uc}^2。

3.5 OLS 的小样本性质

- (1) 线性性：OLS 估计量$\boldsymbol{b} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}$为$\boldsymbol{y}$的线性组合。
- (2) 无偏性：$E(\boldsymbol{b}|\boldsymbol{X}) = \boldsymbol{\beta}$，即$\boldsymbol{b}$不会系统地高估或低估$\boldsymbol{\beta}$。
- (3) 估计量$\boldsymbol{b}$的方差为$Var(\boldsymbol{b}|\boldsymbol{X}) = \sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1}$。
  - 球型扰动项假定是证明的关键。
  - 如存在条件异方差，则方差表达式不同，应使用“稳健标准误”(robust standard error)，具体参见第5讲。
- (4) “高斯-马尔可夫定理”(Gauss-Markov Theorem)：最小二乘法是**最佳线性无偏估计**(Best Linear Unbiased Estimator，简记BLUE)，即在所有线性无偏估计中，最小二乘法的**方差最小**。
- (5)方差的无偏估计：$E(s^2|\boldsymbol{X}) = \sigma^2$。



3.6 对单个系数的t 检验

假定3.5：在给定$\boldsymbol{X}$的情况下，$\boldsymbol{\epsilon}|\boldsymbol{X}$的条件分布为正态，即$\boldsymbol{\epsilon}|\boldsymbol{X}\sim\boldsymbol{N}\left(\boldsymbol{0},\boldsymbol{\sigma}^{\boldsymbol{2}}\boldsymbol{I}_{\boldsymbol{n}}\right)$。

- 考虑对单个系数进行检验，“原假设”(null hypothesis，零假设)为H_0: $\beta_k = \bar{\beta}_k$，其中 $\bar{\beta}_k$为给定常数。
- 通常 $\bar{\beta}_k = 0$，检验变量x_{ik}的系数是否**显著地**不等于0。
- 假设检验是概率意义上的反证法，即首先假定原假设成立，然后看在原假设成立的前提下，是否导致不太可能发生的“小概率事件”在一次抽样的样本中出现。
- 如果小概率事件竟在一次抽样中被观测到，则说明原假设不可信，应该拒绝原假设，接受“替代假设”(alternative hypothesis，备择假设) H_1: $\beta_k \neq \bar{\beta}_k$。

- 如果未知参数β_k的估计值b_k离$\bar{\beta}_k$较远，则倾向于拒绝原假设。这类检验称为“**沃尔德检验**”(Wald test)。
- 在衡量距离远近时，**绝对距离依赖变量单位，需以标准差为基准来考虑相对距离。**
- 由于$\boldsymbol{\epsilon}|\boldsymbol{X}\sim\boldsymbol{N}\left(\boldsymbol{0},\boldsymbol{\sigma^2 I_n}\right)$，而$\boldsymbol{b}-\boldsymbol{\beta}=\boldsymbol{A\epsilon}$为$\boldsymbol{\epsilon}$的线性函数，$\boldsymbol{A}\equiv(\boldsymbol{X'X})^{-1}\boldsymbol{X'}$，故$(\boldsymbol{b}-\boldsymbol{\beta})|\boldsymbol{X}$服从正态分布。
- 进一步，依据OLS估计量的性质(2)和(3)，$E(\boldsymbol{b}-\boldsymbol{\beta}|\boldsymbol{X})=0$，$Var(\boldsymbol{b}|\boldsymbol{X})=\sigma^2(\boldsymbol{X'X})^{-1}$，可得：$(\boldsymbol{b}-\boldsymbol{\beta})|\boldsymbol{X}\sim\boldsymbol{N}(\boldsymbol{0},\sigma^2(\boldsymbol{X'X})^{-1})$。

在原假设“$H_0:\beta_k=\overline{\beta}_k$”成立的情况下，其第 k 个分量 $(b_k-\overline{\beta}_k)\,|\,\boldsymbol{X}\sim N\left(0,\sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1}_{kk}\right)$，其中$(\boldsymbol{X}'\boldsymbol{X})^{-1}_{kk}$为矩阵$(\boldsymbol{X}'\boldsymbol{X})^{-1}$的$(k,k)$元素，而$\sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1}_{kk}$为$b_k$的方差。

如果σ^2已知，则统计量 $z_k\equiv\dfrac{b_k-\overline{\beta}_k}{\sqrt{\sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1}_{kk}}}\sim N(0,1)$。

通常σ^2未知，称为“厌恶参数”(nuisance parameter)：虽然对σ^2不感兴趣，但σ^2却出现在表达式中。

- 合格的“检验统计量”(test statistic)须满足两个条件：(i)能够根据样本数据计算；(ii)概率分布已知。

- 以估计值s^2来替代σ^2，可得t统计量。

定理(t 统计量的分布) 在假定 3.1-3.5 均满足，且原假设“$H_0:\beta_k=\overline{\beta}_k$”也成立的情况下，$t$ 统计量

$$t_k \equiv \frac{b_k-\overline{\beta}_k}{\mathrm{SE}(b_k)} \equiv \frac{b_k-\overline{\beta}_k}{\sqrt{s^2(\boldsymbol{X}'\boldsymbol{X})^{-1}_{kk}}} \sim t(n-K)$$

其中，$\mathrm{SE}(b_k)$是b_k的“估计标准误差”(estimated standard error)，简称“标准误”。

t 检验的步骤

- **第一步：**计算t_k。如果 $|t_k|$ 很大，则H_0较不可信。如果H_0为真，则t_k很大的概率将很小(为小概率事件)，不应在抽样中观测到。
- **第二步：**计算“显著性水平”(significance level)为$\alpha/2$的“临界值”(critical value)， $t_{\alpha/2}(n-K)$。

$$\mathrm{P}\left\{t(n-K)>t_{\alpha/2}(n-K)\right\}=\mathrm{P}\left\{t(n-K)<-t_{\alpha/2}(n-K)\right\}=\alpha/2$$

- 其中，$t(n-K)$服从 $t(n-K)$分布。$t(n-K)$大于 $t_{\alpha/2}(n-K)$，或小于$-t_{\alpha/2}(n-K)$的概率都是 $\alpha/2$ 。通常$\alpha=5\%$，则$\alpha/2=2.5\%$。有时，也取$\alpha=1\%$或10%。
- **第三步：**如果t_k落入“拒绝域”(rejection region)，则拒绝 H_0；t_k落入“接受域”(acceptance region)，则在现有信息下（暂时）接受H_0。
- 拒绝域位于 t 分布的两边，此类检验称为“双边检验”(two-tailed)，也译作双侧检验或双尾检验。

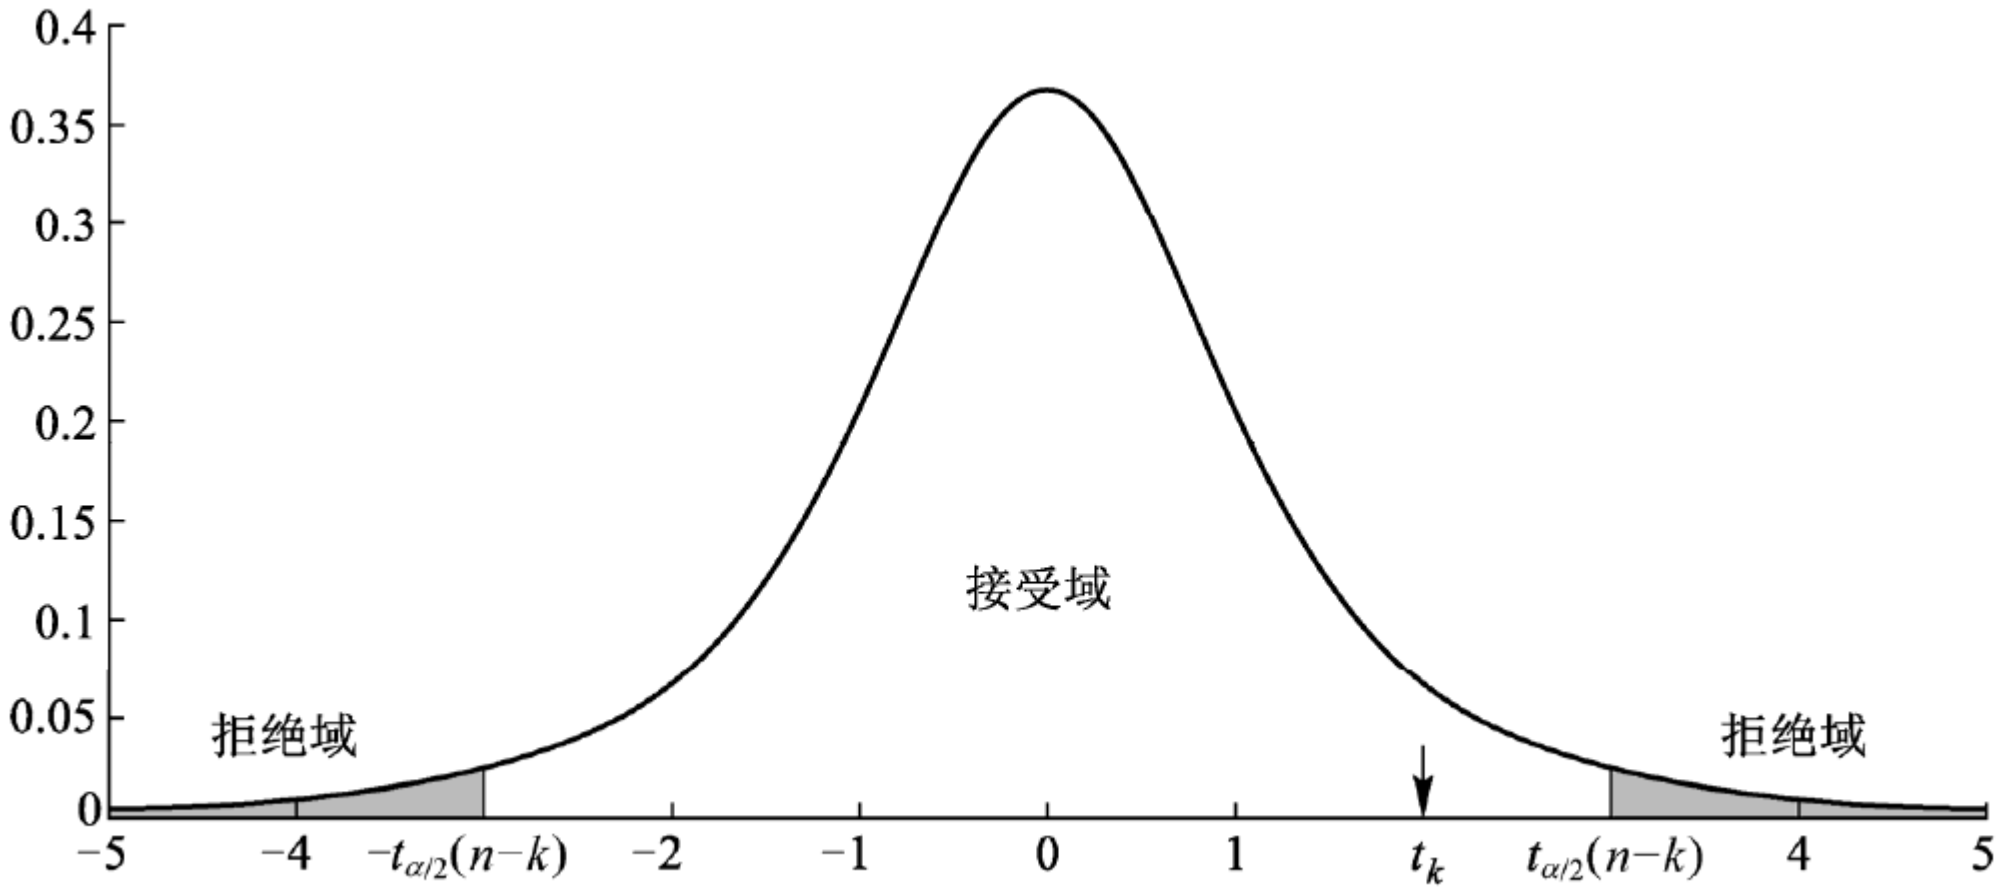

0.4
0.35
0.3
0.25
0.2
0.15
0.1
0.05
0
拒绝域
接受域
拒绝域
−5
−4
$-t_{\alpha/2}(n-k)$
−2
−1
0
1
t_k
$t_{\alpha/2}(n-k)$
4
5

图 3.3　t 检验

计算 p 值

- 定义 给定检验统计量的样本观测值，称原假设可被拒绝的最小显著性水平为此假设检验问题的p 值(probability value，即p-value)。
- 在t检验中，p 值为$P(t > |t_k|) \times 2$，其中t_k为检验统计量的样本观测值。
- p 值越小，越倾向于拒绝原假设。

【例】p 值 = 0.03，则可在5%的显著性水平上拒绝原假设。而且，“p 值= 0.03”还可在3%的显著性水平上拒绝原假设。

- 使用 p 值进行假设检验一般比临界值更有信息量。
- 当然，Stata等统计软件可以直接给出p 值。因此，进行实证研究时一般不需要手动查询t分布的临界值。

计算置信区间

假设“置信度”(confidence level)为$(1-\alpha)$(比如$\alpha=5\%$，则$1-\alpha=95\%$)，要找到“置信区间”(confidence interval)，使得该区间覆盖真实参数β_k的概率为$(1-\alpha)$。

由于$\dfrac{b_k-\beta_k}{\mathrm{SE}(b_k)}\sim t(n-K)$，故

$$\mathrm{P}\left\{-t_{\alpha/2}<\frac{b_k-\beta_k}{\mathrm{SE}(b_k)}<t_{\alpha/2}\right\}=1-\alpha \qquad (t_{\alpha/2}\text{的定义})$$

$$\mathrm{P}\left\{b_k-t_{\alpha/2}\,\mathrm{SE}(b_k)<\beta_k<b_k+t_{\alpha/2}\,\mathrm{SE}(b_k)\right\}=1-\alpha \qquad (\text{不等式变形})$$

即置信区间为$\left[b_k-t_{\alpha/2}\,\mathrm{SE}(b_k),\ b_k+t_{\alpha/2}\,\mathrm{SE}(b_k)\right]$。

统计学上的两类错误

- 第I类错误：弃真，第II类错误：存伪。（参见第2讲，p.30）
- 如果不能增加样本容量，减少第I类错误的发生概率，必然导致第II类错误的发生概率增加，反之亦然。
- 在进行检验时，一般先指定可接受的发生第I类错误的最大概率，即“显著性水平”，比如5%；而不指定第II类错误的发生概率(通常更难计算)。

定义：统计检验的**“功效”**或**“势”** (power)定义为“1 减去第II类错误的发生概率”，即“$1-P(accept\ H_0|H_1)$”。换言之，功效为在原假设为错误的情况下，拒绝原假设的概率。

- 进行检验时，通常知道第I类错误的发生概率，不知道第II类错误的发生概率。
- 拒绝原假设，比较理直气壮，因为知道犯错概率（显著性水平）。
- 接受原假设，比较没有把握，通常不知犯错概率（可能较高）。

3.7 对线性假设的F 检验

- 检验回归方程的显著性，即检验原假设“H_0: $\beta_2 = \cdots = \beta_K = 0$”($\beta_1$为常数项)。
- 更一般地，检验 m 个线性假设是否同时成立：

$$H_0 : \underbrace{\boldsymbol{R}}_{m\times K}\ \underbrace{\boldsymbol{\beta}}_{K\times 1} = \underbrace{\boldsymbol{r}}_{m\times 1}$$

- 其中，$\boldsymbol{r}$为 m 维列向量，$\boldsymbol{R}$为$m \times K$矩阵，$rank(\boldsymbol{R}) = m$，即$\boldsymbol{R}$满行秩，没有多余或自相矛盾的方程。
- Wald检验原理：$\boldsymbol{b}$是β的估计量，如果H_0成立，则$(\boldsymbol{Rb} - \boldsymbol{r})$应该比较接近$\boldsymbol{0}$。

定理(*F* 统计量的分布) 在假定 3.1-3.5 均满足，且原假设“$H_0: \boldsymbol{R\beta} = \boldsymbol{r}$”也成立的情况下，则 F 统计量

（证明见下页）

$$F \equiv \frac{(\boldsymbol{Rb}-\boldsymbol{r})'\left[\boldsymbol{R}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{R}'\right]^{-1}(\boldsymbol{Rb}-\boldsymbol{r})/m}{s^2} \sim F(m, n-K)$$

F检验的步骤

- 第一步：计算F统计量。如果F统计量很大，则H_0较不可信。
- 第二步：计算显著性水平为α的临界值$F_\alpha(m, n-K)$，则：$P\{F(m, n-K) > F_\alpha(m, n-K)\} = \alpha$，其中，$F(m, n-K)$服从$F(m, n-K)$分布。
- 第三步：如果 F 统计量落入右边拒绝域，则拒绝H_0；否则，不能拒绝H_0。注意拒绝域只在右侧，为“单边右侧检验”。

定理(*F* 统计量的分布) 在假定 3.1—3.5 均满足,且原假设"$H_0: \boldsymbol{R\beta}=\boldsymbol{r}$"也成立的情况下,则 F 统计量

$$F \equiv \frac{(\boldsymbol{Rb}-\boldsymbol{r})'[\boldsymbol{R}(\boldsymbol{X'X})^{-1}\boldsymbol{R}']^{-1}(\boldsymbol{Rb}-\boldsymbol{r})/m}{s^2} \sim F(m, n-K) \tag{3.24}$$

证明:由于 $s^2=\boldsymbol{e'e}/(n-K)$,可将 F 写成

$$F \equiv \frac{(\boldsymbol{Rb}-\boldsymbol{r})'[\sigma^2\boldsymbol{R}(\boldsymbol{X'X})^{-1}\boldsymbol{R}']^{-1}(\boldsymbol{Rb}-\boldsymbol{r})/m}{(\boldsymbol{e'e}/\sigma^2)/(n-K)} \equiv \frac{w/m}{q/(n-K)}$$

其中,$w \equiv (\boldsymbol{Rb}-\boldsymbol{r})'[\sigma^2\boldsymbol{R}(\boldsymbol{X'X})^{-1}\boldsymbol{R}']^{-1}(\boldsymbol{Rb}-\boldsymbol{r})$。下面将证明:

(1) $w|\boldsymbol{X} \sim \chi^2(m)$;

(2) $q|\boldsymbol{X} \sim \chi^2(n-K)$;(已在 t 统计量定理中证明)

(3) $w|\boldsymbol{X}$ 与 $q|\boldsymbol{X}$ 相互独立,

则根据 F 分布的定义,$\dfrac{w/m}{q/(n-K)} \sim F(m, n-K)$。

(1) 定义 $\boldsymbol{v} \equiv \boldsymbol{Rb}-\boldsymbol{r}$。在 H_0 成立的情况下,$\boldsymbol{v} \equiv \boldsymbol{Rb}-\boldsymbol{r}=\boldsymbol{Rb}-\boldsymbol{R\beta}=\boldsymbol{R}(\boldsymbol{b}-\boldsymbol{\beta})$。由于 $\boldsymbol{b}$ 为正态分布,故 $\boldsymbol{v}|\boldsymbol{X}$ 为 m 维正态分布,且 $\mathrm{E}(\boldsymbol{v}|\boldsymbol{X})=\boldsymbol{0}$,其方差为

$$\mathrm{Var}(\boldsymbol{v}|\boldsymbol{X})=\mathrm{Var}[\boldsymbol{R}(\boldsymbol{b}-\boldsymbol{\beta})|\boldsymbol{X}]=\boldsymbol{R}\mathrm{Var}(\boldsymbol{b})\boldsymbol{R}'=\sigma^2\boldsymbol{R}(\boldsymbol{X'X})^{-1}\boldsymbol{R}'$$

根据数理统计知识知道[①],

$$w \equiv (\boldsymbol{Rb}-\boldsymbol{r})'[\sigma^2\boldsymbol{R}(\boldsymbol{X'X})^{-1}\boldsymbol{R}']^{-1}(\boldsymbol{Rb}-\boldsymbol{r})=\boldsymbol{v}'[\mathrm{Var}(\boldsymbol{v}|\boldsymbol{X})]^{-1}\boldsymbol{v} \sim \chi^2(m)$$

注:由于 $\boldsymbol{R}$ 满行秩,故$[\boldsymbol{R}(\boldsymbol{X'X})^{-1}\boldsymbol{R}']^{-1}$存在。

(2) w 是 $\boldsymbol{b}$ 的函数,而 q 是 $\boldsymbol{e}$ 的函数,由于 $\boldsymbol{b}$ 与 $\boldsymbol{e}$ 相互独立,故$w|\boldsymbol{X}$ 与$q|\boldsymbol{X}$ 相互独立。

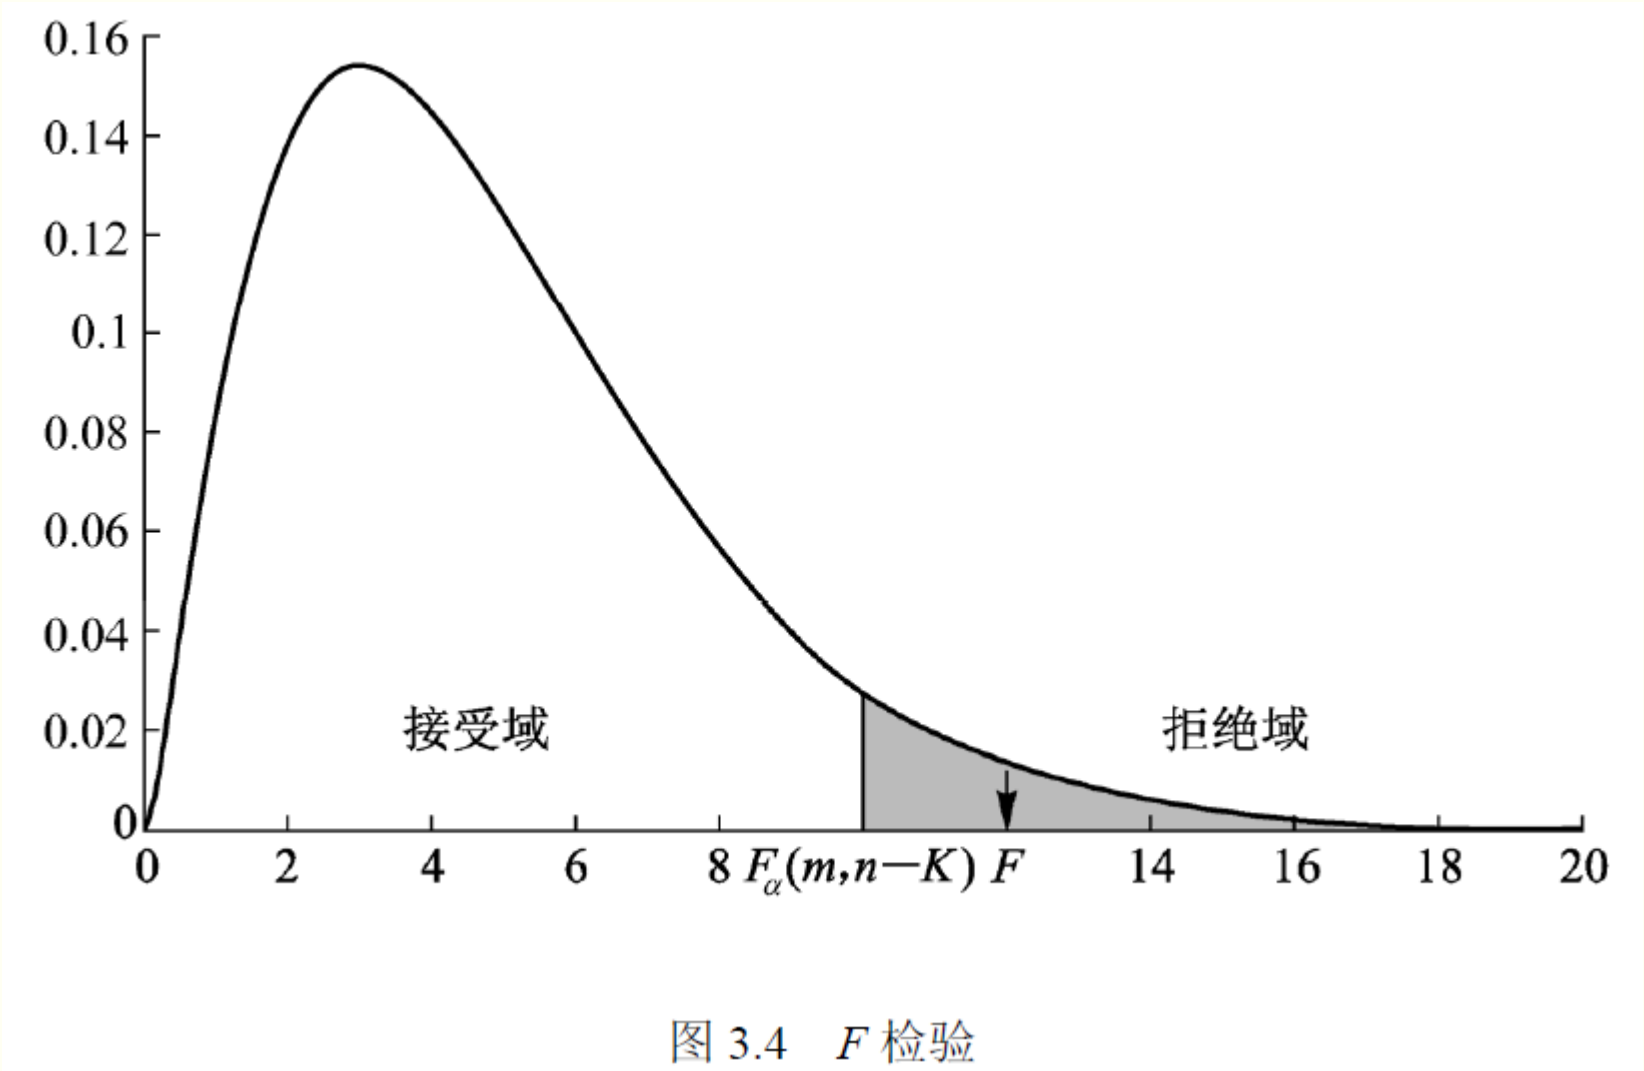

0.16
0.14
0.12
0.1
0.08
0.06
0.04
0.02
0
接受域
拒绝域
0
2
4
6
8 $F_\alpha(m,n-K)$ F
14
16
18
20

图 3.4　F 检验

3.8 F 统计量的似然比原理表达式

- 使用约束条件下的最小二乘法，即 “约束最小二乘法”(Restricted OLS，Constrained OLS)，可得F 统计量的简便表达式。
  - **STATA操作：**先使用`constraint def`命令定义约束，再使用`reg`命令进行回归。
- 考虑以下约束极值问题：

$$\min_{\tilde{\beta}} \ \mathrm{SSR}(\tilde{\boldsymbol{\beta}})$$
$$s.t. \ \ \boldsymbol{R}\tilde{\boldsymbol{\beta}} = \boldsymbol{r}$$

- 如果原假设H_0: $\boldsymbol{R\beta} = \boldsymbol{r}$正确，则加上此约束不应使残差平方和$SSR(\tilde{\boldsymbol{\beta}})$ 的最小值增大很多。**（注意：这一思路会在本课程中反复应用）**

求解此约束极值问题，可证明：

$$F=\frac{(\boldsymbol{e}^{*\prime}\boldsymbol{e}^{*}-\boldsymbol{e}'\boldsymbol{e})/m}{\boldsymbol{e}'\boldsymbol{e}/(n-K)}$$

其中，$\boldsymbol{e}$为无约束残差，$\boldsymbol{e}^{*}$为有约束残差，m 为约束条件个数。

这种通过比较“条件极值”与“无条件极值”而进行的检验，统称为“似然比检验”(Likelihood ratio test)。

命题 对于线性回归方程“$y_i=\beta_1+\beta_2x_{i2}+\cdots+\beta_Kx_{iK}+\varepsilon_i$”，检验原假设“$H_0:\beta_2=\cdots=\beta_K=0$”(即该方程的显著性)的 F 统计量等于$\dfrac{R^2/(K-1)}{(1-R^2)/(n-K)}$。

3.9 利用计量模型进行预测

- 有时，我们也会使用计量模型进行预测(prediction/forecasting)，即给定解释向量$\boldsymbol{x_0}$的(未来)取值，预测被解释变量y_0的取值。
- 假设计量模型对所有观测值都成立(包括外推到未来的观测值)，即：

$$y_0 = \boldsymbol{x_0'\beta} + \epsilon_0$$

- 用$\hat{y}_0 = \boldsymbol{x_0'b}$对$y_0$作点预测，其中$\boldsymbol{b}$为$\boldsymbol{\beta}$的 OLS 估计量。
- “预测误差”(prediction error) $(\hat{y}_0 - y_0)$可写为

$$\hat{y}_0 - y_0 = \boldsymbol{x_0'b - x_0'\beta} - \epsilon_0 = \boldsymbol{x_0'(b-\beta)} - \epsilon_0$$

- 由于$\boldsymbol{b}$是$\boldsymbol{\beta}$的无偏估计，故$E(\hat{y}_0 - y_0) = \boldsymbol{x_0'}E(\boldsymbol{b-\beta}) - E(\epsilon_0) = 0$。
- “无偏预测”(unbiased predictor)：用$\hat{y}_0$来预测y_0不会系统高估或低估。
- 预测$\hat{y}_0$的方差为：$Var(\hat{y}_0) = Var(\boldsymbol{x_0'b}) = \boldsymbol{x_0}'Var(\boldsymbol{b})\boldsymbol{x_0} = \sigma^2\boldsymbol{x_0}'(\boldsymbol{X'X})^{-1}\boldsymbol{x_0}$。
- 此方差反映由于抽样误差$(\boldsymbol{b-\beta})$所带来的预测量$\hat{y}_0$的波动。如果知道$\boldsymbol{\beta}$，则$Var(\hat{y}_0) = Var(\boldsymbol{x_0'\beta}) = 0$。

预测误差$(\hat{y}_0 - y_0)$的方差为：

$$\begin{aligned}\mathrm{Var}(\hat{y}_0 - y_0) &= \mathrm{Var}[\boldsymbol{x}_0'(\boldsymbol{b}-\boldsymbol{\beta}) - \varepsilon_0] \\ &= \mathrm{Var}(\varepsilon_0) + \mathrm{Var}[\boldsymbol{x}_0'(\boldsymbol{b}-\boldsymbol{\beta})] \\ &= \sigma^2 + \sigma^2 \boldsymbol{x}_0'(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{x}_0\end{aligned}$$

其中，假设ε_0与$\boldsymbol{b}$不相关(估计$\boldsymbol{b}$没用到ε_0的信息)，故$\mathrm{Cov}\left[\boldsymbol{x}_0'(\boldsymbol{b}-\boldsymbol{\beta}), \varepsilon_0\right] = 0$。

预测误差的方差有两个来源，即抽样误差$\sigma^2 \boldsymbol{x}_0'(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{x}_0$(不能精确知道参数$\boldsymbol{\beta}$)，以及$y_0$本身的不确定性($\varepsilon_0$的方差$\sigma^2$)。

假设扰动项为正态，则 $\hat{y}_0 - y_0 \sim N\left(0, \sigma^2 + \sigma^2 \boldsymbol{x}_0'(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{x}_0\right)$。

用 s^2 估计 σ^2，得到 t 统计量：

$$\frac{\hat{y}_0 - y_0}{s\sqrt{1 + \boldsymbol{x}_0'(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{x}_0}} \sim t(n-K)$$

y_0 的置信度为 $(1-\alpha)$ 的置信区间为

$$\left(\hat{y}_0 - t_{\alpha/2}s\sqrt{1 + \boldsymbol{x}_0'(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{x}_0},\ \hat{y}_0 + t_{\alpha/2}s\sqrt{1 + \boldsymbol{x}_0'(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{x}_0}\right)$$

经济与工商管理学院
BNU Business School

问题与讨论

电子邮箱：licheng.xu@bnu.edu.cn

办公室：后主楼1730A