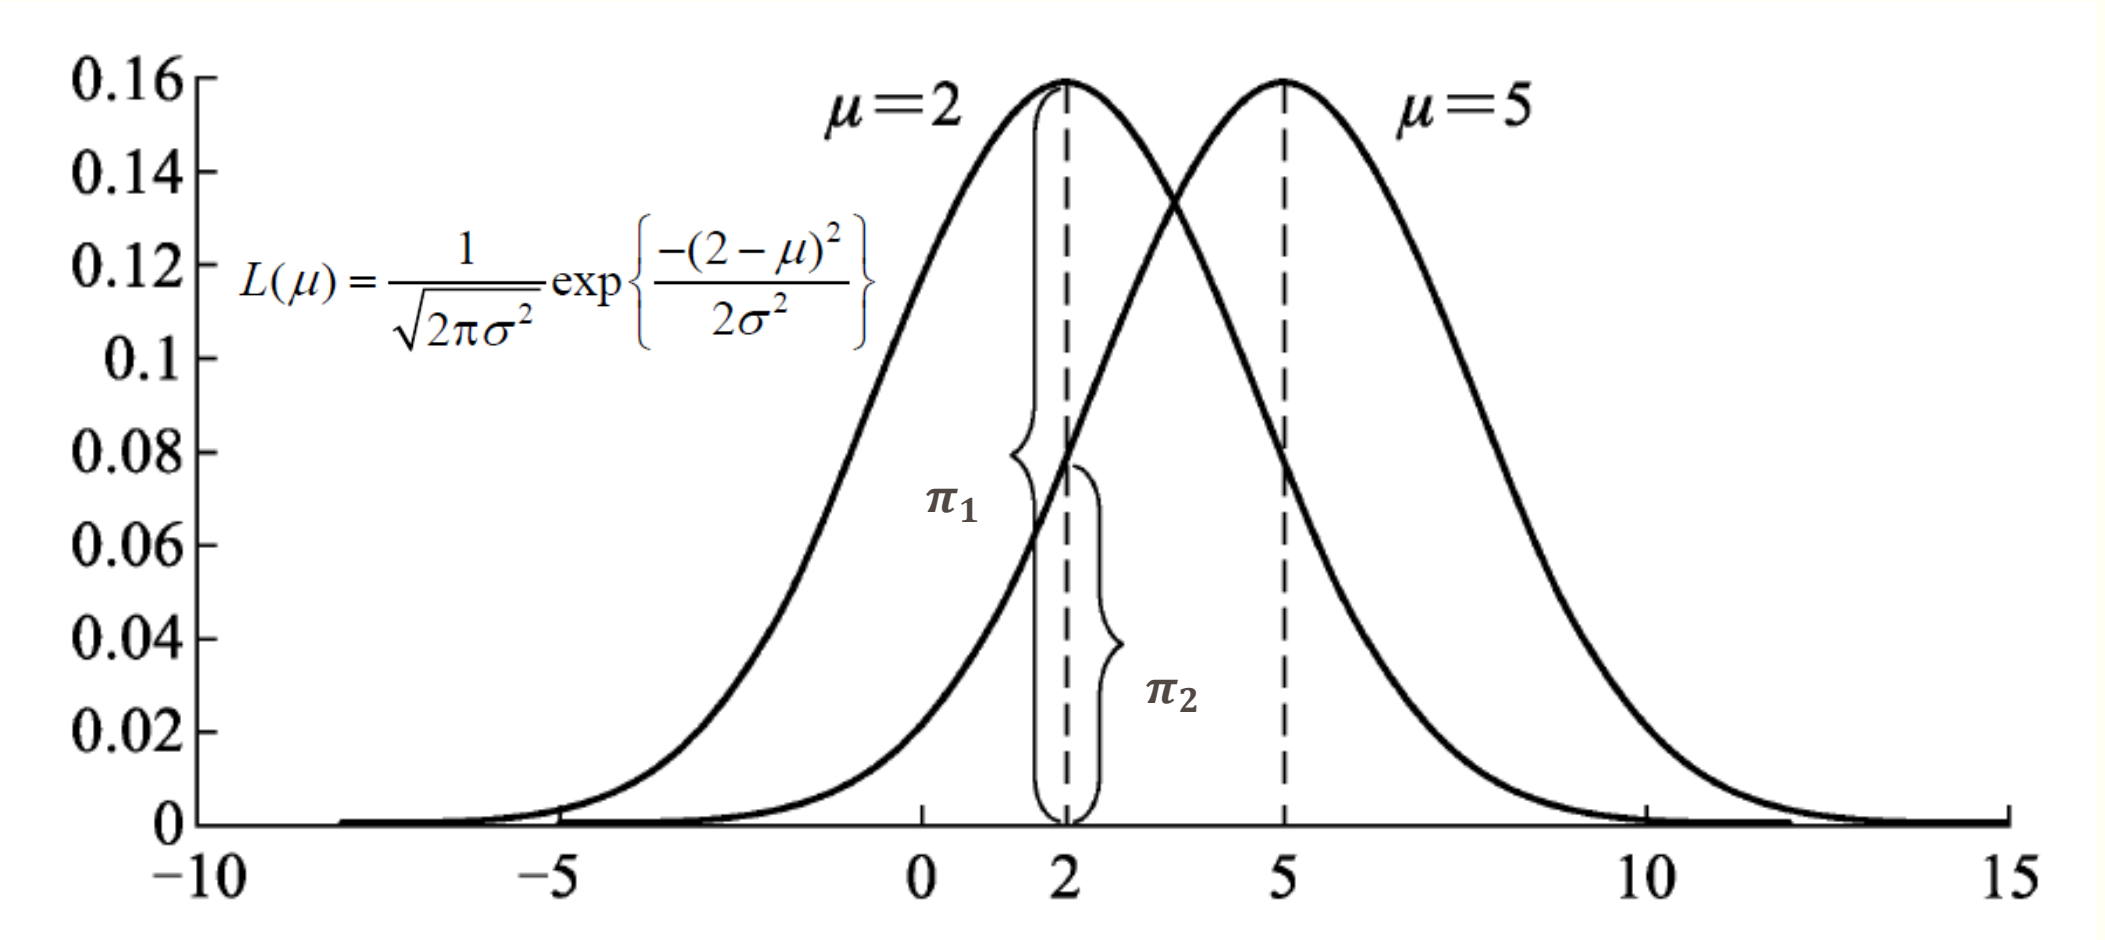
高级计量经济学

(2026/27学年度 秋季学期)

第五讲：极大似然估计

引入（1）：极大似然估计的应用场景及基本思想

- 如果回归模型存在非线性，可能不方便使用OLS。
- 此时，一个经常使用的参数估计方法是极大似然估计(MLE)。
- **极大似然估计法的基本思想：通过给定的数据找到使观测数据出现概率最大的参数值。**
  - **例：**某人（个体）操一口浓重的广东口音，则判断他最有可能来自广东（总体）。
  - **问：**他是否一定来自广东呢？不一定，但可能性很大。
- 同理，给定一个样本，如果在某个参数$\boldsymbol{\theta}$下观测到该样本的可能性最大，那么参数$\boldsymbol{\theta}$所确定的总体就是我们推测该样本来源的总体。不一定对，但可能性比较大。
  - 这里，$\boldsymbol{\theta}$就是我们要找的极大似然估计量。
  - **注意：**这里的$\boldsymbol{\theta}$只是一个代号，不是一成不变的。例如，对于服从正态分布的总体，我们可能要估计的参数就是期望μ或者方差σ^2。（下面以方差σ^2给定、估计期望μ为例）



图示：选择参数（估计值）使得观测到样本的可能性最大

引入（2）：从一个常见的STATA输出结果谈起

- 本科阶段学习和应用计量经济学时，你是否见过下图这样的输出结果？
- 你是否有过这样的疑问：下图中展示的log likelihood是什么？是如何求到的？

```
Iteration 0:   log likelihood = -3896.1666
Iteration 1:   log likelihood = -3824.9438
Iteration 2:   log likelihood = -3819.6424
Iteration 3:   log likelihood = -3817.6225
Iteration 4:   log likelihood = -3817.5472
Iteration 5:   log likelihood = -3817.5471

Logistic regression                             Number of obs     =     18,870
                                                LR chi2(8)        =     157.24
                                                Prob > chi2       =     0.0000
Log likelihood = -3817.5471                     Pseudo R2         =     0.0202
```

voluntaryceo	Coef.	Std. Err.	z	P>|z|	[95% Conf.	Interval]
roaa	-.8199288	.32877	-2.49	0.013	-1.464306	-.1755515
age	.0031431	.0045636	0.69	0.491	-.0058014	.0120877
days	.0038754	.0009667	4.01	0.000	.0019807	.0057701
roea	.0121695	.0163592	0.74	0.457	-.019894	.0442331
valuebookratiob	.1660779	.4239323	0.39	0.695	-.6648143	.99697
logsize	.0702887	.1315256	0.53	0.593	-.1874967	.3280742
lntotalsalary	-.4523606	.0383628	-11.79	0.000	-.5275504	-.3771709
lnysmvttl	.1293734	.1375683	0.94	0.347	-.1402555	.3990022
_cons	-1.578898	.8766776	-1.80	0.072	-3.297154	.1393589

```
Note: 1 failure and 0 successes completely determined.
```

本讲主要内容

- 极大似然估计法的定义
- 线性回归模型的极大似然估计
- 极大似然估计的数值解
- 信息矩阵与无偏估计的最小方差
- 极大似然估计的大样本性质
- 极大似然估计量的渐近协方差矩阵
- 三类渐近等价的统计检验
- 准极大似然估计法
- 对正态分布假设的检验

5.1 极大似然估计法的定义

假设随机向量$\boldsymbol{y}$的概率密度函数为$f(\boldsymbol{y};\boldsymbol{\theta})$，其中$\boldsymbol{\theta}$为 K 维未知参数向量，$\boldsymbol{\theta}\in\Theta$。

Θ为参数空间，即参数$\boldsymbol{\theta}$所有可能取值所构成的集合。

通过抽取随机样本$\{\boldsymbol{y}_1,\cdots,\boldsymbol{y}_n\}$来估计$\boldsymbol{\theta}$。

假设$\{\boldsymbol{y}_1,\cdots,\boldsymbol{y}_n\}$为 iid，则样本数据的联合密度函数为$f(\boldsymbol{y}_1;\boldsymbol{\theta})f(\boldsymbol{y}_2;\boldsymbol{\theta})\cdots f(\boldsymbol{y}_n;\boldsymbol{\theta})$。

- 在抽样前，$\{\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}\}$为随机向量。
- 抽样后，$\{\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}\}$有了特定的样本值，可将样本联合密度函数视为在$\{\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}\}$给定情况下，未知参数$\boldsymbol{\theta}$的函数。
- 定义似然函数(likelihood function)为：

$$L(\boldsymbol{\theta}; y_1, \cdots, y_n) = \prod_{i=1}^{n} f(y_i; \boldsymbol{\theta})$$

- 似然函数与联合密度函数完全相等，只是$\boldsymbol{\theta}$与$\{\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}\}$的角色互换，即把$\boldsymbol{\theta}$作为自变量，而视$\{\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}\}$为给定。
- 为了运算方便，常把似然函数取对数：

$$\ln L(\boldsymbol{\theta}; y_1, \cdots, y_n) = \sum_{i=1}^{n} \ln f(y_i; \boldsymbol{\theta})$$

极大似然估计法的核心思想：

- 给定样本取值后，推断该样本最有可能来自参数$\boldsymbol{\theta}$为何值的总体。
- 换句话说，要寻找$\widehat{\boldsymbol{\theta}}_{\mathrm{ML}}$，使得观测到样本数据的可能性最大，也就是对数似然函数(log-likelihood function)最大化：

$$\max_{\boldsymbol{\theta}\in\Theta} \ln L(\boldsymbol{\theta};\, \boldsymbol{y})$$

- 极大似然估计量$\widehat{\boldsymbol{\theta}}_{\mathrm{ML}}$可写为：

$$\hat{\boldsymbol{\theta}}_{\mathrm{ML}} \equiv \arg\max \ln L(\boldsymbol{\theta};\, \boldsymbol{y})$$

- 其中，“argmax”(argument of the maximum)表示能使$\ln L(\boldsymbol{\theta};\, \boldsymbol{y})$最大化的$\boldsymbol{\theta}$取值。

- 假设存在唯一内点解，一阶条件要求，对数似然函数的梯度向量(gradient，即一元条件下的偏导数、切线斜率)为0，即$\boldsymbol{s}(\boldsymbol{\theta};\ \boldsymbol{y}) = \mathbf{0}$。

$$\boldsymbol{s}(\boldsymbol{\theta};\ \boldsymbol{y}) \equiv \frac{\partial \ln L(\boldsymbol{\theta};\ \boldsymbol{y})}{\partial \boldsymbol{\theta}} \equiv \begin{pmatrix} \frac{\partial \ln L(\boldsymbol{\theta};\ \boldsymbol{y})}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ln L(\boldsymbol{\theta};\ \boldsymbol{y})}{\partial \theta_K} \end{pmatrix} = \mathbf{0}$$

- 实际上，上式是包含了K个未知参数 $(\theta_1\ \theta_2\ \ldots\ \theta_K)$，$K$个方程的方程组。
- 该向量也称“**得分函数**”(score function) 或“**得分向量**”(score vector)。
- 得分函数$\boldsymbol{s}(\boldsymbol{\theta};\ \boldsymbol{y})$是$\boldsymbol{y}$的函数，也是随机向量。
- 下面，记真实参数为$\boldsymbol{\theta_0}$，而$\boldsymbol{\theta}$为该参数的任何可能取值。

➢ **命题：得分函数的期望为0。**

- 如果似然函数正确(correctly specified)，则

$$E[\boldsymbol{s}(\boldsymbol{\theta_0};\ \boldsymbol{y})] = \mathbf{0}$$

- 其中，$\boldsymbol{s}(\boldsymbol{\theta_0};\ \boldsymbol{y})$表示得分函数$\boldsymbol{s}(\boldsymbol{\theta};\ \boldsymbol{y})$在$\boldsymbol{\theta} = \boldsymbol{\theta_0}$处的取值。

例：假设随机样本$y_i \sim N(\theta_0, 1)$，$i = 1, 2, \ldots, n$。则样本数据的对数似然函数为：

$$L(\theta) = -\frac{n}{2}\ln 2\pi - \frac{1}{2}\sum_{i=1}^{n}(y_i - \theta)^2$$

- 其得分函数为：$s(\theta) = \frac{\partial L(\theta)}{\partial \theta} = \sum_{i=1}^{n}(y_i - \theta)$
- 故得分函数的期望值为：$E[s(\theta)] = \sum_{i=1}^{n}[E(y_i) - \theta] = \sum_{i=1}^{n}(\theta_0 - \theta)$
- 在$\theta = \theta_0$处：$E[s(\theta)]|_{\theta=\theta_0} = \sum_{i=1}^{n}(\theta_0 - \theta)\,|_{\theta=\theta_0} = 0$ (此结果与上述命题一致)

- 可对得分函数做进一步分解：

$$\boldsymbol{s}(\boldsymbol{\theta};\ \boldsymbol{y}) \equiv \frac{\partial \ln L(\boldsymbol{\theta};\ \boldsymbol{y})}{\partial \boldsymbol{\theta}} = \frac{\partial \sum_{i=1}^{n} \ln f(\boldsymbol{y}_i;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}$$
$$= \sum_{i=1}^{n} \frac{\partial \ln f(\boldsymbol{y}_i;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \equiv \sum_{i=1}^{n} \boldsymbol{s}_i(\boldsymbol{\theta};\ \boldsymbol{y}_i)$$

- 其中，$\boldsymbol{s_i(\theta;\ y_i)} \equiv \frac{\partial \ln f(\boldsymbol{y_i};\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}$ 为第i个观测值对得分函数的贡献。
- 在前页的示例中，$s(\theta;\boldsymbol{y}) = \sum_{i=1}^{n}(y_i - \theta)$，而$s_i(\theta;\ y_i) = y_i - \theta$。

- 二阶条件要求，对数似然函数的黑塞矩阵(Hessian matrix)为负定矩阵，即对数似然函数为严格凹函数 (strictly concave)。
- 黑塞矩阵可表示并分解为：

$$\boldsymbol{H}(\boldsymbol{\theta};\ \boldsymbol{y}) \equiv \frac{\partial^2 \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} = \sum_{i=1}^{n} \frac{\partial^2 \ln L(\boldsymbol{\theta};\boldsymbol{y_i})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} \equiv \sum_{i=1}^{n} \boldsymbol{H}_i(\boldsymbol{\theta};\ \boldsymbol{y}_i)$$

- 其中，$\boldsymbol{H}_i(\boldsymbol{\theta};\ \boldsymbol{y}_i)$为第$i$个观测值对黑塞矩阵的贡献。
- 在上例中，$\boldsymbol{H}(\theta;\ \boldsymbol{y}) = \frac{\partial s(\theta)}{\partial \theta} = \frac{\partial \sum_{i=1}^{n}(y_i-\theta)}{\partial \theta} = -n$，而$\boldsymbol{H}_i(\theta;\ y_i) = \frac{\partial s_i(\theta)}{\partial \theta} = \frac{\partial (y_i-\theta)}{\partial \theta} = -1$。

5.2 线性回归模型的极大似然估计

- **极大似然估计(MLE)多用于非线性模型，但不代表不能用于线性回归。**
- 首先考虑如下线性回归模型：

$$\boldsymbol{y} = \boldsymbol{X\beta} + \boldsymbol{\epsilon}$$

- 为了使用MLE，首先要对扰动项的条件概率分布进行假设，即假设$\boldsymbol{\epsilon|X}\sim N(\boldsymbol{0}, \boldsymbol{\sigma^2 I_n})$。因此，被解释变量的条件分布为$\boldsymbol{y|X}\sim N(\boldsymbol{X\beta}, \boldsymbol{\sigma^2 I_n})$，其条件概率密度函数为：

$$f(\boldsymbol{y}\mid \boldsymbol{X}) = (2\pi\sigma^2)^{-n/2}\exp\left\{-\frac{1}{2\sigma^2}(\boldsymbol{y}-\boldsymbol{X\beta})'(\boldsymbol{y}-\boldsymbol{X\beta})\right\}$$

- 用假想值$\tilde{\boldsymbol{\beta}}, \tilde{\sigma}^2$代替真实值$\boldsymbol{\beta}, \sigma^2$，取对数可得：

$$\ln L(\tilde{\boldsymbol{\beta}}, \tilde{\sigma}^2) = -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln\tilde{\sigma}^2 - \frac{1}{2\tilde{\sigma}^2}(\boldsymbol{y}-\boldsymbol{X}\tilde{\boldsymbol{\beta}})'(\boldsymbol{y}-\boldsymbol{X}\tilde{\boldsymbol{\beta}})$$

- 此对数似然函数的最大化问题可分两步求解：第一步，给定$\tilde{\sigma}^2$，选择最优$\widetilde{\boldsymbol{\beta}}$。第二步，代入第一步求到的最优$\widetilde{\boldsymbol{\beta}}$，选择最优的$\tilde{\sigma}^2$。
- **第一步：**由于$\widetilde{\boldsymbol{\beta}}$只出现在第三项中，故等价于使$(\boldsymbol{y}-\boldsymbol{X}\widetilde{\boldsymbol{\beta}})'(\boldsymbol{y}-\boldsymbol{X}\widetilde{\boldsymbol{\beta}})$最小，这也正是OLS的目标函数$\boldsymbol{e}'\boldsymbol{e}$。从而有：

$$\widehat{\boldsymbol{\beta}}_{\boldsymbol{ML}}=\widehat{\boldsymbol{\beta}}_{\boldsymbol{OLS}}=(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}$$

- **第二步：**对数似然函数变为$\ln L(\tilde{\sigma}^2)=-\frac{n}{2}\ln 2\pi-\frac{n}{2}\ln\tilde{\sigma}^2-\frac{1}{2\tilde{\sigma}^2}\boldsymbol{e}'\boldsymbol{e}$，称为“集中对数似然函数”(concentrated log likelihood function)，因为的取值已在第一步固定，称为“对参数$\widetilde{\boldsymbol{\beta}}$集中”(concentrated with respect to $\widetilde{\boldsymbol{\beta}}$)。将$\ln L(\tilde{\sigma}^2)$对$\tilde{\sigma}^2$求导可得：

$$-\frac{n}{2}\frac{1}{\tilde{\sigma}^2}+\frac{1}{2\tilde{\sigma}^4}\boldsymbol{e}'\boldsymbol{e}=0$$

- 求解σ^2的MLE估计量为：

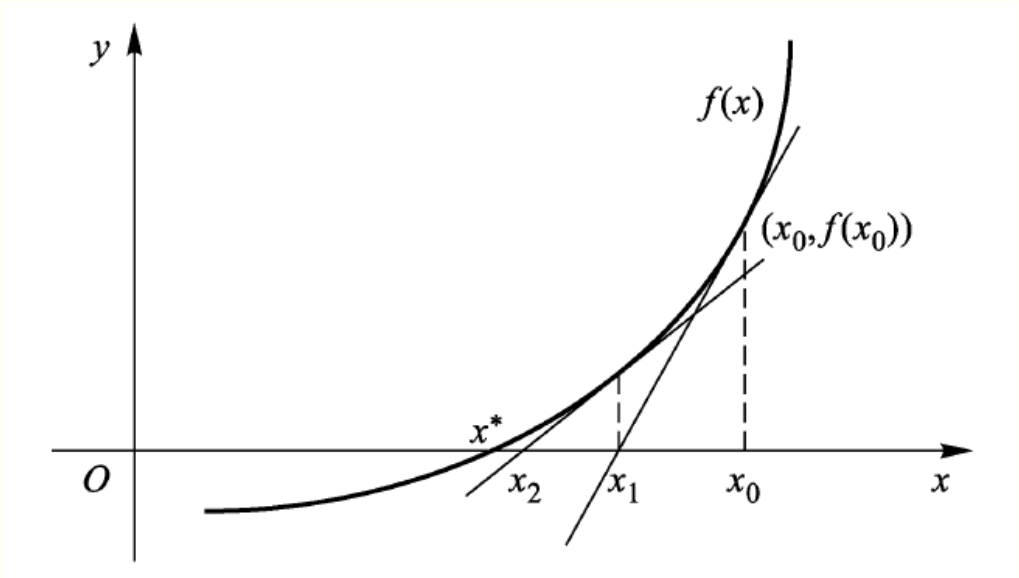
$$\hat{\sigma}^2_{\mathrm{ML}}=\frac{\boldsymbol{e}'\boldsymbol{e}}{n}\neq\hat{\sigma}^2_{\mathrm{OLS}}=\frac{\boldsymbol{e}'\boldsymbol{e}}{n-K}\equiv s^2$$

➢线性回归模型的极大似然估计小结：

- MLE 对$\boldsymbol{\beta}$的估计与 OLS 一样，但对σ^2的估计略有不同，此差别在大样本下消失。
- 由于OLS估计量s^2是对σ^2的无偏估计，故MLE估计量$\hat{\sigma}^2_{ML}$是有偏的(小样本性质)。
- **MLE 的主要优点是大样本性质良好**，比如一致性、最小渐近方差。

5.3 极大似然估计的数值解

- 极大似然估计通常没有解析解，只能寻找“数值解”(numerical solution)。
- 方法一为“网格搜索”(grid search)：
- 如果待估参数θ为一维，且大致知道取值范围，比如$\theta \in (0,1)$，可进行网格搜索。
- 如果待估参数$\boldsymbol{\theta}$为多维，或对$\boldsymbol{\theta}$的取值范围所知不多，则网格搜索不现实。
- 方法二为“高斯−牛顿法”(Gauss-Newton method)，也是实践中的常用迭代方法。



- 高斯-牛顿法方法之所以常用，是因为它收敛很快，是二次的，即本次迭代误差为0.1，下次则为0.01。
- 如果初始值 x_0 选择不当，可能出现迭代不收敛的情形。
- 使用高斯-牛顿法得到的可能只是“局部最大值”(local maximum)，而非“整体最大值”(global maximum)。
- 牛顿法也适用于多元函数的情形 $f(\boldsymbol{x}) = 0$ ，将切线替换为(超)切平面即可。
- 高斯-牛顿法相当于对原函数做了一阶近似，一个改进方法是对原函数 $f(x)$作二阶近似(二阶泰勒展开)，称为“牛顿-拉夫森法”(Newton-Raphson method)。

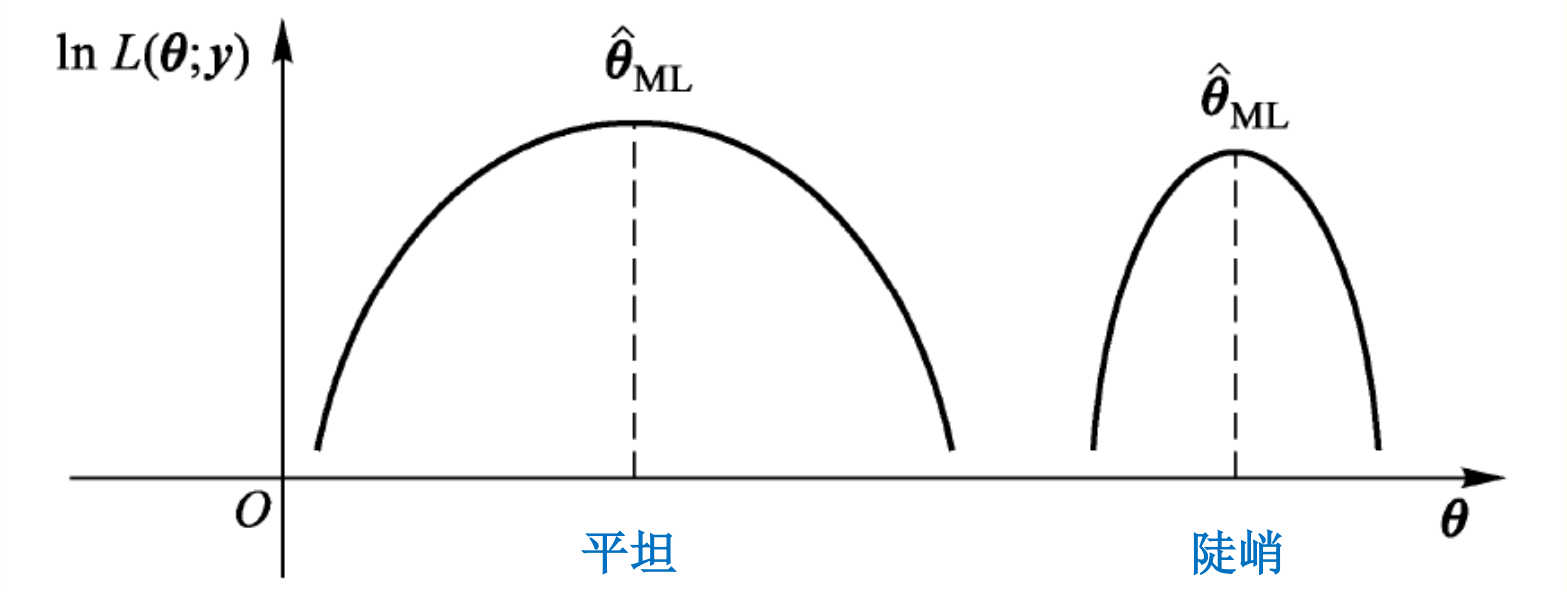
5.4 信息矩阵与无偏估计的最小方差

- 定义**信息矩阵**(information matrix)为对数似然函数的黑塞矩阵之期望值(对$\boldsymbol{y}$求期望)的负数，一般记为：

$$\boldsymbol{I}(\boldsymbol{\theta}) \equiv -\mathrm{E}\left[\frac{\partial^2 \ln L(\boldsymbol{\theta}; \boldsymbol{y})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'}\right]$$

- 一维情形下，$-\frac{\partial^2 \ln L}{\partial \theta^2}$为对数似然函数的二阶导数之负数。
- 对数似然函数为凹函数，故二阶导数为负数，加负号后为正数。
- $-\frac{\partial^2 \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'}$表示对数似然函数在$\boldsymbol{\theta}$空间中的**曲率**(curvature)，取期望值之后为平均曲率(对$\boldsymbol{y}$进行平均)。

- 如果曲率大，对数似然函数陡峭，较易根据样本分辨真实$\boldsymbol{\theta}$的位置；反之，如果曲率小，对数似然函数平坦，不易根据样本判断真实$\boldsymbol{\theta}$的位置。
- 如果似然函数完全平坦，则似然函数不存在唯一最大值，MLE 没有唯一解；则无法根据样本数据来判断$\boldsymbol{\theta}$的位置。
- $\boldsymbol{I}(\boldsymbol{\theta})$包含了$\boldsymbol{\theta}$是否容易估计的信息，故称“信息矩阵”。



➢**命题：信息矩阵等式**

- 在$\boldsymbol{\theta} = \boldsymbol{\theta_0}$处，以下“信息矩阵等式”(information matrix equality)成立：

$$\boldsymbol{I}(\boldsymbol{\theta}_0) \equiv -\mathrm{E}\left[\frac{\partial^2 \ln L(\boldsymbol{\theta}_0; \boldsymbol{y})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'}\right]$$

$$= \mathrm{E}\left[\frac{\partial \ln L(\boldsymbol{\theta}_0; \boldsymbol{y})}{\partial \boldsymbol{\theta}} \frac{\partial \ln L(\boldsymbol{\theta}_0; \boldsymbol{y})}{\partial \boldsymbol{\theta}'}\right] = \mathrm{E}\left[s(\boldsymbol{\theta}_0; \boldsymbol{y}) s(\boldsymbol{\theta}_0; \boldsymbol{y})'\right]$$

- 第一行有负号，是为了把“二阶导数为负”的曲率，翻转成正的信息量。
- 第二行没负号，是因为一阶导数的乘积项（平方项）本身非负。
- 在实际计算中，方差估计常用第二个（更简单），而理论推导常用第一个。

➢**命题：得分函数的方差为信息矩阵**

- 在$\boldsymbol{\theta} = \boldsymbol{\theta_0}$处，信息矩阵$\boldsymbol{I}(\boldsymbol{\theta_0})$就是得分函数的协方差矩阵$Var[s(\boldsymbol{\theta_0}; \boldsymbol{y})]$。

证明：

$$\mathrm{Var}\left[s(\boldsymbol{\theta}_0;\boldsymbol{y})\right] = \mathrm{E}\left[s(\boldsymbol{\theta}_0;\boldsymbol{y})s(\boldsymbol{\theta}_0;\boldsymbol{y})'\right] - \underbrace{\mathrm{E}\left[s(\boldsymbol{\theta}_0;\boldsymbol{y})\right]}_{=0}\underbrace{\mathrm{E}\left[s(\boldsymbol{\theta}_0;\boldsymbol{y})\right]'}_{=0}$$

$$= \mathrm{E}\left[s(\boldsymbol{\theta}_0;\boldsymbol{y})s(\boldsymbol{\theta}_0;\boldsymbol{y})'\right]$$

$$= \boldsymbol{I}(\boldsymbol{\theta}_0)$$

- 最后一步用到了信息矩阵等式。

- 假设$\widehat{\boldsymbol{\theta}}$是对真实参数$\boldsymbol{\theta_0}$的任意无偏估计，则在一定的正则条件(regularity conditions)下，$\widehat{\boldsymbol{\theta}}$的方差不会小于$[\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1}$，即：$Var(\widehat{\boldsymbol{\theta}}) \geq [\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1}$。
- 称$[\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1}$为“**克莱默—劳下限**”(Cramer-Rao Lower Bound)。
- 无偏估计所能达到的最小方差与信息矩阵有关。曲率$\boldsymbol{I}(\boldsymbol{\theta_0})$越大，则$[\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1}$越小，无偏估计可能达到的最小方差越小。
- 在古典线性回归模型中，可证明：

$$\left[\boldsymbol{I}(\boldsymbol{\theta}_0)\right]^{-1} = \begin{pmatrix} \sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1} & \mathbf{0} \\ \mathbf{0} & 2\sigma^4/n \end{pmatrix}$$

- 其中，$\boldsymbol{\theta_0} = (\boldsymbol{\beta}\ \sigma^2)'$，由于$Var(\widehat{\boldsymbol{\beta}}_{\boldsymbol{OLS}}) = \sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1}$，故$\widehat{\boldsymbol{\beta}}_{\boldsymbol{ML}} = \widehat{\boldsymbol{\beta}}_{\boldsymbol{OLS}}$均达到了无偏估计的最小方差。

- **命题：**在高斯-马尔可夫定理中，如果加上扰动项为正态分布的假定，则OLS 是“一致最小方差无偏估计”(Uniformly Minimum Variance Unbiased Estimator，简记 UMVUE)，而不仅仅是“最佳线性无偏估计”(BLUE)。
  - 注：此处中文版教材表述不够严谨，说此时OLS 是“最佳无偏估计”(Best Unbiased Estimator，简记BUE)，但这个词在统计学中通常是一个不严谨的简称。严格来说，不存在绝对的“最佳无偏估计”，因为在某些模型中，可能根本找不到无偏估计量。
- 克莱默-劳下限的结论可推广到渐近分布的情形：
- 在一定的正则条件下，对于真实参数$\boldsymbol{\theta_0}$的渐近正态一致估计(Consistent and Asymptotically Normally distributed estimators，简记CAN)所能达到的最小方差为$[\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1}$，即克莱默-劳下限。

5.5 极大似然估计的大样本性质

➢**定理：MLE的大样本性质**

- 在一定的正则条件下，MLE 估计量拥有以下良好的大样本性质。

(1) 一致性，即：$\underset{n\to\infty}{\text{plim}}\,\widehat{\boldsymbol{\theta}}_{ML}=\boldsymbol{\theta}_0$

(2) 渐近有效性，即：渐近协方差矩阵$Avar(\widehat{\boldsymbol{\theta}}_{ML})=n[\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1}$，在大样本下达到了克莱默-劳下限。

(3) 渐近正态，即：$\sqrt{n}\left(\widehat{\boldsymbol{\theta}}_{ML}-\boldsymbol{\theta}_0\right)\xrightarrow{d}N(\mathbf{0},n[\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1})$，可近似地认为$\widehat{\boldsymbol{\theta}}_{ML}\xrightarrow{d}N(\boldsymbol{\theta}_0,[\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1})$。

- 上述三条性质的证明需要进行大量数学运算，这里不做要求。
- 在证明渐近正态这一性质时，需首先证明：

$$\sqrt{n}\left(\widehat{\boldsymbol{\theta}}_{ML}-\boldsymbol{\theta}_0\right)\xrightarrow{d}N\left(\mathbf{0},\boldsymbol{A}_0^{-1}\boldsymbol{B}_0\boldsymbol{A}_0^{-1}\right)$$

- 其中，$\boldsymbol{B_0}\equiv Var(\boldsymbol{s_i})$，而$\boldsymbol{s_i}$为得分函数分解后第$i$个观测值对得分函数的贡献（**回顾幻灯片10**）；$\boldsymbol{A_0}\equiv -E\left(\boldsymbol{H}_i(\boldsymbol{\theta_0};\boldsymbol{y}_i)\right)=\frac{\boldsymbol{1}}{\boldsymbol{n}}\boldsymbol{I}(\boldsymbol{\theta_0})$（**回顾幻灯片11和19**）。
- 由于得分函数的方差为信息矩阵，可推导得出$\boldsymbol{B_0}=\boldsymbol{A_0}$，进而可知：

$$\boldsymbol{A}_0^{-1}\boldsymbol{B}_0\boldsymbol{A}_0^{-1}=\boldsymbol{A}_0^{-1}=n[\boldsymbol{I}(\boldsymbol{\theta}_0)]^{-1}$$

➢定理：不变性

- 如果将$\boldsymbol{\theta}$参数变换为$\boldsymbol{\alpha} \equiv \boldsymbol{g}(\boldsymbol{\theta})$，则对$\boldsymbol{\alpha}$的极大似然估计就是$\hat{\boldsymbol{\alpha}}_{ML} = \boldsymbol{g}\left(\hat{\boldsymbol{\theta}}_{ML}\right)$。
- 其中，$\boldsymbol{g}(\cdot)$可以是多维函数，也不要求$\boldsymbol{\alpha}$与$\boldsymbol{\theta}$有一一对应的函数关系。
- 利用极大似然估计的不变性，有时可以大大简化计算。

【例】对$(\mu + \sigma^2)$的极大似然估计就是$(\hat{\mu}_{ML} + \hat{\sigma}^2_{ML})$。

5.6 极大似然估计量的渐近协方差矩阵

- 在大样本下，极大似然估计量的渐近协方差矩阵为：

$$\mathrm{Avar}(\hat{\boldsymbol{\theta}}_{\mathrm{ML}}) = n[\boldsymbol{I}(\boldsymbol{\theta}_0)]^{-1} = n\left\{-\mathrm{E}\left[\frac{\partial^2 \ln L(\boldsymbol{\theta}_0; \boldsymbol{y})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'}\right]\right\}^{-1}$$

- 此表达式依赖于未知的$\boldsymbol{\theta}_0$，一般有三种估计方法。

1. 期望值法。如果知道黑塞矩阵期望值的具体函数形式，则直接以$\widehat{\boldsymbol{\theta}}_{ML}$替代$\boldsymbol{\theta}_0$，可得：

$$\widehat{\mathrm{Avar}}(\hat{\boldsymbol{\theta}}_{\mathrm{ML}}) = n\left\{-\mathrm{E}\left[\frac{\partial^2 \ln L(\hat{\boldsymbol{\theta}}_{\mathrm{ML}}; \boldsymbol{y})}{\partial \hat{\boldsymbol{\theta}} \partial \hat{\boldsymbol{\theta}}'}\right]\right\}^{-1}$$

潜在问题：黑塞矩阵通常包含复杂的非线性函数，期望值可能无解析解。

2.观测信息矩阵法。以$\hat{\boldsymbol{\theta}}_{ML}$替代$\boldsymbol{\theta}_0$后，将期望算子忽略掉，可得：

$$\widehat{\text{Avar}}(\hat{\boldsymbol{\theta}}_{\text{ML}}) = n\left[-\frac{\partial^2 \ln L(\hat{\boldsymbol{\theta}}_{\text{ML}}; \boldsymbol{y})}{\partial\hat{\boldsymbol{\theta}}\partial\hat{\boldsymbol{\theta}}'}\right]^{-1}$$

此法称为“**观测信息矩阵**”(Observed Information Matrix，简记 OIM)法。此方法比期望值法相对而言更容易实现，但二阶偏导数可能不易计算。

3. 梯度向量外积或BHHH 法。利用信息矩阵等式，用$\sum_{i=1}^{n}\hat{\boldsymbol{s}}_i\hat{\boldsymbol{s}}_i'$来估计$\boldsymbol{I}(\boldsymbol{\theta}_0)$，即：

$$\widehat{\text{Avar}}(\hat{\boldsymbol{\theta}}_{\text{ML}}) = n\left(\sum_{i=1}^{n}\hat{\boldsymbol{s}}_i\hat{\boldsymbol{s}}_i'\right)^{-1}$$

其中，$\hat{\boldsymbol{s}}_i \equiv \frac{\partial lnf(\boldsymbol{y}_i;\hat{\boldsymbol{\theta}}_{\boldsymbol{ML}})}{\partial\boldsymbol{\theta}}$为第$i$个观测值对得分函数的贡献之估计值。此法称为“**梯度向量外积**”(Outer Product of Gradients，简记OPG)或BHHH 法，只需计算一阶偏导数；而且协方差估计量总是非负定的(nonnegative definite)，而OIM法的协方差估计量无此保证。

- 上述这三种方法在大样本下渐近等价 (asymptotically equivalent)。
- 在有限样本中，计算结果可能差别较大，甚至导致统计推断作出不同的结论。
- 这三种方法都建立在**似然函数正确**的前提上。如果似然函数不正确，则三种方法都失效，应使用**稳健标准误**。

5.7 三类渐近等价的统计检验

- 在计量经济学中，经常使用以下三类在大样本下渐近等价的统计检验：**沃尔德检验、似然比检验、拉格朗日乘子检验**。
- 对于线性回归模型，检验原假设$H_0: \boldsymbol{\beta} = \boldsymbol{\beta_0}$，其中$\boldsymbol{\beta}_{K\times 1}$为未知参数，$\boldsymbol{\beta_0}$已知，共有$K$个约束。

(1) 沃尔德检验(Wald Test)

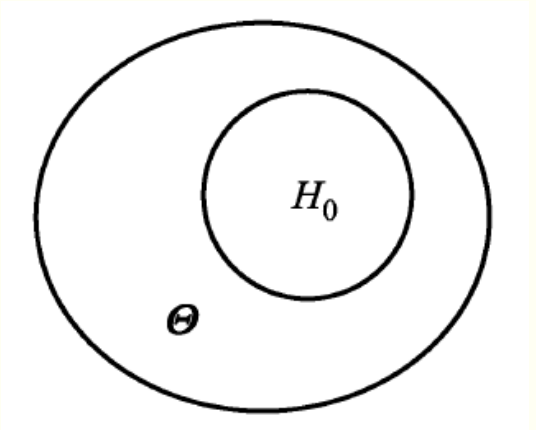
- 通过$\boldsymbol{\beta}$的无约束估计量$\widehat{\boldsymbol{\beta}}_{\boldsymbol{U}}$与$\boldsymbol{\beta_0}$的距离来进行检验。如果$H_0$正确，则$(\widehat{\boldsymbol{\beta}}_{\boldsymbol{U}}-\boldsymbol{\beta_0})$的绝对值不应该很大。
- 沃尔德统计量：

$$W \equiv (\hat{\boldsymbol{\beta}}_U - \boldsymbol{\beta}_0)' [\mathrm{Var}(\hat{\boldsymbol{\beta}}_U)]^{-1} (\hat{\boldsymbol{\beta}}_U - \boldsymbol{\beta}_0) \xrightarrow{d} \chi^2(K)$$

- 其中，K为约束条件的个数，证明类似于第4讲对于线性假设“$H_0: \boldsymbol{R\beta} = \boldsymbol{r}$”的大样本检验。事实上，$t$检验、$F$检验都是Wald检验。

(2) 似然比检验(Likelihood Ratio Test，简记LR)

- 无约束的似然函数最大值$\ln L(\widehat{\boldsymbol{\beta}}_{\boldsymbol{U}})$比有约束的似然函数最大值$\ln L(\widehat{\boldsymbol{\beta}}_{\boldsymbol{R}})$更大，因为在无约束条件下的参数空间$\Theta$比有约束条件下(即$H_0$成立时)参数的取值范围更大。
- 在此例中，有约束的估计量$\widehat{\boldsymbol{\beta}}_{\boldsymbol{R}} = \boldsymbol{\beta}_{\boldsymbol{0}}$。
- 如果H_0正确，则$\ln L\left(\widehat{\boldsymbol{\beta}}_{\boldsymbol{U}}\right) - \ln L(\widehat{\boldsymbol{\beta}}_{\boldsymbol{R}})$不应该很大。
- LR统计量：



$$\mathrm{LR} \equiv -2\ln\left[\frac{L(\hat{\boldsymbol{\beta}}_R)}{L(\hat{\boldsymbol{\beta}}_U)}\right] = 2\left[\ln L(\hat{\boldsymbol{\beta}}_U) - \ln L(\hat{\boldsymbol{\beta}}_R)\right] \xrightarrow{d} \chi^2(K)$$

(3) 拉格朗日乘子检验(Lagrange Multiplier Test，简记LM)：

- 考虑有约束条件的对数似然函数最大化问题：

$$\max_{\tilde{\beta}} \ \ln L(\tilde{\beta})$$
$$s.t. \ \ \beta = \beta_0$$

- 引入拉格朗日乘子函数，可得：

$$\max_{\tilde{\beta},\lambda} \ \ln L(\tilde{\beta}) - \lambda'(\tilde{\beta} - \beta_0)$$

- 其中，$\boldsymbol{\lambda}$为拉格朗日乘子向量。如果$\hat{\boldsymbol{\lambda}} \approx \mathbf{0}$，则说明此约束条件不“紧”(tight) 或不是“硬约束”(binding constraint)，加上此约束条件不会使似然函数的最大值下降很多，即原假设H_0很可能成立。

- 根据一阶条件(对$\tilde{\boldsymbol{\beta}}$求导)，可知：$\hat{\boldsymbol{\lambda}} = \frac{\partial ln\, L(\hat{\boldsymbol{\beta}}_R)}{\partial \tilde{\boldsymbol{\beta}}}$。

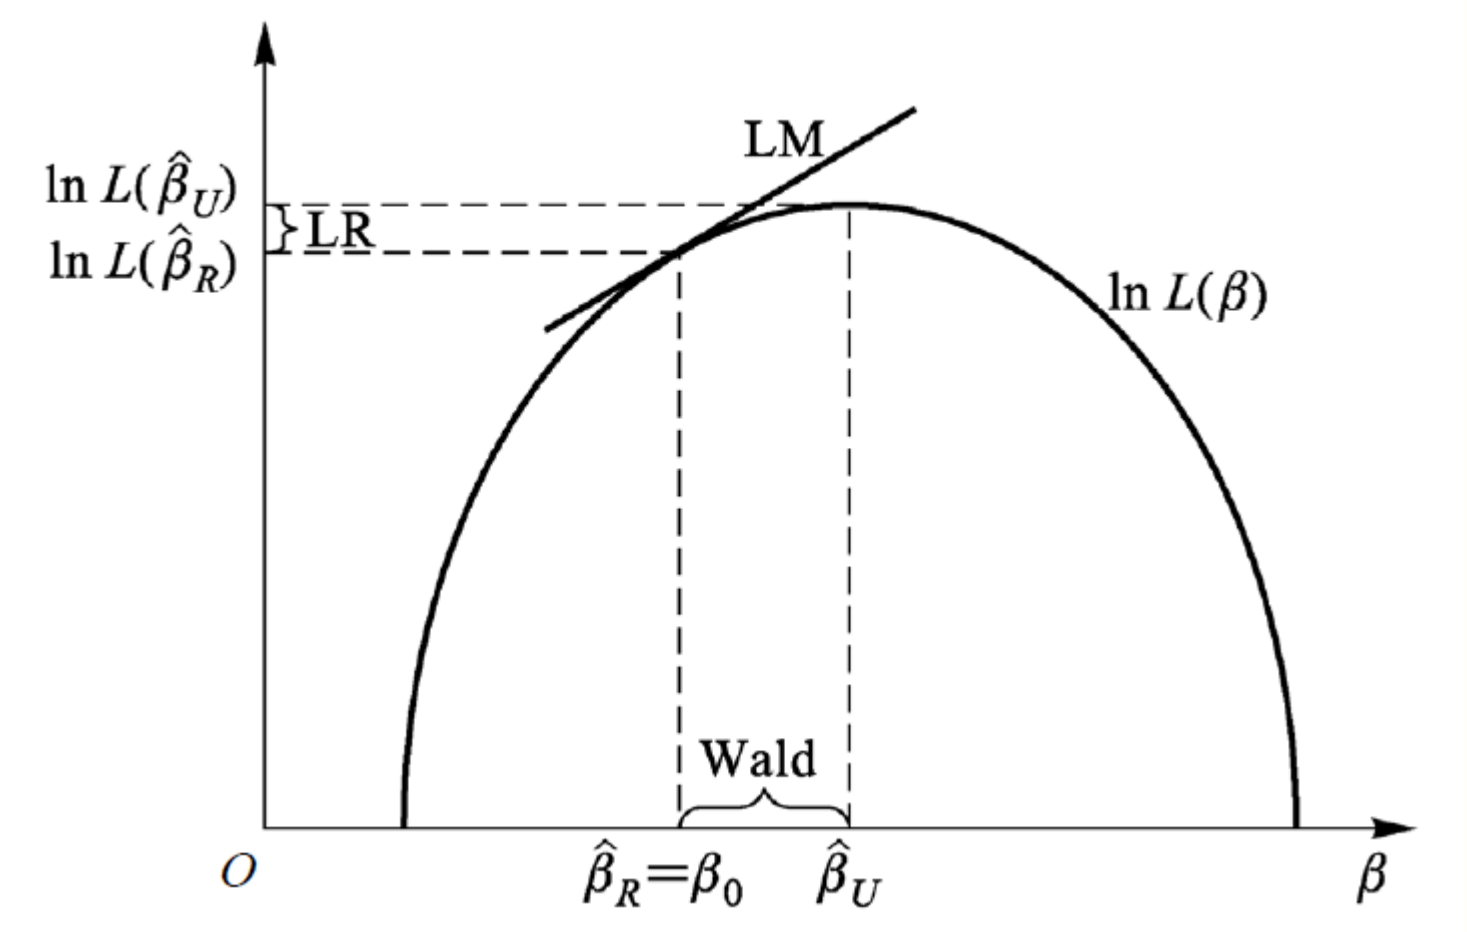
- LM统计量：

$$\mathrm{LM} \equiv \left(\frac{\partial \ln L(\hat{\boldsymbol{\beta}}_R)}{\partial \tilde{\boldsymbol{\beta}}}\right)' \left[\boldsymbol{I}(\hat{\boldsymbol{\beta}}_R)\right]^{-1} \left(\frac{\partial \ln L(\hat{\boldsymbol{\beta}}_R)}{\partial \tilde{\boldsymbol{\beta}}}\right) \xrightarrow{d} \chi^2(K)$$

其中，$\boldsymbol{I}(\hat{\boldsymbol{\beta}}_R)$为信息矩阵在$\hat{\boldsymbol{\beta}}_R$处的取值。由于$\frac{\partial \ln L(\tilde{\boldsymbol{\beta}})}{\partial \tilde{\boldsymbol{\beta}}}$为“得分函数”(score function)，故也称“得分检验”(score test)；而$\boldsymbol{I}(\hat{\boldsymbol{\beta}}_R)$为得分函数的协方差矩阵。

在$\hat{\boldsymbol{\beta}}_U$处，$\frac{\partial \ln L(\hat{\boldsymbol{\beta}}_U)}{\partial \tilde{\boldsymbol{\beta}}} = \mathbf{0}$。如$H_0$成立，则在$\hat{\boldsymbol{\beta}}_R$处，也应有$\frac{\partial \ln L(\hat{\boldsymbol{\beta}}_R)}{\partial \tilde{\boldsymbol{\beta}}} \approx \mathbf{0}$，而LM统计量反映此接近程度。

➢图示：三类统计检验渐近等价



➢三类统计检验之对比：

- Wald检验仅利用无约束估计的信息，LM检验仅利用有约束估计的信息，而LR检验同时利用二者的信息。
- 这三类检验在大样本下渐近等价，但小样本性质不同。
- 实际应用中究竟采取哪种检验常取决于“无约束估计”与“有约束估计”哪种更方便。
- 从计算便捷性的角度来看，LM 检验具有显著优势。它仅需要估计受约束模型即可进行检验，无需估计复杂的无约束模型，在大型计量模型的设定检验中应用广泛。

- 为了直观理解三类统计检验的区别，可以将似然函数的最大化过程比作“寻找山峰的最高点”：

1. **Wald 检验（沃尔德检验）—— 基于“距离”的检验**
   - **视角**：站在无约束的全局最优解（山顶 $\hat{\beta}_U$）处进行考察。
   - **核心思想**：衡量受约束估计值 $\hat{\beta}_R$ 偏离全局最优解 $\hat{\beta}_U$ 的距离（即考察 $\hat{\beta}_R - \hat{\beta}_U$ 的大小）。如果距离过大，则说明原假设的约束不合理。
2. **LR 检验（似然比检验）—— 基于“高度差”的检验**
   - **视角**：同时比较两个模型的似然函数极值。
   - **核心思想**：衡量无约束模型的最大似然值（山顶高度）与受约束模型的最大似然值之间的落差（即考察 $2[\ln L(\hat{\beta}_U) - \ln L(\hat{\beta}_R)]$）。如果似然值下降过多，则拒绝原假设。
3. **LM 检验（拉格朗日乘数检验）—— 基于“斜率”的检验**
   - **视角**：站在受约束模型的最优解（山腰位置 $\hat{\beta}_R$）处进行考察。
   - **核心思想**：在受约束的最优点处，考察对数似然函数的一阶导数（即斜率）。如果原假设成立，受约束的最优点应无限接近山顶，该处的斜率应趋近于0；如果斜率显著不为0（即还有继续上升的空间），说明约束条件与数据相悖。

5.8 准极大似然估计法*

- 如果随机变量不服从正态分布，却使用了以正态分布为前提的MLE，该估计量是否一致？
- 对于线性模型，MLE 估计量等价于OLS 估计量，而OLS估计量的一致性不依赖于正态分布的假定。

定义 使用不正确的似然函数而得到的极大似然估计，被称为准极大似然估计 (Quasi MLE，简记QMLE)或“伪极大似然估计”(Pseudo MLE)。

- 虽然 MLE 常要求随机变量服从正态，此假定可能并不强。
- 如果 QMLE 估计量满足以下两个条件，则为一致估计量。

(i) 模型设定的概率密度函数属于“线性指数分布族”(linear exponential family)，线性指数分布族包括正态分布，二项分布，泊松分布，负二项分布，Γ分布，以及逆高斯分布(inverse Gaussian)等。

(ii) 条件期望$E(y \mid \boldsymbol{x})$的函数形式设定正确。

- 一般情况下，QMLE估计量并不一致，譬如后面要介绍的Tobit回归。即使QMLE 碰巧一致，$\widehat{\boldsymbol{\theta}}_{QML}$的渐近方差也不再是$n[\boldsymbol{I}(\boldsymbol{\theta_0})]^{-1}$。
- 假设正确的对数似然函数为$\ln L(\boldsymbol{\theta};\ \boldsymbol{y})$，被误设为$\ln L^*(\boldsymbol{\theta};\ \boldsymbol{y})$，称为“准对数似然函数”(pseudo log likelihood function)。最大化$\ln L^*(\boldsymbol{\theta};\ \boldsymbol{y})$的结果即为QMLE估计量。即：

$$\widehat{\boldsymbol{\theta}}_{QML} \equiv \text{argmax } \ln L^*(\boldsymbol{\theta};\ \boldsymbol{y})$$

- 遵循类似于 MLE 一致性的证明步骤，可证明$\widehat{\boldsymbol{\theta}}_{QML} \xrightarrow{p} \boldsymbol{\theta}^*$。
- 其中，$\boldsymbol{\theta}^*$称为“准真实值”(pseudo-true value)，通常$\boldsymbol{\theta}^* \neq \boldsymbol{\theta_0}$。(一致性？)

- 对于$\widehat{\boldsymbol{\theta}}_{QML}$的大样本分布，可证明：

$$\sqrt{n}\left(\widehat{\boldsymbol{\theta}}_{ML}-\boldsymbol{\theta}^{*}\right)\xrightarrow{d}N\left(\mathbf{0},\boldsymbol{A}_{\mathbf{0}}^{*-\mathbf{1}}\boldsymbol{B}_{\mathbf{0}}^{*}\boldsymbol{A}_{\mathbf{0}}^{*-\mathbf{1}}\right)$$

- 由于$\ln L^{*}(\boldsymbol{\theta};\ \boldsymbol{y})$并非真正的对数似然函数，信息矩阵等式不成立，故一般$\boldsymbol{B}_{\mathbf{0}}^{*}\neq\boldsymbol{A}_{\mathbf{0}}^{*}$，夹心形式的协方差矩阵$\boldsymbol{A}_{\mathbf{0}}^{*-\mathbf{1}}\boldsymbol{B}_{\mathbf{0}}^{*}\boldsymbol{A}_{\mathbf{0}}^{*-\mathbf{1}}$无法简化。
- 基于$\boldsymbol{A}_{\mathbf{0}}^{*-\mathbf{1}}\boldsymbol{B}_{\mathbf{0}}^{*}\boldsymbol{A}_{\mathbf{0}}^{*-\mathbf{1}}$的标准误差被称为“胡贝尔-怀特稳健标准误”(Huber-White robust standard errors)。
- **胡贝尔-怀特稳健标准误也简称为“稳健标准误”，因为它与异方差稳健标准误是一致的。**
- 假设用 MLE 来估计古典线性回归模型，真实模型存在异方差，但在同方差的错误设定下来求MLE估计量，即得到的就是QMLE估计量。
- 这里的$\widehat{\boldsymbol{\theta}}_{QML}$依然是真实参数$\boldsymbol{\theta}$的一致估计，而胡贝尔-怀特稳健标准误就是异方差稳健的标准误。

- 在使用 MLE 估计非线性模型时，如果对模型的正确设定无把握，而QMLE估计量依然一致，应使用(胡贝尔-怀特)稳健标准误。Stata 中相应的选项为“`r`”或“`vce(robust)`”，需要根据具体的回归命令进行选择。
- 如果对于模型设定很有信心，可直接使用 OIM 或OPG 法来估计渐近方差，没有必要使用稳健标准误。
- 当 QMLE 估计量不一致时，即使采用(胡贝尔-怀特)稳健标准误也无济于事，应担心估计量的一致性。此时，(胡贝尔-怀特)稳健标准误只是一致地估计了一个不一致估计量的方差(a consistent estimator of the variance of an inconsistent estimator)。
- 无论 OIM、OPG 法，还是(胡贝尔-怀特)稳健标准误，都假设样本数据为iid。如果样本数据可分为若干组，而同一组内的观测值存在自相关，则应使用“ 聚 类稳健标准误”(cluster-robust standard errors)，在Stata中由选项“`vce(cluster clustvar)`”来实现。

➢**总结：**

- 对于线性回归模型，建议总是使用稳健标准误。
- 对于非线性模型，可分四种情况考虑：

(i) 如果对模型设定较有信心或模型拟合得较好，可不用稳健标准误。

(ii) 如果对模型设定缺乏信心，且QMLE为一致估计，应使用稳健标准误。

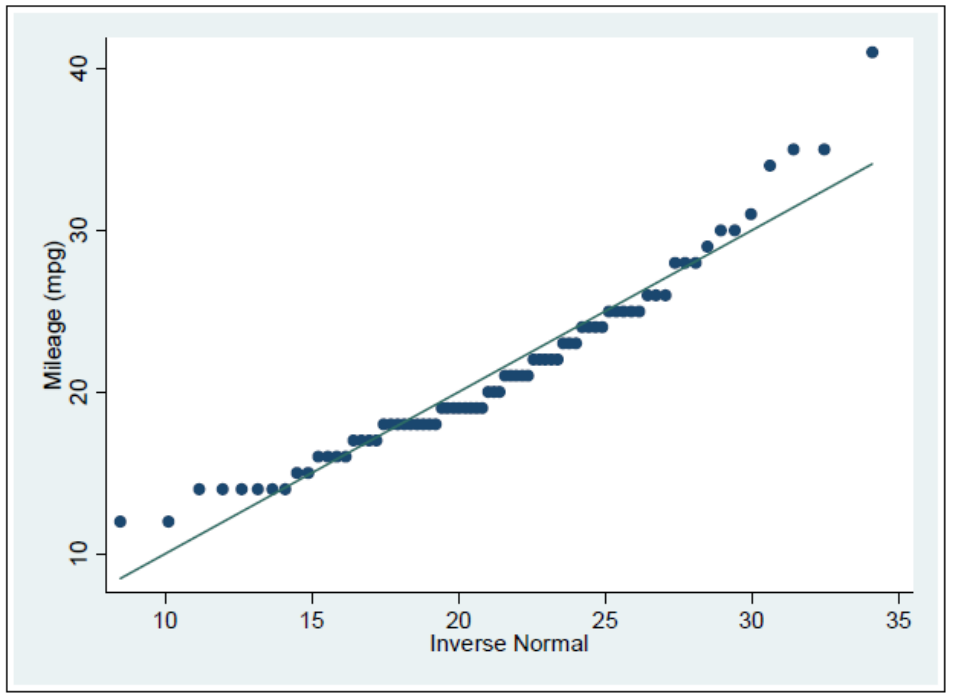
(iii) 如果对模型设定缺乏信心，但QMLE也不一致，应首先担心QMLE估计量的一致性，仅使用稳健标准误进行校正无济于事。

(iv) 对于聚类样本，应使用聚类稳健的标准误。

5.9 对正态分布假设的检验*

- 对于线性回归模型，即使扰动项不服从正态分布，OLS依然一致，且服从渐近正态，可用进行大样本推断；故检验扰动项是否服从正态分布意义不大。
- 对非线性模型，由于正态分布假定是推导 MLE的前提，故检验扰动项是否服从正态分布可能较重要。
- 在某些情况下，“准极大似然估计”也一致，但毕竟不如真正的MLE有效率。
- 为了考察扰动项是否为正态，最直观的方法是画图。可把残差画成直方图(histogram)，并与正态分布的密度函数比较。
- 但直方图是不连续的。为得到光滑估计，可使用“核密度估计法”(kernel density estimation)，并与正态密度相比。

- 另一画图方法是，将正态分布的分位数(quantiles)与残差的分位数画成散点图 (scatter plot)。
- 如果残差来自正态分布，则该图上的散点应该集中在 45°线附近。
- 称这种图为“分位数-分位数图”(Quantile-Quantile plot，简记QQ plot)。



QQ 图

- 常用的检验方法利用了正态分布的偏度与峰度性质。
- 随机变量X的偏度为$E[(\mathrm{X}-\mu)/\sigma]^3$，峰度为$E[(\mathrm{X}-\mu)/\sigma]^4$，超额峰度为$E[(\mathrm{X}-\mu)/\sigma]^4-3$。
- 对于残差$\{e_1, e_2, \ldots, e_n\}$，其偏度与超额峰度的样本估计值分别为：

$$\frac{1}{n\hat{\sigma}^3}\sum_{i=1}^{n} e_i^3$$

$$\left(\frac{1}{n\hat{\sigma}^4}\sum_{i=1}^{n} e_i^4\right)-3$$

- 其中，$\bar{e}=0$。在扰动项服从正态分布的原假设下，这两个统计量服从正态分布。

- “雅克-贝拉检验”(Jarque and Bera, 1987，简记JB)使用它们的平方之加权平均作为检验统计量：

$$JB \equiv \frac{n}{6}\left[\left(\frac{1}{n\hat{\sigma}^3}\sum_{i=1}^{n} e_i^3\right)^2 + \frac{1}{4}\left(\frac{1}{n\hat{\sigma}^4}\sum_{i=1}^{n} e_i^4 - 3\right)^2\right] \xrightarrow{d} \chi^2(2)$$

- JB 检验虽常用，但收敛速度较慢，对样本容量要求较高。
- Stata 官方程序中提供了D’Agostino et al. (1990)的改进方法，基于偏度与峰度设计了更复杂的检验统计量，参见“`help sktest`”。
- 另外，Stata也提供了检验正态性的两种非参数方法，参见“`help swilk`”。
- 如果发现某变量不服从正态分布，有时可以通过取对数，使之变得更接近于正态分布。

5.10 STATA相关操作命令

- **极大似然估计**
  - STATA提供了一个“ml”的命令，可以自行定义似然函数来执行极大似然估计，进行程序完整架构定义的指令结构如下（详见“help ml”）：
  - ml model *method* progname (eq1: y = x1 x2 …) (eq2: x3 x4) (eq3: …) … 【需要先运行program define progname定义程序】
  - 其中，method的常见选项包括lf、d0、d1、d2、lf0、lf1、lf2和gf0。
  - ml方法的关键命令是ml model命令和ml maximize命令，ml model命令用来定义需要拟合的模型，ml maximize命令用来执行最大化。
  - 但通常不需要进行这么复杂的操作，因为对于多数需要使用极大似然估计的情形，STATA都给出了专门的命令，比如后面要讲的Logit/Probit等离散被解释变量模型。
- **LR检验**
  - LR检验可通过STATA命令lrtest来实现。后面我们讨论面板数据的时候，也可以用lrtest命令来对面板数据的异方差进行检验。

- **LM检验**
- STATA 并没有一个名为 `lmtest` 的通用命令来直接实现你课件中那种最一般形式的 LM 检验，但它针对不同的模型设定和检验目的，提供了多种可调用的命令。例如：
  - `xttest0`：用于 `xtreg, re`估计之后，执行 Breusch and Pagan (1980) 的 LM 检验，原假设为随机效应的方差为零（即混合 OLS 优于随机效应）。
  - `estat scoretests`：用于结构方程模型（`sem`）估计之后，对模型中用户指定的线性约束执行得分检验（即 LM 检验）。
  - `lgrgtest`：需通过 `ssc install lgrgtest`安装，可在多种极大似然估计命令（如 `logit`、`probit`、`sem`等）之后，检验通过 `constraints()`选项施加的线性约束。

- **Wald检验**
  - 参考第4讲，在跑完回归（如 `regress`、`logit`、`probit`等）后，使用`test`或`testnl`命令即可。

经济与工商管理学院
BNU Business School

问题与讨论

电子邮箱：licheng.xu@bnu.edu.cn

办公室：后主楼1730A