第五讲：极大似然估计（MLE）补充材料

1. 三类渐近等价的统计检验

（1）为什么 Wald、LR、LM 三个统计量都渐近服从自由度为 K 的卡方分布？

在统计学渐近理论中，似然比检验（LR）、沃尔德检验（W）和拉格朗日乘数检验（LM）在样本量趋于无穷时是**渐近等价**的。它们最终都可以转化为同一个核心形式：

$$(\text{估计偏差})' \times (\text{偏差的协方差矩阵})^{-1} \times (\text{估计偏差})$$

这恰好是**多元正态随机向量的二次型。**

根据统计学理论：

1. 参数估计量 $\hat{\beta}$ 在大样本下渐近服从正态分布。
2. 如果随机向量 $Z \sim N(0, \Sigma)$，那么二次型 $Z'\Sigma^{-1}Z$ 服从**卡方分布**，其自由度等于 Z 的维数。
3. 在原假设下，约束条件的个数是 K（即受限制的参数个数），因此该二次型的"维度"为 K。

因此，当样本量 $n \to \infty$ 时，LR 统计量趋近于一个服从自由度为 K 的卡方分布（$\chi^2(K)$）。

（2）LR 统计量表达式里那个系数-2 和 2 都是怎么来的？

为什么似然比统计量（LR）的表达式中包含 -2 这个系数？这源于对对数似然函数在极大值点附近的二**阶泰勒展开。**

假设 $\hat{\beta}_U$ 是无约束模型的全局极大值点，在此处对数似然函数的一阶导数（得分函数）为 0。那么，对数似然函数在 $\hat{\beta}_U$ 附近可以近似展开为一个开口向下的二次函数：

$$\ln L(\beta) \approx \ln L(\hat{\beta}_U) - \frac{1}{2}(\beta - \hat{\beta}_U)'\mathcal{I}(\beta - \hat{\beta}_U)$$

其中 $\mathcal{I}$ 是**费雪信息矩阵**（即对数似然函数二阶导数期望值的负数，也称海塞矩阵）。

现在，将受约束模型的估计值 $\hat{\beta}_R$ 代入上述近似式（即令 $\beta = \hat{\beta}_R$）：

$$\ln L(\hat{\beta}_R) \approx \ln L(\hat{\beta}_U) - \frac{1}{2}(\hat{\beta}_R - \hat{\beta}_U)'\mathcal{I}(\hat{\beta}_R - \hat{\beta}_U)$$

对上式进行移项，并在等式两边同乘 2，可以得到：

$$2[\ln L(\hat{\beta}_U) - \ln L(\hat{\beta}_R)] \approx (\hat{\beta}_R - \hat{\beta}_U)'\mathcal{I}(\hat{\beta}_R - \hat{\beta}_U)$$

观察等式右侧可以发现，它与沃尔德（Wald）统计量的核心二次型结构是一致的，本质上都是衡量估计偏差的"马氏距离"。等式左侧恰好就是 LR 统计量的定义。因此，乘上 -2 是为了消去泰勒展开式中的 $-\frac{1}{2}$，并抵消对数似然比本身的负号，从而构造出一个与二次型渐近等价的非负统计量。

（3）LM 统计量为什么是课件上那个表达式，尤其是前后两项？

公式中的 $\frac{\partial \ln L(\hat{\beta}_R)}{\partial \tilde{\beta}}$ 表示对数似然函数在**受约束估计值** $\hat{\beta}_R$ 处的**一阶导数**，在统计学中通常被称为**得分向量（Score Vector）**。

- **无约束模型的基准**：在无约束的极大似然估计中，最优解 $\hat{\beta}_U$ 对应似然函数的极值点，该处的一阶导数恒为 0，即 $\frac{\partial \ln L(\hat{\beta}_U)}{\partial \tilde{\beta}} = 0$。
- **受约束模型的检验逻辑**：在原假设成立的前提下，约束条件是真实有效的，受约束估计值 $\hat{\beta}_R$ 应当无限逼近无约束最优解 $\hat{\beta}_U$。由于逼近极值点，此时在 $\hat{\beta}_R$ 处的一阶导数（即似然函数的斜率）应当趋近于 0。
- **拒绝原假设的条件**：反之，如果原假设不成立，约束条件导致估计值严重偏离最优解，对数似然函数在 $\hat{\beta}_R$ 处仍具有显著的上升趋势（即一阶导数显著不为 0）。

逻辑结论：LM 检验的核心思想即考察在受约束估计值处，对数似然函数是否仍存在继续上升的"斜率"。若该斜率显著非零，则表明约束条件施加不当，从而拒绝原假设。

2. 部分定理证明过程（中文版教材第六章附录）

附　　录

A6.1　如果似然函数正确，则得分函数在 $\boldsymbol{\theta}=\boldsymbol{\theta}_0$ 处的期望值为 0，即 $\mathrm{E}\left[\frac{\partial \ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial \boldsymbol{\theta}}\right]=\mathbf{0}$。

证明：因为似然函数 $L(\boldsymbol{\theta};\boldsymbol{y})$ 是概率密度函数，故似然函数的积分为 1，即

$$\int L(\boldsymbol{\theta};\boldsymbol{y})\,\mathrm{d}\boldsymbol{y}=1$$

$$\int \exp[\ln L(\boldsymbol{\theta};\boldsymbol{y})]\,\mathrm{d}\boldsymbol{y}=1 \quad （引入对数似然函数）$$

方程两边对 $\boldsymbol{\theta}$ 求导可得

$$\int \exp[\ln L(\boldsymbol{\theta};\boldsymbol{y})]\frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}}\mathrm{d}\boldsymbol{y}=\mathbf{0} \quad （假设积分与求导可交换次序）$$

$$\int \frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}}L(\boldsymbol{\theta};\boldsymbol{y})\,\mathrm{d}\boldsymbol{y}=\mathbf{0}$$

由于似然函数正确，故在 $\boldsymbol{\theta}=\boldsymbol{\theta}_0$ 处，$L(\boldsymbol{\theta}_0;\boldsymbol{y})$ 就是真实的概率密度函数（样本数据 $\boldsymbol{y}$ 来自于此总体）。因此，在上式中令 $\boldsymbol{\theta}=\boldsymbol{\theta}_0$ 即可得，$\mathrm{E}\left[\frac{\partial \ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial \boldsymbol{\theta}}\right]=\mathbf{0}$。

A6.2　证明在 $\boldsymbol{\theta}=\boldsymbol{\theta}_0$ 处， $-\mathrm{E}\left[\frac{\partial^2 \ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial \boldsymbol{\theta}\partial \boldsymbol{\theta}'}\right]=\mathrm{E}\left[\frac{\partial \ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial \boldsymbol{\theta}}\cdot\frac{\partial \ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial \boldsymbol{\theta}'}\right]$。

证明：根据附录 A6.1 可知，

$$\int \frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}}\exp[\ln L(\boldsymbol{\theta};\boldsymbol{y})]\,\mathrm{d}\boldsymbol{y}=\mathbf{0}$$

该方程两边对 $\boldsymbol{\theta}'$ 求导可得（假设积分与求导可交换次序）

$$\int\left\{\frac{\partial^2 \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}\partial \boldsymbol{\theta}'}\exp[\ln L(\boldsymbol{\theta};\boldsymbol{y})]+\frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}}\exp[\ln L(\boldsymbol{\theta};\boldsymbol{y})]\frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}'}\right\}\mathrm{d}\boldsymbol{y}=\mathbf{0}$$

移项可得

$$-\int\left\{\frac{\partial^2 \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}\partial \boldsymbol{\theta}'}\exp[\ln L(\boldsymbol{\theta};\boldsymbol{y})]\right\}\mathrm{d}\boldsymbol{y}=\int\left\{\frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}}\exp[\ln L(\boldsymbol{\theta};\boldsymbol{y})]\frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}'}\right\}\mathrm{d}\boldsymbol{y}$$

直接使用似然函数（而不用对数似然函数），可得

$$-\int\left\{\frac{\partial^2 \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}\partial \boldsymbol{\theta}'}L(\boldsymbol{\theta};\boldsymbol{y})\right\}\mathrm{d}\boldsymbol{y}=\int\left\{\frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}}\cdot\frac{\partial \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial \boldsymbol{\theta}'}L(\boldsymbol{\theta};\boldsymbol{y})\right\}\mathrm{d}\boldsymbol{y}$$

由于似然函数正确，故在 $\boldsymbol{\theta}=\boldsymbol{\theta}_0$ 处，似然函数就是联合密度函数。因此，在上式中令 $\boldsymbol{\theta}=\boldsymbol{\theta}_0$，可得

$$-\mathrm{E}\left[\frac{\partial^2 \ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial\boldsymbol{\theta}\partial\boldsymbol{\theta}'}\right]=\mathrm{E}\left[\frac{\partial \ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial\boldsymbol{\theta}}\cdot\frac{\partial \ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial\boldsymbol{\theta}'}\right]$$

A6.3　证明“克莱默－劳下限”(Cramer-Rao Lower Bound)。

证明：假设 $\hat{\boldsymbol{\theta}}$ 是对真实参数 $\boldsymbol{\theta}_0$ 的任意无偏估计，则在一定的正则条件下，$\mathrm{Var}(\hat{\boldsymbol{\theta}})\geqslant[I(\boldsymbol{\theta}_0)]^{-1}$。为简单起见，只证明一维情形，多维情形可类似证明。

由于 $\hat{\theta}(\boldsymbol{y})$ 是 θ_0 的无偏估计(其中 $\boldsymbol{y}$ 为样本数据)，故

$$\theta_0=\mathrm{E}[\hat{\theta}(\boldsymbol{y})]=\int\hat{\theta}(\boldsymbol{y})L(\theta_0;\boldsymbol{y})\mathrm{d}\boldsymbol{y}\quad(\text{随机变量函数 }\hat{\theta}(\boldsymbol{y})\text{ 的期望定义})$$

将上式两边同时对 θ_0 求导可得，

$$\begin{aligned}
1&=\int\hat{\theta}(\boldsymbol{y})\frac{\partial L(\theta_0;\boldsymbol{y})}{\partial\theta}\mathrm{d}\boldsymbol{y}=\int\hat{\theta}(\boldsymbol{y})\frac{\partial \ln L(\theta_0;\boldsymbol{y})}{\partial\theta}\cdot L(\theta_0;\boldsymbol{y})\mathrm{d}\boldsymbol{y}\\
&=\mathrm{E}\left[\hat{\theta}(\boldsymbol{y})\frac{\partial \ln L(\theta_0;\boldsymbol{y})}{\partial\theta}\right]\qquad(\text{期望的定义})\\
&=\mathrm{Cov}\left[\hat{\theta}(\boldsymbol{y}),\frac{\partial \ln L(\theta_0;\boldsymbol{y})}{\partial\theta}\right]\qquad(\text{根据附录 A6.1},\mathrm{E}\left[\frac{\partial \ln L(\theta_0;\boldsymbol{y})}{\partial\theta}\right]=0)\\
&\leqslant\mathrm{Var}[\hat{\theta}(\boldsymbol{y})]\cdot\mathrm{Var}\left[\frac{\partial \ln L(\theta_0;\boldsymbol{y})}{\partial\theta}\right]\qquad(\text{相关系数小于或等于 1})\\
&=\mathrm{Var}[\hat{\theta}(\boldsymbol{y})]\cdot\mathrm{E}\left[\frac{\partial \ln L(\theta_0;\boldsymbol{y})}{\partial\theta}\right]^2\qquad(\text{根据信息矩阵等式})
\end{aligned}$$

因此，$\mathrm{Var}[\hat{\theta}(\boldsymbol{y})]\geqslant\left[\mathrm{E}\left(\frac{\partial \ln L(\theta_0;\boldsymbol{y})}{\partial\theta}\right)^2\right]^{-1}=I(\theta_0)^{-1}$。

A6.4　证明古典线性回归模型的信息矩阵。

证明：对数似然函数为 $\ln L(\boldsymbol{\beta},\sigma^2)=-\frac{n}{2}\ln 2\pi-\frac{n}{2}\ln\sigma^2-\frac{1}{2\sigma^2}(\boldsymbol{y}-\boldsymbol{X\beta})'(\boldsymbol{y}-\boldsymbol{X\beta})$。为了求导方便，记 $\gamma\equiv\sigma^2$，则 $\ln L(\boldsymbol{\beta},\gamma)=-\frac{n}{2}\ln 2\pi-\frac{n}{2}\ln\gamma-\frac{1}{2\gamma}(\boldsymbol{y}-\boldsymbol{X\beta})'(\boldsymbol{y}-\boldsymbol{X\beta})$。因此，一阶导数为

$$\frac{\partial \ln L(\boldsymbol{\beta},\gamma)}{\partial\boldsymbol{\beta}}=\frac{1}{\gamma}\boldsymbol{X}'(\boldsymbol{y}-\boldsymbol{X\beta})$$

$$\frac{\partial \ln L(\boldsymbol{\beta},\gamma)}{\partial\gamma}=-\frac{n}{2\gamma}+\frac{1}{2\gamma^2}(\boldsymbol{y}-\boldsymbol{X\beta})'(\boldsymbol{y}-\boldsymbol{X\beta})$$

二阶导数为

$$\frac{\partial^2 \ln L(\boldsymbol{\beta},\gamma)}{\partial\boldsymbol{\beta}\partial\boldsymbol{\beta}'}=-\frac{1}{\gamma}\boldsymbol{X}'\boldsymbol{X}$$

$$\frac{\partial \ln L(\boldsymbol{\beta},\gamma)}{\partial\boldsymbol{\beta}\partial\gamma}=-\frac{1}{\gamma^2}\boldsymbol{X}'(\boldsymbol{y}-\boldsymbol{X\beta})=-\frac{1}{\gamma^2}\boldsymbol{X}'\boldsymbol{\varepsilon}$$

$$\frac{\partial^2 \ln L(\boldsymbol{\beta},\gamma)}{\partial\gamma^2}=\frac{n}{2\gamma^2}-\frac{1}{\gamma^3}(\boldsymbol{y}-\boldsymbol{X\beta})'(\boldsymbol{y}-\boldsymbol{X\beta})=\frac{n}{2\gamma^2}-\frac{1}{\gamma^3}\boldsymbol{\varepsilon}'\boldsymbol{\varepsilon}$$

根据严格外生性 $\mathrm{E}(\boldsymbol{\varepsilon}\mid\boldsymbol{X})=0$ 可知，$\mathrm{E}(\boldsymbol{X}'\boldsymbol{\varepsilon})=0$，故 $\mathrm{E}\left(\frac{\partial \ln L(\boldsymbol{\beta},\gamma)}{\partial\boldsymbol{\beta}\partial\gamma}\right)=-\frac{1}{\gamma^2}\mathrm{E}(\boldsymbol{X}'\boldsymbol{\varepsilon})=0$。另外，$\mathrm{E}(\boldsymbol{\varepsilon}'\boldsymbol{\varepsilon})=\mathrm{E}\left(\sum_{i=1}^{n}\varepsilon_i^2\right)=n\sigma^2=n\gamma$，故 $\mathrm{E}\left(\frac{\partial^2 \ln L(\boldsymbol{\beta},\gamma)}{\partial\gamma^2}\right)=\frac{n}{2\gamma^2}-\frac{1}{\gamma^3}\mathrm{E}(\boldsymbol{\varepsilon}'\boldsymbol{\varepsilon})=\frac{n}{2\gamma^2}-\frac{n}{\gamma^2}=-\frac{n}{2\gamma^2}$。将 $\gamma\equiv\sigma^2$ 代回表达式可得，

$$I(\boldsymbol{\theta})\equiv-\mathrm{E}\left(\frac{\partial^2 \ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial\boldsymbol{\theta}\partial\boldsymbol{\theta}'}\right)=-\mathrm{E}\begin{pmatrix}\dfrac{\partial^2 \ln L(\boldsymbol{\beta},\gamma)}{\partial\boldsymbol{\beta}\partial\boldsymbol{\beta}'} & \dfrac{\partial \ln L(\boldsymbol{\beta},\gamma)}{\partial\boldsymbol{\beta}\partial\gamma}\\ \dfrac{\partial \ln L(\boldsymbol{\beta},\gamma)}{\partial\gamma\partial\boldsymbol{\beta}} & \dfrac{\partial^2 \ln L(\boldsymbol{\beta},\gamma)}{\partial\gamma^2}\end{pmatrix}=\begin{pmatrix}\dfrac{1}{\sigma^2}\boldsymbol{X}'\boldsymbol{X} & \boldsymbol{0}\\ \boldsymbol{0} & \dfrac{n}{2\sigma^4}\end{pmatrix}$$

因此，信息矩阵的逆矩阵为

$$I(\boldsymbol{\theta})^{-1}=\begin{pmatrix}\frac{1}{\sigma^2}\boldsymbol{X}'\boldsymbol{X} & \mathbf{0}\\ \mathbf{0} & \frac{n}{2\sigma^4}\end{pmatrix}^{-1}=\begin{pmatrix}\sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1} & \mathbf{0}\\ \mathbf{0} & \frac{2\sigma^4}{n}\end{pmatrix}$$

A6.5 证明最大似然估计量的不变性。

证明：将 $\boldsymbol{\alpha}$ 视为对原参数 $\boldsymbol{\theta}$ 的参数变换(reparameterization)，则可以将似然函数写为 $\boldsymbol{\alpha}$ 函数。记 $L(\boldsymbol{\theta};\boldsymbol{y})$ 为以 $\boldsymbol{\theta}$ 为参数的似然函数，其最大似然估计为 $\hat{\boldsymbol{\theta}}_{\mathrm{ML}}$。定义 $\hat{\boldsymbol{\alpha}}_{\mathrm{ML}}\equiv\boldsymbol{g}(\hat{\boldsymbol{\theta}}_{\mathrm{ML}})$，需要证明 $\hat{\boldsymbol{\alpha}}_{\mathrm{ML}}$ 为对 $\boldsymbol{\alpha}$ 的最大似然估计。

定义以 $\boldsymbol{\alpha}$ 为参数的似然函数为

$$\begin{aligned}
L_g(\boldsymbol{\alpha};\boldsymbol{y}) &\equiv \sup_{\{\boldsymbol{\theta}:\boldsymbol{g}(\boldsymbol{\theta})=\boldsymbol{\alpha}\}} L(\boldsymbol{\theta};\boldsymbol{y}) && (\text{可能多个}\ \boldsymbol{\theta}\ \text{满足“}\boldsymbol{g}(\boldsymbol{\theta})=\boldsymbol{\alpha}\text{”，择其最大者})\\
&\leqslant \sup_{\boldsymbol{\theta}} L(\boldsymbol{\theta};\boldsymbol{y}) && (\text{去掉约束条件“}\boldsymbol{g}(\boldsymbol{\theta})=\boldsymbol{\alpha}\text{”，不会减小最大值})\\
&= L(\hat{\boldsymbol{\theta}}_{\mathrm{ML}};\boldsymbol{y}) && (\text{根据最大似然估计量的定义})\\
&= \sup_{\{\boldsymbol{\theta}:\boldsymbol{g}(\boldsymbol{\theta})=\boldsymbol{g}(\hat{\boldsymbol{\theta}}_{\mathrm{ML}})=\hat{\boldsymbol{\alpha}}_{\mathrm{ML}}\}} L(\boldsymbol{\theta};\boldsymbol{y}) && (\text{由于}\ \hat{\boldsymbol{\theta}}_{\mathrm{ML}}\in\{\boldsymbol{\theta}:\boldsymbol{g}(\boldsymbol{\theta})=\boldsymbol{g}(\hat{\boldsymbol{\theta}}_{\mathrm{ML}})\}\text{，故可加约束条件})\\
&= L_g(\hat{\boldsymbol{\alpha}}_{\mathrm{ML}};\boldsymbol{y}) && (\text{根据以}\ \boldsymbol{\alpha}\ \text{为参数的似然函数的定义})
\end{aligned}$$

因此，$L_g(\boldsymbol{\alpha};\boldsymbol{y})\leqslant L_g(\hat{\boldsymbol{\alpha}}_{\mathrm{ML}};\boldsymbol{y})$，$\forall\boldsymbol{\alpha}$，即 $L_g(\boldsymbol{\alpha};\boldsymbol{y})$ 在 $\boldsymbol{\alpha}=\hat{\boldsymbol{\alpha}}_{\mathrm{ML}}$ 处达到最大值，故 $\hat{\boldsymbol{\alpha}}_{\mathrm{ML}}$ 是对 $\boldsymbol{\alpha}$ 的最大似然估计。在上面的推导中，sup 为“上确界”(least upper bound)算子。如果上确界可以达到，则上确界等于最大值。

A6.6 关于 BHHH 法：为什么用 $\sum_{i=1}^{n}\hat{\boldsymbol{s}}_i\hat{\boldsymbol{s}}_i'$ 来估计信息矩阵 $\boldsymbol{I}(\boldsymbol{\theta})$。

因为 $\dfrac{\partial\ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial\boldsymbol{\theta}}=\dfrac{\partial\left[\sum_{i=1}^{n}\ln f(\boldsymbol{y}_i;\boldsymbol{\theta})\right]}{\partial\boldsymbol{\theta}}=\sum_{i=1}^{n}\dfrac{\partial\ln f(\boldsymbol{y}_i;\boldsymbol{\theta})}{\partial\boldsymbol{\theta}}\equiv\sum_{i=1}^{n}\boldsymbol{s}_i$，

所以 $\dfrac{\partial^2\ln L(\boldsymbol{\theta};\boldsymbol{y})}{\partial\boldsymbol{\theta}\partial\boldsymbol{\theta}'}=\sum_{i=1}^{n}\dfrac{\partial^2\ln f(\boldsymbol{y}_i;\boldsymbol{\theta})}{\partial\boldsymbol{\theta}\partial\boldsymbol{\theta}'}$。因此，

$$\begin{aligned}
\boldsymbol{I}(\boldsymbol{\theta}_0) &\equiv -\mathrm{E}\left[\frac{\partial^2\ln L(\boldsymbol{\theta}_0;\boldsymbol{y})}{\partial\boldsymbol{\theta}\partial\boldsymbol{\theta}'}\right] && (\text{信息矩阵的定义})\\
&= -\mathrm{E}\left[\sum_{i=1}^{n}\frac{\partial^2\ln f(\boldsymbol{y}_i;\boldsymbol{\theta}_0)}{\partial\boldsymbol{\theta}\partial\boldsymbol{\theta}'}\right] && (\text{样本信息矩阵等于每个观测值信息矩阵之和})\\
&= \sum_{i=1}^{n}\left[-\mathrm{E}\left(\frac{\partial^2\ln f(\boldsymbol{y}_i;\boldsymbol{\theta}_0)}{\partial\boldsymbol{\theta}\partial\boldsymbol{\theta}'}\right)\right] && (\text{求和与期望算子交换次序})\\
&= \sum_{i=1}^{n}\left[\mathrm{E}\left(\frac{\partial\ln L(\boldsymbol{\theta}_0;\boldsymbol{y}_i)}{\partial\boldsymbol{\theta}}\cdot\frac{\partial\ln L(\boldsymbol{\theta}_0;\boldsymbol{y}_i)}{\partial\boldsymbol{\theta}'}\right)\right] && (\text{信息矩阵等式})\\
&= \sum_{i=1}^{n}\mathrm{E}(\boldsymbol{s}_i\boldsymbol{s}_i') && (\boldsymbol{s}_i\ \text{的定义})\\
&= n\mathrm{E}(\boldsymbol{s}_i\boldsymbol{s}_i') && (\text{iid 的假设})
\end{aligned}$$

由于 $\sum_{i=1}^{n}\hat{\boldsymbol{s}}_i\hat{\boldsymbol{s}}_i'=n\left(\frac{1}{n}\sum_{i=1}^{n}\hat{\boldsymbol{s}}_i\hat{\boldsymbol{s}}_i'\right)$，而 $\frac{1}{n}\sum_{i=1}^{n}\hat{\boldsymbol{s}}_i\hat{\boldsymbol{s}}_i'\xrightarrow{p}\mathrm{E}(\boldsymbol{s}_i\boldsymbol{s}_i')$，故 $\sum_{i=1}^{n}\hat{\boldsymbol{s}}_i\hat{\boldsymbol{s}}_i'$ 是 $n\mathrm{E}(\boldsymbol{s}_i\boldsymbol{s}_i')$ 的一致估计。