高级计量经济学

(2026/27学年度 秋季学期)

第七讲（下）：内生性问题讨论

注：本讲部分内容摘自安格里斯特、皮施克合著《基本无害的计量经济学：实证研究者指南》和陈传波独著《STATA统计分析教程（STATA十八讲）》及其配套讲义。

导入：回看教育回报率的案例

美国经济学家明瑟（Mincer，1974）提出的收入（或工资）决定方程：

$$lnY_i = \alpha + \beta_1 educ_i + \beta_2 exper_i + \beta_3 exper_i^2 + u_i$$

其中，*lnY*是工资收入的对数值，*educ*是受教育年限，*exper*是工作经验，明瑟将工作经验定义为年龄减去受教育年限再减去6（儿童入学年龄）。

思考：除了模型误设之外，该模型是否还有别的问题？如果要进行因果识别，应该如何解决？

本讲主要内容

- 内生性问题概述
- 内生性问题的来源
- 如何处理内生性问题
- 样本选择与Heckman两步法

7.11 内生性问题概述

- 在随机抽样和大样本条件下，要获得一致估计，最关键的假设是自变量与误差不相关，又称为自变量的外生性。如果自变量与误差相关，则称之为内生变量。
- 外生或内生有多种情形，最严格的情形称为严格外生，即：

$$E(u|X) = 0 \rightarrow Cov(x_{ij}, u_k) = 0$$

- 注意x和u的下标不同。严格外生要求任意一个误差与自变量$\boldsymbol{X}$中任何一个自变量的任一样本（随机变量）均不相关。在时间序列数据中，当自变量中含滞后因变量时，这一假定基本上不成立。考虑一个$AR(1)$模型：

$$y_t = \beta y_{t-1} + u_t$$

$$E(u_t \mid Y) = 0 \Rightarrow \begin{cases} E(y_t u_t) = 0 \\ E(y_{t-1} u_t) = 0 \end{cases}$$

$$E(y_t u_t) = E[\beta y_{t-1} + u_t) u_t] = \beta E(y_{t-1} u_t) + E u_t^2 \neq 0$$

- 在按简单随机抽样形成的横截面样本中，因样本间相互独立，则**严格外生可弱化**为要求每i个样本误差项以每i个样本的自变量X_i为条件的期望为零。在时间序列分析时，称为**同期外生性**。

$$E(u|X)=0 \xrightarrow{iid} E(u|X)=E(u_i|X_i,X_{-i})=E(u_i|X_i)=0 \Rightarrow E(xu)=\text{cov}(x,u)=0$$

- 内生性通常与模型设定密切相关，当自变量与误差**同期不相关**这一假设不成立时，OLS估计是不一致的。

- 导致内生性的原因有很多，本节将讨论内生性的几个主要来源。

7.12 内生性问题的主要来源

➢内生性的常见来源：

- 模型误设（本讲前半节）
  - 遗漏变量
  - 函数形式误设
- 测量误差
- 样本选择
- 联立因果

测量误差

1. 因变量测量误差

- 如果因变量的测量误差与自变量不相关，则OLS估计具有良好的性质，是无偏且一致的。反之，OLS估计将是有偏且不一致的。

真实模型为:

$y = \beta x + u \quad 且 E(xu) = 0$ (1)

但因变量存在测量误差ε, 实际测量值

$y^* = y + \varepsilon$ (2)

将(2)代入(1)得到

$y^* = \beta x + \varepsilon + u,$

因为计算时使用的数据是(x, y^*),故有

$E[x(\varepsilon + u)] = E(x\varepsilon) + E(xu) = E(x\varepsilon)$ (3)

除非$E(x\varepsilon) = 0$,否则(3)必不为零, 无法得到β的一致估计

- 仍然以教育与收入的关系为例，对收入的调查通常是非常困难的，真实的收入可能永远是个谜，我们能收集到的只能是受访者自报收入，自报收入与真实收入之间存在测量误差，而且这个测量误差往往与教育水平相关，如教育水平越低，越可能算不清楚他的收入。

- 此外，即便高收入的受访者没有隐瞒实际收入的意图，收入越高的人一般回忆的误差也就越大（比如收入来源太多），而收入越高的人，通常更可能是教育水平较高的人。

- 上述两类因变量测量误差与自变量的相关性都会导致无法得到待估参数的一致估计。

2. 自变量测量误差

- 自变量的测量误差分两种情形，一种涉及到测量误差与观测值之间的相关性，另一种涉及到测量误差与真实值之间的相关性。
- **第一种情形：**测量误差与观测值不相关。

真实模型为：

$$y = \beta x + u \tag{1}$$

但x观测不到，x的测量值为x^*，测量误差为ε，即

$$x^* = x + \varepsilon \tag{2}$$

将(2)代入(1)得到

$$y = \beta x + u = \beta(x^* - \varepsilon) + u = \beta x^* + u - \beta\varepsilon$$

$$E[x^*(u - \beta\varepsilon)] = E(x^*u) - \beta E(x^*\varepsilon)$$

$$= 0 \quad (\text{当 } E(x^*u) = 0 \text{ 且 } E(x^*\varepsilon) = 0)$$

当测量误差ε与测量值x^*不相关，且测量值x^*与误差u不相关时，才能得到一致估计，但方差变大

$$Var(u - \beta\varepsilon) = \sigma^2 + \beta^2\sigma_\varepsilon^2 > \sigma^2$$

- **第二种情形：**测量误差与观测不到的真实值无关。
- 例如，y为学习成绩，x为旷课次数，当一个人很少旷课时，他所报告的旷课次数更准确，相反，随着旷课次数的增多，他能够准确回忆并报告其次数的可能性也下降，因此测量误差与报告结果存在正相关。

真实模型：$y=\beta x+u,$

但x观测不到，x的测量值为x^*，测量误差为ε，即

$$x^*=x+\varepsilon$$

$$y=\beta x+u=\beta(x^*-\varepsilon)+u=\beta x^*+u-\beta\varepsilon$$

如果测量误差ε与观测不到的变量x无关，

$$E(x\varepsilon)=0$$

则测量误差ε必然与观测变量 x^*相关，因为

$$E(x^*\varepsilon)=E[(x+\varepsilon)\varepsilon]=E(x\varepsilon)+\sigma_\varepsilon^2=\sigma_\varepsilon^2>0$$

$$E[x^*(u-\beta\varepsilon)]=E(x^*u)-\beta E(x^*\varepsilon)=E(x^*u)-\beta\sigma_\varepsilon^2\neq 0$$

OLS估计量是不一致的

样本选择

- 考虑一个简单的例子：去医院接受治疗能够让人变得更健康吗？**对于习惯进行实证研究的学者而言，自然而然的方法就是比较去过医院和没去医院的人在健康状况上的差异。**

- 美国全国健康采访调查（NHIS）包含了进行这种比较的信息。具体而言，这个调查里包含这样一个问题，“在过去的12个月中，被访者是否曾因病在医院过夜？”，我们可以用这个问题来识别最近去过医院的人。全国健康采访调查还问，“总体而言，你觉得你的健康水平是极好、非常好、好、一般还是差？”下面的表格给出了最近去医院和没有去过医院的人的平均健康状况（对健康状况最差的人赋值1，对健康状况最好的人赋值5）。

组别	样本大小	平均健康水平	标准差
去过医院	7774	3.21	0.014
没去过医院	90049	3.93	0.003

- 从表面上看，两者之间的平均差距是0.72，没有去过医院的人健康状况更好，这个结果意味着去医院会使人的健康状况变差。但是，**我们很容易解释为什么这个结果不能只从表面上看：去医院的人可能本身健康水平就比较差。更进一步讲，即使在医院接受过治疗，那些到医院寻求治疗的人的健康水平还是不如没有去医院的人。**

- 用数学公式来理解上述道理，可以通过加减同一个数，将总效应分解为**因果效应**（cause effect）和**选择性偏误**（selection bias）。**注意，下标*i*和*j*代表不同个体或群体。**

$$\beta = y_i^1 - y_i^0 + y_i^0 - y_j^0 = (y_i^1 - y_i^0) + (y_i^0 - y_j^0)$$

cause effect *selection bias*

- 再次回到教育回报率的案例。如果我们想知道，接受高等教育能不能带来更高的收入。通常的做法是比较一群高中毕业的人和一群大学毕业生的工资。在现实中，研究者一般无法随机安排别人的教育水平，因此是否接受大学教育这一处理（treatment）是与很多个人和家庭因素相关的（例如：父母收入、父母受教育水平，等等）。从而，这一变量是内生的。由此，会产生样本选择偏误。

- 由于这部分选择性偏误被忽略了，即使我们发现大学生的平均工资比没上过大学的人的平均工资高，也不能得出上大学可以提高收入的结论，因为这个出现这个差异有可能是仅仅是因为上大学的人平均智力水平高，而上大学本身并不能帮助我们提高收入。

- 处理样本选择偏误的常见方法是**Heckman两步法**。

联立因果

- 联立因果关系普遍存在，尤其是在经济学的经典供求关系中。实际上，经济学中的供给方程和需求方程都只是我们的一个理论抽象，真实世界中是不存在的，我们能从真实世界中观察到的价格和供需量都只有一个，即均衡价格和均衡供需量。
- 利用这样的均衡供需量对均衡价格进行估计，我们究竟估计的是需求方程呢还是供给方程呢？估计系数是正还是负呢？因为供给方程和需求方程的系数正好是一正一负（正常商品），那么是否意味着，我们可以根据估计结果来判断是供给方程还是需求方程？
- 实际上，这种估计既非供给方程也非需求方程。我们可以证明，采用均衡数据对单一供给方程或需求方程进行估计，都无法得到一致的估计结果。

假设真实模型是如下的联立方程

$$\begin{cases} x = \beta y + u & (1) \\ y = \delta x + \varepsilon & (2) \end{cases}$$

对于上述联立方程，如果仅估计单一方程 (1) 并要求得到系数β的一致估计，则必须满足

$$E(yu) = 0 \qquad (3)$$

将(1)代入(2)，得

$$y = \delta(\beta y + u) + \varepsilon$$

$$y = \frac{\delta}{1-\beta\delta}u + \frac{1}{1-\beta\delta}\varepsilon$$

$$E(yu) = \frac{\delta}{1-\beta\delta}E(u^2) = \frac{\delta\sigma_u^2}{1-\beta\delta} \qquad (4)$$

除非$\delta = 0$，否则(4)式必不为零，与(3)矛盾

7.13 如何处理内生性问题

➢内生性的常见处理方法：

- 增加控制变量（本讲前半节）
- 使用代理变量（本讲前半节）
- 工具变量（第8讲）
- 面板数据（第9讲）
- 随机实验与自然实验（第10讲）
- 其他技术性手段（例如Heckman两步法、联立方程模型等）

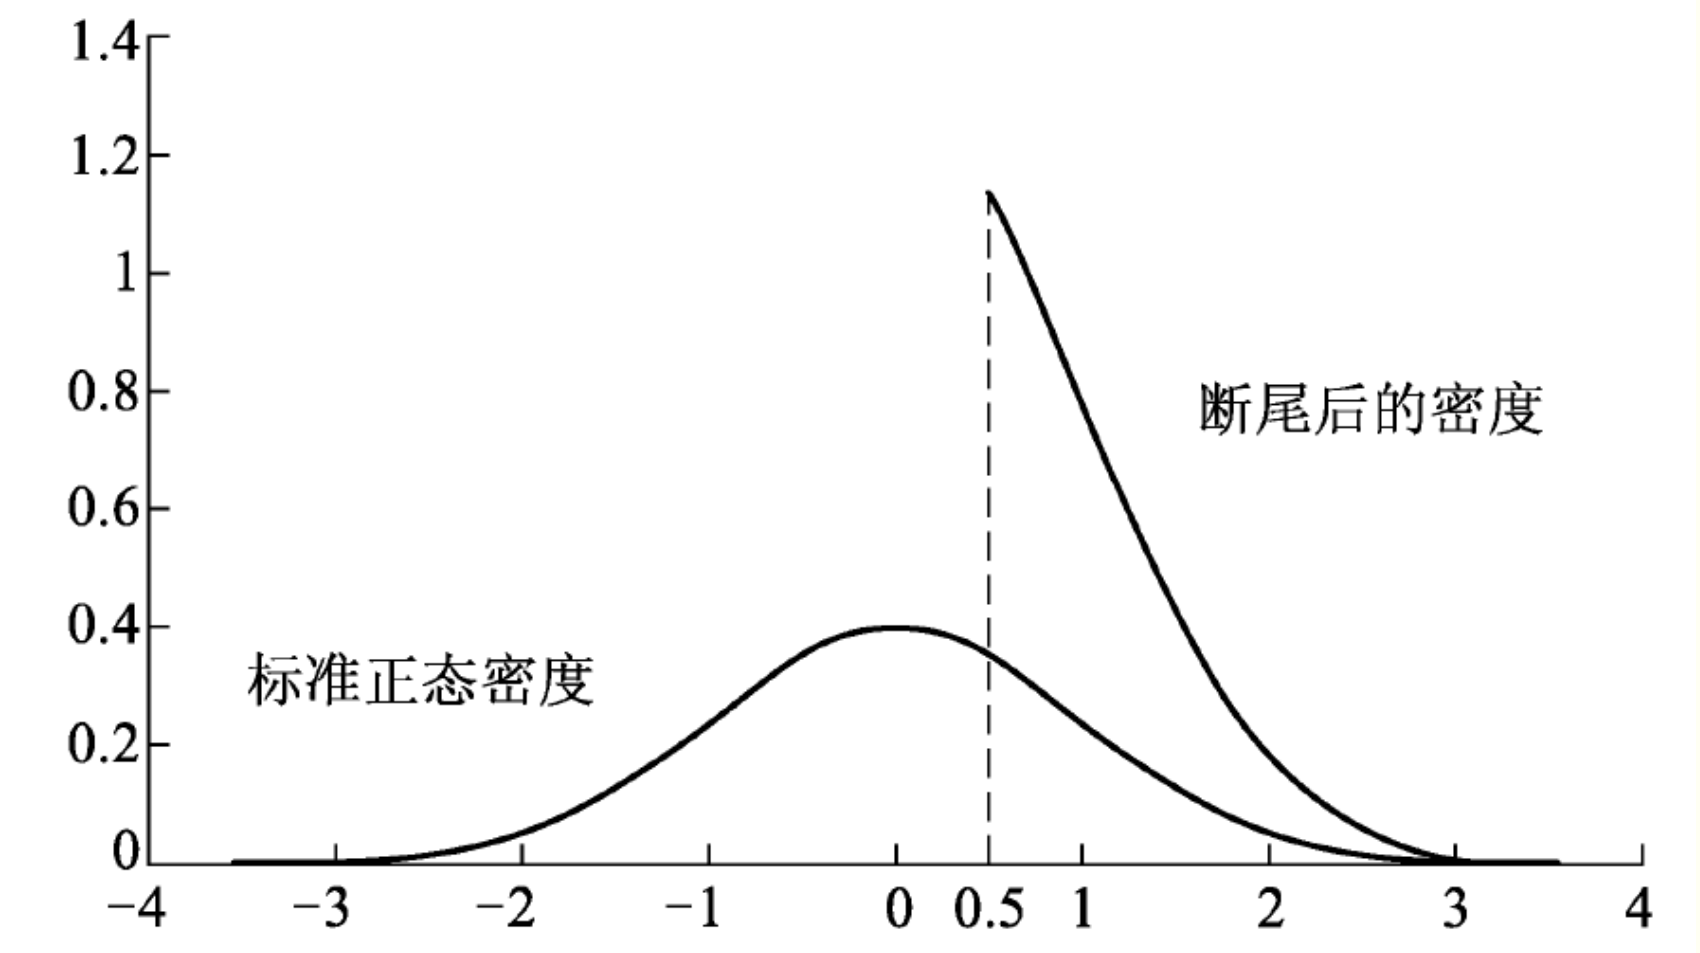
7.14 样本选择与Heckman两步法

➢ **断尾** (truncation)：对线性模型$y_i = \boldsymbol{x}_i'\boldsymbol{\beta} + \epsilon_i$，假设只有满足$y_i \geq c$的数据才能观测到。【参见教材第14章第1节】

- **例**：y_i为所有企业的销售收入，而统计局只收集规模以上企业数据，比如y_i ≥100,000。被解释变量在100,000处存在“左边断尾” (left truncation)。
- 断尾随机变量的概率分布随机变量 y 断尾后，其概率密度随之变化。
- 记y的概率密度为$f(y)$，在c处左边断尾后的条件概率密度函数为：

$$f(y \mid y > c) = \begin{cases} \dfrac{f(y)}{\mathrm{P}(y > c)}, & \text{若} \quad y > c \\ 0, & \text{若} \quad y \leq c \end{cases}$$

- 由于概率密度曲线下的面积为1，故断尾变量的密度函数乘以因子$\frac{1}{P(y>c)}$。


1.4
1.2
1
0.8
0.6
0.4
0.2
0
−4
−3
−2
−1
0
0.5
1
2
3
4
断尾后的密度
标准正态密度

- **断尾分布的期望也发生变化**，以左边断尾为例。
- 对于最简单情形，$y \sim N(0,1)$，可证明：

$$E(y \mid y > c) = \frac{\phi(c)}{1 - \Phi(c)}$$

- 对于任意实数 c，定义“反米尔斯比率”(Inverse Mill’s Ratio，简记IMR)为：

$$\lambda(c) \equiv \frac{\phi(c)}{1 - \Phi(c)}$$

- 则：$E(y \mid y > c) = \lambda(c)$。
- 对于正态分布 $y \sim N(\mu, \sigma^2)$，定义 $z \equiv \frac{y-\mu}{\sigma} \sim N(0,1)$，则$y = \mu + \sigma z$。故：

$$\begin{aligned} \mathrm{E}(y \mid y > c) &= \mathrm{E}(\mu + \sigma z \mid \mu + \sigma z > c) = \mathrm{E}\left[\mu + \sigma z \middle| z > (c - \mu)/\sigma\right] \\ &= \mu + \sigma \mathrm{E}\left[z \middle| z > (c - \mu)/\sigma\right] = \mu + \sigma \cdot \lambda\left[(c - \mu)/\sigma\right] \end{aligned}$$

- **样本选择** (sample selection)本质上是一种“**偶然断尾**” (occasional truncation)，即被解释变量y_i的断尾与另一变量z_i有关，称z_i为**选择变量**。【参见教材第14章第4节】

- **例1**：在美国的亚裔移民给人的整体印象是聪明能干。但在美国的亚裔并非亚洲人口的代表性样本。通常只有受过高等教育或具有吃苦冒险精神的亚裔才会“自我选择”(self selection)移民。决定移民与否的变量便对被解释变量产生了断尾作用，故“样本选择”将导致“**选择性偏差**”(selection bias)。
- **例2**：劳动力供给模型
- 劳动时间方程：$hours = \alpha_0 + \alpha_1\, wage + \alpha_2\, children + \alpha_3\, marriage + u$
- 工资方程：$w^o - w^r = \beta_0 + \beta_1\, age + \beta_2\, educ + \beta_3\, children + \beta_4\, location + v$
- w^o表示**工资报价** (offered wage)，w^r表示**期望薪酬/保留工资** (reservation wage)。
- 如果$w^o - w^r < 0$，则选择不工作，无法观测到劳动时间(hours)，造成劳动时间方程的偶然断尾与样本选择问题。

- 考虑二维正态随机向量(y,z)，记期望为(μ_y,μ_z)，标准差为(σ_y,σ_z)，相关系数为ρ，联合密度函数为$f(y,z)$。
- 假设个体进入样本的“选择机制”(selection mechanism)为，“选择变量z大于某常数c”。比如，在劳动力供给决策的例子中，$z=w^o-w^r$，而$c=0$。
- 断尾后的联合分布：

$$f(y,z|z>c)=\frac{f(y,z)}{P(z>c)}$$

- 将上式中的z积分掉，可以证明偶然断尾y的条件期望为：

$$E(y\mid z>c)=\mu_y+\rho\sigma_y\lambda[(c-\mu_z)/\sigma_z]$$

- 其中，$\lambda(\cdot)$为反米尔斯比率(IMR)函数。

- 如果$\rho = 0$(即y与z不相关)，则z的选择过程并不对y产生影响。
- 如果$\rho > 0$(即y与z正相关)，则“$z > c$”偶然断尾的结果是把y的整个分布推向右边(因为$\lambda(\cdot) > 0$)，从而使得条件期望$E(y|z > c)$大于无条件期望$E(y)$。
- 在“$z < c$”条件下，偶然断尾y的条件期望为：

$$E(y\,|z < c) = \mu_y - \rho\sigma_y\lambda[(\mu_z - c)/\sigma_z]$$

- 假设回归模型为$y_i = \boldsymbol{x}_i'\boldsymbol{\beta} + \epsilon_i$，$y_i$是否可观测取决于选择变量$z_i$(取值为0或1)。

$$y_i = \begin{cases} \text{可观测} & z_i=1 \\ \text{不可观测} & z_i=0 \end{cases}$$

- 决定二值变量z_i的方程为：

$$z_i = \begin{cases} 1, & \text{若} \quad z_i^* > 0 \\ 0, & \text{若} \quad z_i^* \le 0 \end{cases}$$

- 其中，$z_i^* = \boldsymbol{w}_i'\boldsymbol{\gamma} + u_i$，$z_i^*$为不可观测的潜变量。
- 假设u_i服从正态分布，则z_i为Probit模型，故$P(z_i = 1|\boldsymbol{w_i}) = \Phi(\boldsymbol{w}_i'\boldsymbol{\gamma})$。
- 可观测样本的条件期望：

$$\begin{aligned}\mathrm{E}(y_i \mid y_i\text{可观测}) &= \mathrm{E}(y_i \mid z_i^* > 0) = \mathrm{E}(\boldsymbol{x}_i'\boldsymbol{\beta} + \varepsilon_i \mid \boldsymbol{w}_i'\boldsymbol{\gamma} + u_i > 0) \\ &= \mathrm{E}(\boldsymbol{x}_i'\boldsymbol{\beta} + \varepsilon_i \mid u_i > -\boldsymbol{w}_i'\boldsymbol{\gamma}) = \boldsymbol{x}_i'\boldsymbol{\beta} + \mathrm{E}(\varepsilon_i \mid u_i > -\boldsymbol{w}_i'\boldsymbol{\gamma}) \\ &= \boldsymbol{x}_i'\boldsymbol{\beta} + \rho\sigma_\varepsilon\lambda(-\boldsymbol{w}_i'\boldsymbol{\gamma})\end{aligned}$$

- 其中，$E(\epsilon_i) = E(u_i) = 0$，并将Probit扰动项的标准差$\sigma_u$标准化为1。
- 如果使用OLS估计，将遗漏非线性项$\rho\sigma_\epsilon\lambda(-\boldsymbol{w}_i'\boldsymbol{\gamma})$。
- 如果$\boldsymbol{w}_i$与$\boldsymbol{x}_i$相关，则OLS估计量不一致，除非$\rho = 0$(即y与z不相关)。

- 解释变量x_{ik}的边际效应：

$$\frac{\partial \mathrm{E}(y_i \mid z_i^* > 0)}{\partial x_{ik}} = \beta_k + \rho\sigma_\varepsilon \frac{\partial \lambda(-\boldsymbol{w}_i'\boldsymbol{\gamma})}{\partial x_{ik}}$$

- 右边第一项为直接影响，第二项是通过改变个体进入样本可能性而产生的间接影响(即选择性偏差)。
- 如果知道$\boldsymbol{\gamma}$，就能知道$\lambda(-\boldsymbol{w}_i'\boldsymbol{\gamma})$，可把它作为解释变量引入回归方程。
- Heckman (1979)提出“两步估计法”，也称“Heckit”（2000年诺贝尔经济学奖）。
- 第一步：用Probit估计方程$P(z_i = 1|\boldsymbol{w_i}) = \Phi(\boldsymbol{w}_i'\boldsymbol{\gamma})$，得到估计值$\hat{\boldsymbol{\gamma}}$，计算$\hat{\lambda}(-\boldsymbol{w}_i'\hat{\boldsymbol{\gamma}})$。
- 第二步：用OLS回归$y_i \xrightarrow{OLS} \boldsymbol{x}_i, \hat{\lambda}_i$，得到估计值$\hat{\boldsymbol{\beta}}$，$\hat{\rho}$和$\hat{\sigma}_\epsilon$。

- 更有效率的方法是 MLE。
- 在两步法中，第一步误差被带入第二步，效率不如 MLE 的整体估计。
- 两步法的优点在于，操作简便；对于分布的假设也更弱(即使不假设二维正态分布，也可能成立)。
- 为检验是否存在样本选择偏差(sample selection bias)，可使用似然比检验来检验原假设“$H_0: \rho = 0$”。
- 如使用 Heckit，则无法进行此LR检验。
- **样本选择模型的STATA命令**
  - **两步法：**`heckman y x1 x2 x3, select(z1 z2) twostep`
  - **MLE：**`heckman y x1 x2 x3, select(z1 z2)` **【STATA默认使用MLE】**

经济与工商管理学院
BNU Business School

问题与讨论

电子邮箱：licheng.xu@bnu.edu.cn

办公室：后主楼1730A